# Phân cụm dữ liệu

Trần Hồng Việt

Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội

# Nội dung


1. Khái niệm phân cụm dữ liệu
2. Hiểu dữ liệu trước khi phân cụm
3. Phân cụm phân cấp (Hierarchical clustering)
4. Phân cụm phân vùng (Partitioning clustering)
5. **Phân cụm theo phân phối (Distribution-based)**
6. Phân cụm theo mật độ (Density-based)
7. Kiểm định và đánh giá kết quả phân cụm
8. Tài liệu tham khảo và Kết luận

# Các phương pháp phân cụm dựa trên phân phối

- Hầu hết các thuật toán phân cụm được thảo luận trong bài giảng này là các thuật toán phân cụm **cứng** (hard clustering), trong đó mỗi điểm dữ liệu được gán xác định vào một cụm cụ thể.
- Các thuật toán dựa trên phân phối hoặc dựa trên mô hình xác suất là các thuật toán **mềm** (soft algorithms), trong đó mỗi điểm dữ liệu có thể có xác suất được gán khác 0 cho nhiều (thường là tất cả) các cụm.
- Nguyên tắc chung của **mô hình sinh dựa trên hỗn hợp** (mixture-based generative model) là giả định rằng dữ liệu được sinh ra từ một hỗn hợp của $k$ phân phối với các phân phối xác suất $G_1, G_2, \ldots, G_k$. Mỗi phân phối $G_i$ đại diện cho một cụm và còn được gọi là một thành phần hỗn hợp (mixture component).
- Mỗi phân phối $G_i$ được gắn với một hàm mật độ xác suất $f_i(x)$. Giả định phổ biến nhất là $G_i$ ($i = 1..k$) tuân theo phân phối Gauss (chuẩn).
- Và phương pháp phân cụm dựa trên mô hình xác suất phổ biến nhất là **Mô hình hỗn hợp Gauss** (Gaussian mixture models - GMMs) với thuật toán **cực đại hóa kỳ vọng** (expectation maximization - EM).

# Bài toán phân cụm dữ liệu nhìn lại



- Giả sử $X = (X_1, X_2, \ldots, X_d)$ là một không gian $d$ chiều, trong đó mỗi thuộc tính/biến $X_j$ là dạng số hoặc dạng phân loại.
- Giả sử $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ là một mẫu dữ liệu hoặc tập dữ liệu gồm $n$ điểm dữ liệu (thực thể, quan sát, ví dụ) $x_i = (x_1, x_2, \ldots, x_d) \in X$.
- Phân cụm dữ liệu là việc sử dụng một thuật toán $\mathcal{A}$ để gán các điểm dữ liệu trong $\mathcal{D}$ vào các cụm có khả năng nhất của chúng. Kết quả là một tập hợp gồm $k$ cụm $C = \{C_1, C_2, \ldots, C_k\}$. Các điểm dữ liệu trong cùng một cụm thì tương đồng với nhau và khác biệt với các điểm dữ liệu trong các cụm khác.

# Mô hình hỗn hợp Gauss (GMMs)

- Giả định rằng mỗi cụm $C_i$ ($i = 1..k$) được đặc trưng bởi một phân phối chuẩn đa biến, nghĩa là:

$$f_i(x) = f(x|\mu_i, \Sigma_i) = \frac{1}{(2\pi)^{\frac{d}{2}}|\Sigma_i|^{\frac{1}{2}}} \exp\left\{-\frac{(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i)}{2}\right\} \quad (23)$$

trong đó trung bình cụm $\mu_i \in \mathbb{R}^d$ và ma trận hiệp phương sai $\Sigma_i \in \mathbb{R}^{d\times d}$ đều là các tham số chưa biết. $f_i(x)$ là mật độ xác suất tại $x$ thuộc về cụm $C_i$.

- Giả định rằng hàm mật độ xác suất của $X$ được cho dưới dạng một mô hình hỗn hợp Gauss trên $k$ phân phối chuẩn của cụm:

$$f(x) = \sum_{i=1}^{k} f_i(x)P(C_i) = \sum_{i=1}^{k} f(x|\mu_i, \Sigma_i)P(C_i) \quad (24)$$

trong đó các xác suất tiên nghiệm $P(C_i)$ được gọi là các tham số hỗn hợp, phải thỏa mãn điều kiện: $\sum_{i=1}^{k} P(C_i) = 1$.

# Mô hình hỗn hợp Gauss (tiếp)

- Do đó, mô hình hỗn hợp Gauss được đặc trưng bởi trung bình $\mu_i$, ma trận hiệp phương sai $\Sigma_i$ và xác suất hỗn hợp $P(C_i)$ cho mỗi trong số $k$ phân phối chuẩn.
- Chúng ta có thể viết tập hợp tất cả các tham số mô hình một cách ngắn gọn là:

$$\theta = \{(\mu_i, \Sigma_i, P(C_i))\}_{i=1}^{k}$$

- Hoặc:

$$\theta = \{\mu_1, \Sigma_1, P(C_1), \mu_2, \Sigma_2, P(C_2), \ldots, \mu_k, \Sigma_k, P(C_k)\}$$

# Ước lượng hợp lý cực đại (MLE)

- Cho tập dữ liệu $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ và các tham số mô hình $\theta$, hàm hợp lý của mô hình $f(x)$ trên $\mathcal{D}$ khi biết $\theta$, ký hiệu là $P(\mathcal{D}|\theta)$.
- Vì mỗi điểm trong n điểm $x_j$ được coi là một mẫu ngẫu nhiên độc lập từ $X$, hàm hợp lý là:

$$P(\mathcal{D}|\theta) = \prod_{j=1}^{n} f(x_j) \quad (25)$$

- Mục tiêu của MLE là chọn các tham số $\theta^*$ sao cho tối đa hóa hàm hợp lý:

$$\theta^* = \arg\max_{\theta} P(\mathcal{D}|\theta) \quad (26)$$

- Thông thường người ta sẽ tối đa hóa logarit của hàm hợp lý (log-likelihood):

$$\theta^* = \arg\max_{\theta} \{\log P(\mathcal{D}|\theta)\} \quad (27)$$

# Ước lượng hợp lý cực đại (tiếp)

- Hàm log-hợp lý:

$$\log P(\mathcal{D}|\theta) = \sum_{j=1}^{n} \log f(x_j) = \sum_{j=1}^{n} \log \left( \sum_{i=1}^{k} f(x_j|\mu_i, \Sigma_i) P(C_i) \right) \quad (28)$$

- Việc trực tiếp tối đa hóa hàm log-hợp lý theo $\theta$ là rất khó. Thay vào đó, chúng ta có thể sử dụng phương pháp Cực đại hóa Kỳ vọng (Expectation-Maximization - EM) để tìm các ước lượng hợp lý cực đại cho các tham số $\theta$.
- EM là một phương pháp tiếp cận lặp hai bước, bắt đầu từ một phỏng đoán ban đầu cho các tham số $\theta$.

# Thuật toán cực đại hóa kỳ vọng (EM)

- Biết các ước lượng hiện tại cho $\theta$, trong bước kỳ vọng (expectation step), EM tính toán các xác suất hậu nghiệm $P(C_i|x_j)$ của cụm thông qua định lý Bayes:

$$P(C_i|x_j) = \frac{P(C_i \text{ và } x_j)}{P(x_j)} = \frac{P(x_j|C_i)P(C_i)}{\sum_{r=1}^{k} P(x_j|C_r)P(C_r)} \quad (29)(30)$$

- Vì mỗi cụm được mô hình hóa như một phân phối chuẩn đa biến, xác suất của $x_j$ khi biết cụm $C_i$ có thể tính được bằng cách xét một khoảng nhỏ $\epsilon > 0$ có tâm tại $x_j$:

$$P(x_j|C_i) = 2\epsilon \cdot f(x_j|\mu_i, \Sigma_i) = 2\epsilon \cdot f_i(x_j) \quad (31)$$

# Thuật toán cực đại hóa kỳ vọng (EM) (tiếp)

- Xác suất hậu nghiệm của $C_i$ khi biết $x_j$ do đó được cho bởi:

$$P(C_i|x_j) = \frac{f_i(x_j)P(C_i)}{\sum_{r=1}^{k} f_r(x_j)P(C_r)} \quad (32)$$

  $P(C_i|x_j)$ có thể được coi là trọng số hoặc mức độ đóng góp của điểm $x_j$ vào cụm $C_i$. Đây chính là trọng số thành viên đã đề cập trước đó.
- Tiếp theo, trong bước cực đại hóa (maximization step), sử dụng các trọng số $P(C_i|x_j)$, EM ước lượng lại $\theta$, tức là ước lượng lại các tham số $\mu_i$, $\Sigma_i$, và $P(C_i)$ cho mỗi cụm $C_i$.
- Trung bình được ước lượng lại là trung bình có trọng số của tất cả các điểm, ma trận hiệp phương sai là hiệp phương sai có trọng số trên tất cả các cặp chiều, và xác suất tiên nghiệm là tỷ lệ trọng số đóng góp cho cụm đó.

# Thuật toán EM cho không gian một chiều

- Xét tập dữ liệu $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ gồm $n$ điểm dữ liệu $x_j \in \mathbb{R}$ chỉ từ một biến $X$. Đối với mô hình hỗn hợp, chúng ta sử dụng phân phối chuẩn đơn biến cho mỗi cụm:

$$f_i(x) = f(x|\mu_i, \sigma_i^2) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left\{-\frac{(x-\mu_i)^2}{2\sigma_i^2}\right\} \quad (33)$$

  với các tham số cụm $\mu_i$, $\sigma_i^2$ và $P(C_i)$.

- Thuật toán EM bao gồm ba bước:
  - Bước khởi tạo (Initialization step)
  - Bước kỳ vọng (Expectation step)
  - Bước cực đại hóa (Maximization step)
- Bước khởi tạo được thực hiện một lần trong khi bước kỳ vọng và bước cực đại hóa được lặp lại cho đến khi thuật toán hội tụ.

# Thuật toán EM cho không gian một chiều: bước khởi tạo

- Đối với mỗi cụm $C_i$ ($i = 1..k$), chúng ta có thể khởi tạo ngẫu nhiên các tham số cụm: $\mu_i$, $\sigma_i^2$, và $P(C_i)$.
- Trung bình $\mu_i$ được chọn ngẫu nhiên đồng đều từ phạm vi các giá trị có thể có cho biến $X$.
- Thông thường giả định rằng phương sai ban đầu được cho là $\sigma_i^2 = 1$.
- Các xác suất tiên nghiệm của cụm được khởi tạo thành $P(C_i) = 1/k$, nghĩa là mỗi cụm có xác suất bằng nhau.

# Thuật toán EM cho không gian một chiều: bước kỳ vọng

- Giả sử rằng đối với mỗi cụm, chúng ta có một ước lượng cho các tham số: trung bình $\mu_i$, phương sai $\sigma_i^2$, và xác suất tiên nghiệm $P(C_i)$. Dựa vào các giá trị này, các xác suất hậu nghiệm của cụm được tính bằng:

$$P(C_i|x_j) = \frac{f(x_j|\mu_i, \sigma_i^2) \cdot P(C_i)}{\sum_{r=1}^{k} f(x_j|\mu_r, \sigma_r^2) \cdot P(C_r)} \quad (34)$$

- Để thuận tiện, chúng ta sử dụng ký hiệu $w_{ij} = P(C_i|x_j)$, coi xác suất hậu nghiệm như là trọng số hoặc mức độ đóng góp của điểm $x_j$ vào cụm $C_i$.

# Thuật toán EM cho không gian một chiều: bước cực đại hóa

- Giả sử tất cả các giá trị trọng số $w_{ij} = P(C_i|x_j)$ đã biết, bước cực đại hóa sẽ tính toán các ước lượng hợp lý cực đại bằng cách ước lượng lại $\mu_i$, $\sigma_i^2$, và $P(C_i)$.
- Giá trị trung bình cụm $\mu_i$ được ước lượng lại bằng:

$$\mu_i = \frac{\sum_{j=1}^{n} w_{ij} \cdot x_j}{\sum_{j=1}^{n} w_{ij}} \quad (35)$$

- Phương sai cụm được ước lượng lại bằng:

$$\sigma_i^2 = \frac{\sum_{j=1}^{n} w_{ij}(x_j - \mu_i)^2}{\sum_{j=1}^{n} w_{ij}} \quad (36)$$

- Xác suất tiên nghiệm $P(C_i)$ được ước lượng lại bằng:

$$P(C_i) = \frac{\sum_{j=1}^{n} w_{ij}}{\sum_{r=1}^{k} \sum_{j=1}^{n} w_{rj}} = \frac{\sum_{j=1}^{n} w_{ij}}{\sum_{j=1}^{n} 1} = \frac{\sum_{j=1}^{n} w_{ij}}{n} \quad (37)$$

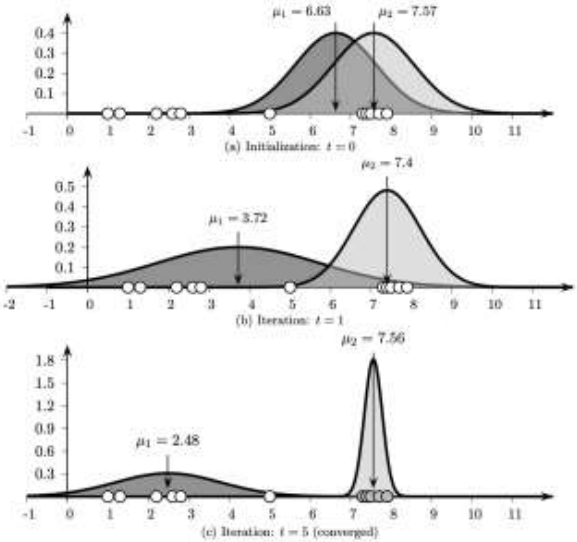
# Thuật toán EM cho không gian một chiều: vòng lặp

- **Vòng lặp**: Bắt đầu từ một tập hợp các giá trị ban đầu cho các tham số $\mu_i$, $\sigma_i^2$ và $P(C_i)$ cho tất cả $i = 1..k$, **thuật toán EM** áp dụng bước kỳ vọng để tính toán các trọng số $w_{ij} = P(C_i|x_j)$.
- Các giá trị này sau đó được sử dụng trong bước **cực đại hóa** để tính toán các tham số cụm được cập nhật $\mu_i$, $\sigma_i^2$ và $P(C_i)$.
- Cả hai bước kỳ vọng và cực đại hóa được áp dụng lặp đi lặp lại cho đến khi hội tụ (ví dụ: cho đến khi các giá trị trung bình thay đổi rất ít giữa các vòng lặp).

# Thuật toán EM cho không gian một chiều: ví dụ [4]

- Xét thuật toán EM trên tập dữ liệu một chiều: $x_1 = 1.0, x_2 = 1.3, x_3 = 2.2, x_4 = 2.6, x_5 = 2.8, x_6 = 5.0, x_7 = 7.3, x_8 = 7.4, x_9 = 7.5, x_{10} = 7.7, x_{11} = 7.9$
- Giả sử $k = 2$. Các tham số khởi tạo ngẫu nhiên ban đầu:
  - $\mu_1 = 6.63, \sigma_1^2 = 1, P(C_1) = 0.5$
  - $\mu_2 = 7.57, \sigma_2^2 = 1, P(C_2) = 0.5$
- Sau vòng lặp thứ nhất ($t = 1$):
  - $\mu_1 = 3.72, \sigma_1^2 = 6.13, P(C_1) = 0.71$
  - $\mu_2 = 7.4, \sigma_2^2 = 0.69, P(C_2) = 0.29$
- Thuật toán hội tụ sau 5 vòng lặp. Sau vòng lặp cuối cùng ($t = 5$):
  - $\mu_1 = 2.48, \sigma_1^2 = 1.69, P(C_1) = 0.55$
  - $\mu_2 = 7.56, \sigma_2^2 = 0.05, P(C_2) = 0.45$

# Thuật toán EM cho không gian một chiều: ví dụ [4] (tiếp)



# Thuật toán EM trong không gian $d$ chiều: Mô hình hỗn hợp Gauss nhìn lại

- Giả định rằng mỗi cụm $C_i$ $(i = 1..k)$ được đặc trưng bởi một phân phối chuẩn đa biến, nghĩa là:

$$f_i(\mathrm{x}) = f(\mathrm{x}|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = \frac{1}{(2\pi)^{\frac{d}{2}}|\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \exp\left\{-\frac{(\mathrm{x}-\boldsymbol{\mu}_i)^T\boldsymbol{\Sigma}_i^{-1}(\mathrm{x}-\boldsymbol{\mu}_i)}{2}\right\} \tag{38}$$

  trong đó trung bình cụm $\boldsymbol{\mu}_i \in \mathbb{R}^d$ và ma trận hiệp phương sai $\boldsymbol{\Sigma}_i \in \mathbb{R}^{d\times d}$ đều là các tham số chưa biết. $f_i(\mathrm{x})$ là mật độ xác suất tại x thuộc về cụm $C_i$.
- Giả định rằng hàm mật độ xác suất của X được cho dưới dạng một *mô hình hỗn hợp Gauss* trên $k$ phân phối chuẩn của cụm, được định nghĩa là:

$$f(\mathrm{x}) = \sum_{i=1}^{k} f_i(\mathrm{x})P(C_i) = \sum_{i=1}^{k} f(\mathrm{x}|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)P(C_i) \tag{39}$$

  trong đó các xác suất tiên nghiệm $P(C_i)$ được gọi là các *tham số hỗn hợp*, phải thỏa mãn điều kiện: $\sum_{i=1}^{k} P(C_i) = 1$.

# Thuật toán EM trong không gian $d$ chiều

- Trong trường hợp không gian $d$ chiều, mỗi cụm được đặc trưng bởi một phân phối chuẩn đa biến (38), với các tham số $\boldsymbol{\mu}_i$, $\boldsymbol{\Sigma}_i$ và $P(C_i)$. Do đó, đối với mỗi cụm $C_i$, chúng ta cần ước lượng vectơ trung bình $d$ chiều và ma trận hiệp phương sai $d \times d$:

$$\boldsymbol{\mu}_i = (\mu_{i1}, \mu_{i2}, \ldots, \mu_{id})^T \tag{40}$$

$$\boldsymbol{\Sigma}_i = \begin{pmatrix} (\sigma_1^i)^2 & \sigma_{12}^i & \ldots & \sigma_{1d}^i \\ \sigma_{21}^i & (\sigma_2^i)^2 & \ldots & \sigma_{2d}^i \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1}^i & \sigma_{d2}^i & \ldots & (\sigma_d^i)^2 \end{pmatrix} \tag{41}$$

- Vì số lượng tham số trong $\boldsymbol{\Sigma}_1, \boldsymbol{\Sigma}_2, \ldots, \boldsymbol{\Sigma}_k$ là rất lớn nếu $d$ lớn. Chúng ta giả định rằng tất cả các chiều là độc lập với nhau, khi đó ta có:

$$\boldsymbol{\Sigma}_i = \begin{pmatrix} (\sigma_1^i)^2 & 0 & \ldots & 0 \\ 0 & (\sigma_2^i)^2 & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \ldots & (\sigma_d^i)^2 \end{pmatrix} \tag{42}$$

# Thuật toán EM trong không gian $d$ chiều: bước khởi tạo

- Đối với mỗi cụm $C_i$, với $i = 1..k$, chúng ta khởi tạo ngẫu nhiên trung bình $\boldsymbol{\mu}_i$ bằng cách chọn một giá trị $\mu_{ia}$ ($a = 1..d$) cho mỗi chiều $X_a$ một cách ngẫu nhiên đồng đều từ dải giá trị của chiều $X_a$.
- Ma trận hiệp phương sai được khởi tạo là ma trận đơn vị $d \times d$, $\boldsymbol{\Sigma}_i = \mathrm{I}$:

$$\boldsymbol{\Sigma}_i = \begin{pmatrix} (\sigma_1^i)^2 & 0 & \dots & 0 \\ 0 & (\sigma_2^i)^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & (\sigma_d^i)^2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{pmatrix} \tag{43}$$

- Cuối cùng, các xác suất tiên nghiệm của cụm được khởi tạo thành $P(C_i) = 1/k$, để mỗi cụm có xác suất bằng nhau.

# Thuật toán EM trong không gian d chiều: bước kỳ vọng

- Trong bước kỳ vọng, chúng ta tính toán xác suất hậu nghiệm của cụm $C_i$ khi biết điểm $x_j$ bằng phương trình (32) với i = 1..k và j = 1..n.
- Ký hiệu rút gọn $w_{ij} = P(C_i|x_j)$ biểu thị trọng số thành viên hoặc mức độ đóng góp của điểm dữ liệu $x_j$ vào cụm $C_i$.
- Và sử dụng ký hiệu $w_i = (w_{i1}, w_{i2}, \ldots, w_{in})^T$ để biểu thị vectơ trọng số cho cụm $C_i$, trên tất cả $n$ điểm dữ liệu.

# Thuật toán EM trong không gian d chiều: bước cực đại hóa

- Dựa trên các trọng số $w_{ij}$, chúng ta ước lượng lại $\mu_i$, $\Sigma_i$ và $P(C_i)$.
- Trung bình $\mu_i$ cho cụm $C_i$ được ước lượng là:

$$\mu_i = \frac{\sum_{j=1}^{n} w_{ij} \cdot x_j}{\sum_{j=1}^{n} w_{ij}} \quad (44)$$

- Gọi $z_{ji} = x_j - \mu_i \in \mathbb{R}^d$, $\Sigma_i$ có thể được tính là:

$$\Sigma_i = \frac{\sum_{j=1}^{n} w_{ij} z_{ji} z_{ji}^T}{\sum_{j=1}^{n} w_{ij}} \quad (45)$$

- Xét theo từng cặp chiều, hiệp phương sai giữa chiều $X_a$ và $X_b$ được tính:

$$\sigma_{ab}^i = \frac{\sum_{j=1}^{n} w_{ij}(x_{ja} - \mu_{ia})(x_{jb} - \mu_{ib})}{\sum_{j=1}^{n} w_{ij}} \quad (46)$$

trong đó $x_{ja}$ và $\mu_{ia}$ là giá trị cho a_th chiều cho $x_j$ và $\mu_i$.

# Thuật toán EM trong không gian d chiều: bước cực đại hóa (tiếp)

- Cuối cùng, xác suất tiên nghiệm $P(C_i)$ cho mỗi cụm giống như trong trường hợp một chiều, được ước lượng lại bằng:

$$P(C_i) = \frac{\sum_{j=1}^{n} w_{ij}}{\sum_{r=1}^{k} \sum_{j=1}^{n} w_{rj}} = \frac{\sum_{j=1}^{n} w_{ij}}{\sum_{j=1}^{n} 1} = \frac{\sum_{j=1}^{n} w_{ij}}{n} \quad (47)$$

# Thuật toán EM trong không gian d chiều: mã giả [4]

**EXPECTATION-MAXIMIZATION** $(\mathbf{D}, k, \epsilon)$:

$t \leftarrow 0$

// Random Initialization

Randomly initialize $\boldsymbol{\mu}_1^t, \cdots, \boldsymbol{\mu}_k^t$

$\boldsymbol{\Sigma}_i^t \leftarrow \mathbf{I},\ \forall i = 1, \ldots, k$

$P^t(C_i) \leftarrow \frac{1}{k},\ \forall i = 1, \ldots, k$

**repeat**

  $t \leftarrow t + 1$

  // Expectation Step

  **for** $i = 1, \ldots, k$ *and* $j = 1, \ldots, n$ **do**

    $w_{ij}^t \leftarrow \frac{f(\mathbf{x}_j|\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot P(C_i)}{\sum_{a=1}^{k} f(\mathbf{x}_j|\boldsymbol{\mu}_a, \boldsymbol{\Sigma}_a) \cdot P(C_a)}$ // posterior probability $P^t(C_i|\mathbf{x}_j)$

  // Maximization Step

  **for** $i = 1, \ldots, k$ **do**

    $\boldsymbol{\mu}_i^t \leftarrow \frac{\sum_{j=1}^{n} w_{ij} \cdot \mathbf{x}_j}{\sum_{j=1}^{n} w_{ij}}$ // re-estimate mean

    $\boldsymbol{\Sigma}_i^t \leftarrow \frac{\sum_{j=1}^{n} w_{ij} (\mathbf{x}_j - \boldsymbol{\mu}_i)(\mathbf{x}_j - \boldsymbol{\mu}_i)^T}{\sum_{j=1}^{n} w_{ij}}$ // re-estimate covariance matrix

    $P^t(C_i) \leftarrow \frac{\sum_{j=1}^{n} w_{ij}}{n}$ // re-estimate priors

**until** $\sum_{i=1}^{k} \left\| \boldsymbol{\mu}_i^t - \boldsymbol{\mu}_i^{t-1} \right\| \leq \epsilon$

# Ví dụ thuật toán EM trong không gian 2 chiều: Iris 2-d [4]

- Minh họa thuật toán EM trên tập dữ liệu Iris hai chiều, dựa trên 2 thành phần chính đầu tiên.
- Tập dữ liệu gồm $n = 150$ điểm, EM chạy với $k = 3$ và ma trận hiệp phương sai đầy đủ cho mỗi cụm.
- Tham số khởi tạo:
  - $\mu_1 = (-3.59, 0.25)^T, \mu_2 = (-1.09, -0.46)^T, \mu_3 = (0.75, 1.07)^T$
  - Ma trận hiệp phương sai ban đầu ($i = 1..3$): $\Sigma_i = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$
  - Xác suất tiên nghiệm ban đầu: $P(C_i) = 1/3$ cho $i = 1..3$.

# Ví dụ thuật toán EM trong không gian 2 chiều: Iris 2-d [4] (tiếp)

- Thuật toán EM mất 36 vòng lặp để hội tụ (sử dụng $\epsilon = 0.001$).
- Cuối cùng tại vòng lặp $t = 36$, ba cụm đã được xác định chính xác, với các tham số sau:

$$\boldsymbol{\mu}_1 = (-2.02, 0.017)^T \quad \boldsymbol{\mu}_2 = (-0.51, -0.23)^T \quad \boldsymbol{\mu}_3 = (2.64, 0.19)^T$$

$$\boldsymbol{\Sigma}_1 = \begin{pmatrix} 0.56 & -0.29 \\ -0.29 & 0.23 \end{pmatrix} \quad \boldsymbol{\Sigma}_2 = \begin{pmatrix} 0.36 & -0.22 \\ -0.22 & 0.19 \end{pmatrix} \quad \boldsymbol{\Sigma}_3 = \begin{pmatrix} 0.05 & -0.06 \\ -0.06 & 0.21 \end{pmatrix}$$

$$P(C_1) = 0.36 \quad P(C_2) = 0.31 \quad P(C_3) = 0.33$$

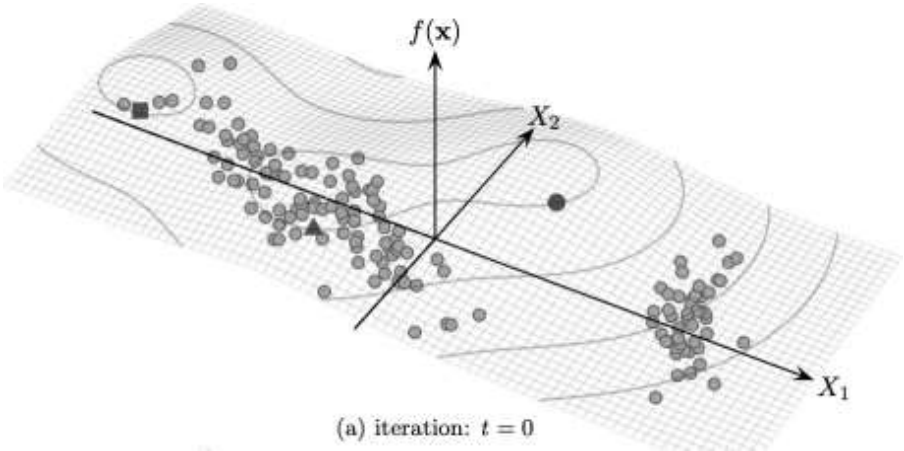
- Để xem tác động của ma trận hiệp phương sai đầy đủ so với ma trận đường chéo, thuật toán EM trên tập dữ liệu các thành phần chính của Iris dưới **giả định độc lập** đã được chạy, mất $t = 29$ vòng lặp để hội tụ. Các tham số cụm cuối cùng là:

$$\boldsymbol{\mu}_1 = (-2.1, 0.28)^T \quad \boldsymbol{\mu}_2 = (-0.67, -0.40)^T \quad \boldsymbol{\mu}_3 = (2.64, 0.19)^T$$

$$\boldsymbol{\Sigma}_1 = \begin{pmatrix} 0.50 & 0 \\ 0 & 0.11 \end{pmatrix} \quad \boldsymbol{\Sigma}_2 = \begin{pmatrix} 0.49 & 0 \\ 0 & 0.11 \end{pmatrix} \quad \boldsymbol{\Sigma}_3 = \begin{pmatrix} 0.05 & 0 \\ 0 & 0.21 \end{pmatrix}$$

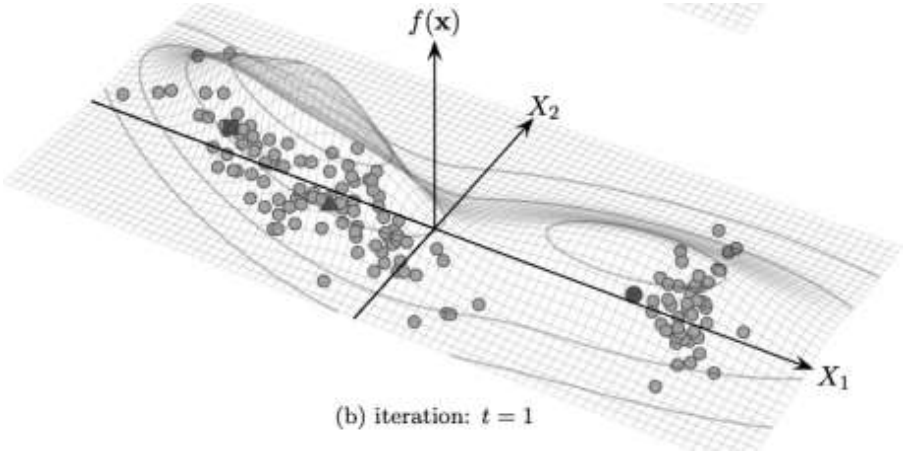
$$P(C_1) = 0.30 \quad P(C_2) = 0.37 \quad P(C_3) = 0.33$$

# Ví dụ thuật toán EM trong không gian 2 chiều: Iris 2-d (tiếp)




- (a) Vòng lặp: $t = 0$

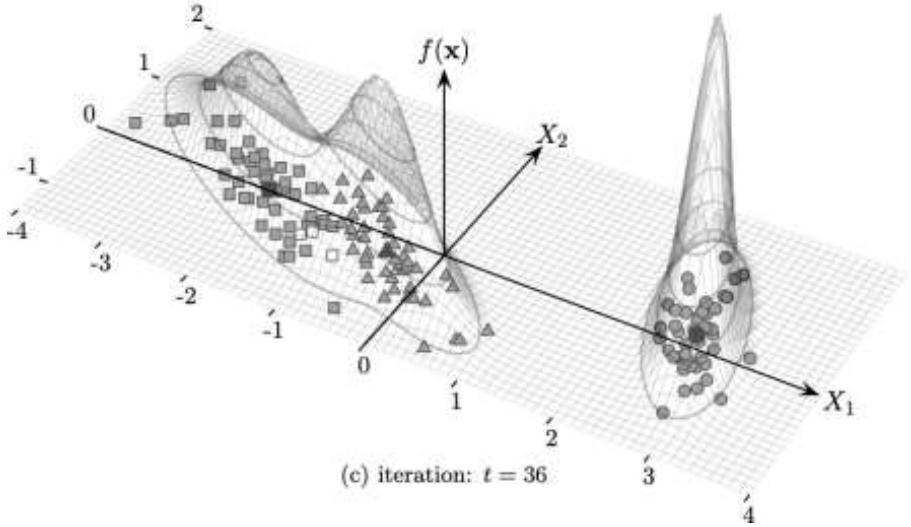
# Ví dụ thuật toán EM trong không gian 2 chiều: Iris 2-d (tiếp)




(b) iteration: $t = 1$

- (b) Vòng lặp: $t = 1$

# Ví dụ thuật toán EM trong không gian 2 chiều: Iris 2-d (tiếp)




- (c) Vòng lặp: $t = 36$ (Hội tụ)

# Thuật toán EM: Độ phức tạp tính toán

- Trong bước kỳ vọng, để tính các xác suất hậu nghiệm của cụm, chúng ta cần nghịch đảo $\mathbf{\Sigma}_i$ và tính định thức $|\mathbf{\Sigma}_i|$ của nó, quá trình này mất thời gian $O(d^3)$. Qua $k$ cụm, thời gian là $O(kd^3)$.
- Trong bước kỳ vọng, việc tính toán mật độ $f(\mathrm{x}_j|\boldsymbol{\mu}_i, \mathbf{\Sigma}_i)$ mất thời gian $O(d^2)$, với tổng thời gian là $O(knd^2)$ trên $n$ điểm và $k$ cụm.
- Trong bước cực đại hóa, thời gian bị chi phối bởi thao tác cập nhật cho $\mathbf{\Sigma}_i$, mất thời gian $O(knd^2)$ qua tất cả $k$ cụm.
- Độ phức tạp tính toán của phương pháp EM do đó là $O(t(kd^3 + nkd^2))$, trong đó $t$ là số vòng lặp.
- Nếu chúng ta sử dụng ma trận hiệp phương sai đường chéo, thì nghịch đảo và định thức của $\mathbf{\Sigma}_i$ có thể được tính trong thời gian $O(d)$. Việc tính toán mật độ cho mỗi điểm mất thời gian $O(d)$, do đó thời gian cho bước kỳ vọng là $O(knd)$. Bước cực đại hóa vẫn mất thời gian $O(knd^2)$ để ước lượng lại $\mathbf{\Sigma}_i$. Tổng thời gian khi dùng ma trận hiệp phương sai đường chéo do đó là $O(tnkd^2)$.
- Độ phức tạp I/O cho thuật toán EM là $O(t)$ lần quét toàn bộ cơ sở dữ liệu, vì chúng ta đọc toàn bộ tập hợp các điểm trong mỗi vòng lặp.

# K-means như một trường hợp đặc biệt của thuật toán EM

- Mặc dù chúng ta đã giả định một mô hình hỗn hợp chuẩn (normal mixture model) cho các cụm, phương pháp EM có thể được áp dụng với các mô hình khác cho phân phối mật độ cụm $P(x_j|C_i)$.
- Ví dụ, k-means có thể được coi là một trường hợp đặc biệt của thuật toán EM, thu được như sau:

$$P(x_j|C_i) = \begin{cases} 1 & \text{nếu } C_i = \arg\min_{C_r} ||x_j - \mu_r||^2 \\ 0 & \text{trái lại} \end{cases} \tag{48}$$

- Sử dụng công thức Bayes:

$$P(C_i|x_j) = \frac{P(x_j|C_i)P(C_i)}{\sum_{r=1}^{k} P(x_j|C_r)P(C_r)} \tag{49}$$

# K-means như một trường hợp đặc biệt của thuật toán EM (tiếp)

- Ta có thể thấy rằng nếu $P(x_j|C_i) = 0$ thì $P(C_i|x_j) = 0$. Trái lại, nếu $P(x_j|C_i) = 1$, thì $P(x_j|C_r) = 0$ cho tất cả $r \neq i$, và do đó $P(C_i|x_j) = \frac{1 \cdot P(C_i)}{1 \cdot P(C_i)} = 1$. Kết hợp lại, xác suất hậu nghiệm được cho bởi:

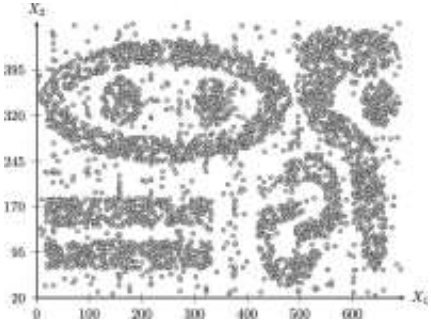
$$P(C_i|x_j) = \begin{cases} 1 & \text{nếu } x_j \in C_i, \\ 0 & \text{trái lại} \end{cases} \quad \text{tức là, nếu } C_i = \arg\min_{C_r} ||x_j - \mu_r||^2 \qquad (50)$$

- Rõ ràng đối với k-means, các tham số cụm là $\mu_i$ và $P(C_i)$. Ma trận hiệp phương sai bị bỏ qua.

# Nội dung


1. Khái niệm phân cụm dữ liệu
2. Hiểu dữ liệu trước khi phân cụm
3. Phân cụm phân cấp (Hierarchical clustering)
4. Phân cụm phân vùng (Partitioning clustering)
5. Phân cụm theo phân phối (Distribution-based)
6. **Phân cụm theo mật độ (Density-based)**
7. Kiểm định và đánh giá kết quả phân cụm
8. Tài liệu tham khảo và Kết luận

# Các phương pháp phân cụm dựa trên mật độ




Dữ liệu với cấu trúc cụm tùy ý [4]

- Các phương pháp phân cụm dựa trên mật độ có thể xác định các cụm có hình dạng tùy ý miễn là các điểm dữ liệu của cùng một cụm đủ gần nhau.
- Các thuật toán dựa trên mật độ nổi tiếng nhất: DBSCAN (Density-Based Clustering Based on Connected Regions with High Density), OPTICS, và DENCLUE.

# Xem lại bài toán phân cụm dữ liệu



- Giả sử $X = (X_1, X_2, \ldots, X_d)$ là một không gian $d$ chiều, trong đó mỗi thuộc tính/biến $X_j$ là dạng số hoặc dạng phân loại.
- Giả sử $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ là một mẫu dữ liệu hoặc tập dữ liệu gồm $n$ điểm dữ liệu $x_i = (x_1, x_2, \ldots, x_d) \in X$.
- Phân cụm dữ liệu là việc sử dụng một kỹ thuật hoặc thuật toán phân cụm $\mathcal{A}$ để gán các điểm dữ liệu trong $\mathcal{D}$ vào các cụm có khả năng nhất của chúng. Kết quả là một tập hợp gồm $k$ cụm $C = \{C_1, C_2, \ldots, C_k\}$. Các điểm dữ liệu trong cùng một cụm thì tương đồng với nhau và khác biệt với các điểm dữ liệu trong các cụm khác.

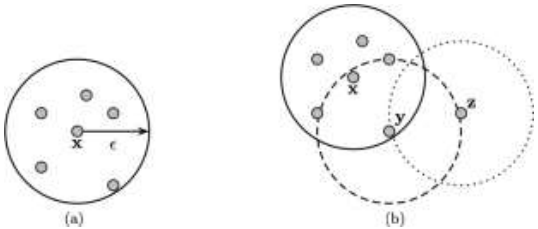
# Các khái niệm DBSCAN: điểm lõi, điểm biên, và điểm nhiễu

- Phân cụm dựa trên mật độ sử dụng mật độ cục bộ của các điểm để xác định các cụm, thay vì chỉ sử dụng khoảng cách giữa các điểm.
- Định nghĩa một hình cầu bán kính $\epsilon$ xung quanh một điểm $x$, gọi là lân cận $\epsilon$ của $x$ ($\epsilon$-neighborhood), như sau:

$$N_\epsilon(x) = B_\delta(x, \epsilon) = \{y | y \in \mathcal{D} \text{ và } \delta(x, y) \leq \epsilon\} \tag{51}$$

  Ở đây $\delta(x, y)$ là khoảng cách giữa hai điểm $x$ và $y$, thường được giả định là khoảng cách Euclidean, tức là $\delta(x, y) = ||x - y||_2$.
- Đối với bất kỳ điểm $x \in \mathcal{D}$, ta nói $x$ là một **điểm lõi** (core point) nếu có ít nhất *minpts* điểm trong lân cận $\epsilon$ của nó. Nói cách khác, $x$ là điểm lõi nếu $|N_\epsilon(x)| \geq$ minpts, trong đó *minpts* là ngưỡng mật độ (hoặc tần suất) cục bộ do người dùng xác định.
- Một **điểm biên** (border point) $y$ được định nghĩa là một điểm không đáp ứng ngưỡng *minpts*, tức là $|N_\epsilon(y)| <$ minpts, nhưng nó thuộc về lân cận của một điểm lõi $x$.
- Cuối cùng, nếu một điểm không phải là điểm lõi cũng không phải là điểm biên, thì nó được gọi là **điểm nhiễu** (noise point) hoặc **ngoại lệ** (outlier).

# Ví dụ về điểm lõi, điểm biên, và điểm nhiễu




Ví dụ về điểm lõi, điểm biên, và điểm nhiễu [4]

- Cho $\epsilon$ và minpts $= 5$.
- $x$ là một điểm lõi vì $|N_\epsilon(x)| \geq 5$.
- $y$ là một điểm biên vì $|N_\epsilon(y)| = 3 < 5$ và $y \in N_\epsilon(x)$.
- $z$ là một điểm nhiễu vì nó không phải là điểm lõi và không thuộc lân cận của bất kỳ điểm lõi nào.

# Mật độ đến được, liên thông mật độ, và các cụm trong DBSCAN

- Một điểm $y$ **trực tiếp đến được theo mật độ** (directly density reachable) từ một điểm $x$ nếu $y \in N_\epsilon(x)$ và $x$ là một điểm lõi.
- Một điểm $y$ **đến được theo mật độ** (density reachable) từ một điểm $x$ nếu tồn tại một chuỗi các điểm, $y_0, y_1, \ldots, y_l$, sao cho $y = y_l$ và $x = y_0$, và $y_i$ trực tiếp đến được theo mật độ từ $y_{i-1}$ với mọi $1 \leq i \leq l$. Lưu ý rằng tính đến được theo mật độ là một quan hệ bất đối xứng hoặc có hướng.
- Hai điểm $x$ và $y$ được định nghĩa là **liên thông theo mật độ** (density connected) nếu tồn tại một điểm lõi $z$, sao cho cả $x$ và $y$ đều có thể đến được theo mật độ từ $z$.
- Một cụm dựa trên mật độ được định nghĩa là một tập hợp tối đa các điểm liên thông theo mật độ. Tập $C \subseteq \mathcal{D}$ là một cụm trong DBSCAN nếu:
  - Đối với bất kỳ hai điểm $x, y \in C$, $x$ và $y$ liên thông theo mật độ, và
  - Không có $x \in C$ và $y \notin C$ sao cho $x$ và $y$ liên thông theo mật độ.

# Thuật toán DBSCAN: mã giả [4]

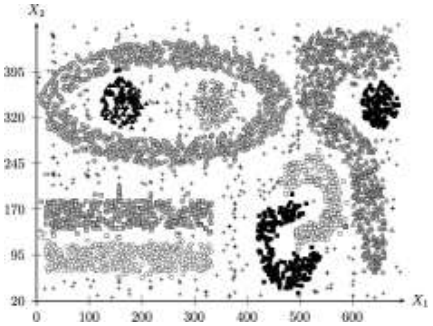
**DBSCAN** (**D**, $\epsilon$, *minpts*):

```
1  Core ← ∅
2  foreach x_i ∈ D do // Find the core points
3      Compute N_ε(x_i)
4      id(x_i) ← ∅ // cluster id for x_i
5      if N_ε(x_i) ≥ minpts then Cores ← Cores ∪ {x_i}
6  k ← 0 // cluster id
7  foreach x_i ∈ Core, such that id(x_i) = ∅ do
8      k ← k + 1
9      id(x_i) ← k // assign x_i to cluster id k
10     DensityConnected (x_i, k)
11 C ← {C_i}_{i=1}^k, where C_i ← {x ∈ D | id(x) = i}
12 Noise ← {x ∈ D | id(x) = ∅}
13 Border ← D \ {Core ∪ Noise}
14 return C, Core, Border, Noise
```

**DensityConnected** (**x**, $k$):

```
15 foreach y ∈ N_ε(x) do
16     id(y) ← k // assign y to cluster id k
17     if y ∈ Core then DensityConnected (y, k)
```

# Ví dụ về kết quả phân cụm DBSCAN [4]




- Các cụm được phát hiện bởi DBSCAN với $\epsilon = 15$ và minpts $= 10$.
- Với việc tinh chỉnh tham số phù hợp, DBSCAN mang lại kết quả phân cụm gần như hoàn hảo bao gồm tất cả chín cụm.
- Các cụm được hiển thị bằng các ký hiệu/sắc thái khác nhau. Điểm nhiễu được hiển thị dưới dạng dấu cộng (+).

# Hạn chế của DBSCAN

- Một hạn chế của DBSCAN là nó nhạy cảm với việc chọn $\epsilon$, cụ thể là nếu các cụm có mật độ khác nhau.
- Nếu $\epsilon$ quá nhỏ, các cụm thưa thớt hơn sẽ bị phân loại là nhiễu.
- Nếu $\epsilon$ quá lớn, các cụm dày đặc hơn có thể bị gộp lại với nhau.
- Nếu có các cụm với mật độ cục bộ khác nhau, thì một giá trị $\epsilon$ duy nhất có thể không đủ.

# Độ phức tạp tính toán của DBSCAN

- Chi phí chính trong DBSCAN là tính toán lân cận $\epsilon$ cho mỗi điểm.
- Nếu số chiều không quá cao, điều này có thể được thực hiện hiệu quả bằng cách sử dụng cấu trúc chỉ mục không gian (spatial index structure) trong thời gian $O(n \log n)$.
- Khi số chiều cao, mất $O(n^2)$ để tính toán lân cận cho mỗi điểm.
- Khi $N_\epsilon(x)$ đã được tính, thuật toán chỉ cần quét qua tất cả các điểm một lần để tìm các cụm liên thông theo mật độ.
- Do đó, độ phức tạp tổng thể của DBSCAN là $O(n^2)$ trong trường hợp xấu nhất.

# Nội dung


1. Khái niệm phân cụm dữ liệu
2. Hiểu dữ liệu trước khi phân cụm
3. Phân cụm phân cấp (Hierarchical clustering)
4. Phân cụm phân vùng (Partitioning clustering)
5. Phân cụm theo phân phối (Distribution-based)
6. Phân cụm theo mật độ (Density-based)
7. **Kiểm định và đánh giá kết quả phân cụm**
8. Tài liệu tham khảo và Kết luận

# Kiểm định và đánh giá phân cụm

- Kiểm định xu hướng phân cụm (Validating cluster tendency)
- Hiểu mật độ dữ liệu (Understanding data density)
- Ước lượng đúng số lượng cụm: $k$
  - Phương pháp khuỷu tay (Elbow method)
  - Kiểm chứng chéo (Cross-validation)
  - Hệ số Silhouette (Silhouette coefficient)
- Đánh giá kết quả phân cụm (tiêu chí/phương pháp nội bộ)
  - Tổng bình phương khoảng cách đến tâm cụm
  - Tỷ lệ khoảng cách nội cụm so với liên cụm
  - Độ đo xác suất (Probabilistic measure)
  - Hệ số Silhouette

# Kiểm định xu hướng phân cụm

- Đã được mô tả trong phần thứ hai (Hiểu dữ liệu trước khi phân cụm)
- Các kỹ thuật:
  - Biểu đồ không gian (Spatial histogram / cell-based histogram)
  - Entropy dựa trên ô (Cell-based entropy)
  - Phân phối khoảng cách (Distance distribution)
  - Thống kê Hopkins (Hopkins statistic)

# Hiểu mật độ dữ liệu

- Ngoài xu hướng phân cụm, mật độ cụm cũng rất quan trọng. Làm thế nào chúng ta có thể thiết lập một giá trị phù hợp cho bán kính $\epsilon$ trong thuật toán DBSCAN?
- Đối với mỗi điểm dữ liệu $x_i \in \mathcal{D}$, tính khoảng cách đến điểm gần nhất của nó trong $\mathcal{D}$:

$$r_i = \arg \min_{x_j \in \mathcal{D}, j \neq i} d(x_i, x_j) \tag{52}$$

- Tính trung bình, trung vị và độ lệch chuẩn của tập $\{r_i\}_{i=1}^n$.
- Vẽ biểu đồ histogram và biểu đồ hộp (boxplot) của $\{r_i\}_{i=1}^n$.
- Dựa trên thống kê mô tả và trực quan hóa để ước lượng phạm vi của bán kính $\epsilon$ trong các thuật toán phân cụm dựa trên mật độ như DBSCAN.

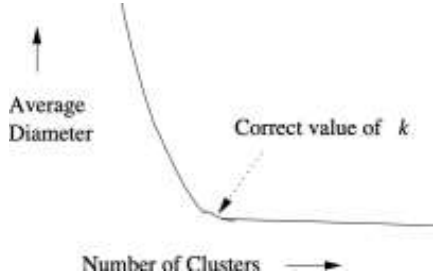
# Ước lượng đúng số lượng cụm

- Việc xác định "đúng" số lượng cụm trong một tập dữ liệu là rất quan trọng, không chỉ vì một số thuật toán phân cụm như k-means yêu cầu **tham số** đó, mà còn vì số lượng cụm phù hợp kiểm soát độ **chi tiết hợp lý** của phân tích cụm.
- Nó có thể được coi là việc tìm kiếm sự cân bằng tốt giữa **tính nén** (compressibility) và **độ chính xác** (accuracy) trong phân tích cụm.
- Xem xét hai trường hợp cực đoan:
  - Điều gì xảy ra nếu bạn coi toàn bộ tập dữ liệu như một cụm duy nhất? Điều này sẽ tối đa hóa khả năng nén dữ liệu, nhưng phân tích cụm như vậy không có giá trị.
  - Coi mỗi đối tượng trong tập dữ liệu là một cụm sẽ mang lại độ phân giải phân cụm tốt nhất nhưng **không cho phép bất kỳ sự tóm tắt dữ liệu nào**.
- Việc xác định số lượng cụm không hề dễ dàng, thường là do "đúng" số lượng là rất mơ hồ.
- Số lượng cụm đúng thường phụ thuộc vào **hình dạng** và **thang đo** phân phối trong tập dữ liệu, cũng như **độ phân giải phân cụm** mà người dùng yêu cầu.

# Ước lượng đúng số lượng cụm: phương pháp khuỷu tay

- Phương pháp **khuỷu tay** (the elbow method) dựa trên quan sát rằng việc tăng số lượng cụm có thể giúp giảm tổng phương sai nội cụm của mỗi cụm.
- Điều này là do việc có **nhiều cụm hơn** cho phép nắm bắt **các nhóm đối tượng dữ liệu nhỏ hơn** và tương đồng với nhau hơn.
- Tuy nhiên, hiệu ứng biên của việc giảm tổng phương sai nội cụm có thể giảm xuống nếu có **quá nhiều cụm** được hình thành, vì việc chia một cụm gắn kết thành hai chỉ mang lại sự sụt giảm nhỏ.
- Do đó, **một kinh nghiệm** (heuristic) để chọn số lượng cụm đúng là sử dụng **điểm rẽ** (turning point) trên **đường cong** của tổng phương sai nội cụm theo **số lượng cụm**.

# Ước lượng đúng số lượng cụm: phương pháp khuỷu tay (tiếp)




- Đường kính trung bình của các cụm giảm nhanh chóng nếu $k$ giảm (khi $k$ vẫn nhỏ hơn số lượng cụm thực tế), và giảm nhẹ khi $k$ giảm (khi $k$ lớn hơn số lượng "đúng" của các cụm).
- Vùng "khuỷu tay" (elbow region) có thể chứa giá trị $k$ thực tế.
- Phương sai nội cụm có thể dựa trên trung bình của tổng bình phương khoảng cách đến tâm cụm, hoặc bất kỳ thống kê nào có thể đo lường tính gắn kết của các cụm.

# Ước lượng đúng số lượng cụm: kiểm chứng chéo

- Số lượng "đúng" của các cụm trong một tập dữ liệu cũng có thể được xác định bằng **phương pháp kiểm chứng chéo** (cross-validation), một kỹ thuật thường dùng trong phân loại.
- Đầu tiên, chia tập dữ liệu đã cho, $\mathcal{D}$, thành $m$ phần. Tiếp theo, sử dụng $m-1$ phần để xây dựng một mô hình phân cụm, và sử dụng phần còn lại để kiểm tra chất lượng của phân cụm.
- Ví dụ, đối với mỗi điểm trong tập kiểm tra, ta có thể tìm **tâm cụm gần nhất**. Do đó, ta có thể sử dụng **tổng bình phương khoảng cách** giữa tất cả các điểm trong tập kiểm tra và tâm cụm gần nhất để đo lường mức độ phù hợp của mô hình phân cụm với tập kiểm tra.
- Đối với bất kỳ số nguyên $k > 0$, ta lặp lại quá trình này $m$ lần để đưa ra kết quả phân thành $k$ cụm bằng cách lần lượt sử dụng từng phần làm tập kiểm tra. **Trung bình của độ đo chất lượng được coi là độ đo** chất lượng tổng thể.
- Sau đó, ta có thể so sánh độ đo chất lượng tổng thể đối với các giá trị khác nhau của $k$, và tìm ra **số lượng cụm phù hợp nhất với dữ liệu**.

# Ước lượng đúng số lượng cụm: hệ số Silhouette

- Xem cách tính toán **hệ số Silhouette** (silhouette coefficient) ở các slide tiếp theo.
- Hệ số Silhouette cũng được sử dụng để đánh giá chất lượng phân cụm.

# Các tiêu chí nội bộ để đánh giá kết quả phân cụm

- **Các tiêu chí kiểm định nội bộ** (Internal validation criteria) được sử dụng khi không có sẵn các tiêu chí bên ngoài để đánh giá chất lượng phân cụm (trong hầu hết các trường hợp).
- Trong hầu hết các trường hợp, **các tiêu chí** được sử dụng để kiểm định chất lượng của thuật toán được vay mượn trực tiếp từ **hàm mục tiêu**, hàm được tối ưu hóa bởi một mô hình phân cụm cụ thể.
- Ví dụ, **gần như bất kỳ hàm mục tiêu** nào trong k-representatives, thuật toán EM, và các phương pháp agglomerative đều có thể được sử dụng cho mục đích kiểm định.
- Một tiêu chí kiểm định sẽ luôn **thiên vị** một thuật toán phân cụm sử dụng loại hàm mục tiêu **tương tự** cho quá trình tối ưu hóa của nó.
- Tuy nhiên, trong trường hợp **không có tiêu chí kiểm định bên ngoài** (thường xảy ra), đây là điều tốt nhất mà chúng ta có thể kỳ vọng đạt được.

# Đánh giá kết quả phân cụm: tổng bình phương khoảng cách đến tâm cụm

- Trong trường hợp này, các tâm của các cụm khác nhau được xác định, và **tổng bình phương khoảng cách** (SSQ - Sum of Squared distances) được báo cáo làm hàm mục tiêu tương ứng.
- Giá trị nhỏ hơn của thước đo này chỉ ra chất lượng cụm tốt hơn.
- Thước đo này rõ ràng được tối ưu hơn cho **các thuật toán dựa trên khoảng cách**, như k-means, so với phương pháp dựa trên mật độ, như DBSCAN.
- Một vấn đề khác với SSQ là khoảng cách tuyệt đối không cung cấp thông tin có ý nghĩa cho người dùng về chất lượng thực sự của các cụm bên dưới.

# Đánh giá kết quả phân cụm: tỷ lệ nội cụm so với liên cụm

- Thước đo này chi tiết hơn thước đo SSQ. Ý tưởng là lấy mẫu r cặp các cặp điểm dữ liệu từ dữ liệu gốc.
- Gọi $P$ là tập hợp các cặp thuộc cùng một cụm do thuật toán tìm ra. Các cặp còn lại được ký hiệu là tập $Q$. Khoảng cách trung bình nội cụm (intra-cluster) và liên cụm (inter-cluster) được định nghĩa như sau:

$$Intra = \frac{1}{|P|} \sum_{(x_i, x_j) \in P} d(x_i, x_j) \tag{53}$$

$$Inter = \frac{1}{|Q|} \sum_{(x_i, x_j) \in Q} d(x_i, x_j) \tag{54}$$

- Sau đó tỷ lệ giữa khoảng cách nội cụm trung bình và khoảng cách liên cụm được tính bằng $Intra/Inter$.
- Giá trị nhỏ của thước đo này cho thấy kết quả phân cụm tốt hơn.

# Đánh giá kết quả phân cụm: độ đo xác suất

- Trong trường hợp này, mục tiêu là sử dụng một **mô hình hỗn hợp** (mixture model) để ước tính chất lượng của một kết quả phân cụm cụ thể.
- **Tâm** của mỗi **thành phần hỗn hợp** được giả định là tâm của mỗi cụm được phát hiện, và các tham số khác của mỗi thành phần (như ma trận hiệp phương sai) được tính toán từ phân cụm được phát hiện bằng cách sử dụng một phương pháp tương tự như bước M của thuật toán EM.
- Tổng log-likelihood của thước đo được báo cáo lại.
- Thước đo này rất hữu ích khi biết được từ kiến thức chuyên ngành rằng các cụm phải có một hình dạng cụ thể, như được gợi ý bởi sự phân phối của từng thành phần trong hỗn hợp.

# Đánh giá kết quả phân cụm: Hệ số Silhouette

- Giả sử tập dữ liệu $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ được phân hoạch thành $k$ cụm $\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$ bởi một thuật toán phân cụm.
- Đối với mỗi $x \in C_i \subseteq \mathcal{D}$ $(i = 1..k)$, tính $a(x)$ và $b(x)$ như sau:
- $a(x)$: khoảng cách trung bình giữa $x$ và tất cả các điểm dữ liệu trong cùng một cụm $C_i$:

$$a(x) = \frac{\sum_{y \in C_i} d(x, y)}{|C_i| - 1} \tag{55}$$

- $b(x)$: khoảng cách trung bình nhỏ nhất giữa $x$ và các điểm dữ liệu thuộc các cụm khác $C_j$ $(j = 1..k$ và $j \neq i)$:

$$b(x) = \min_{C_j, j=1..k, j \neq i} \frac{\sum_{y \in C_j} d(x, y)}{|C_j|} \tag{56}$$

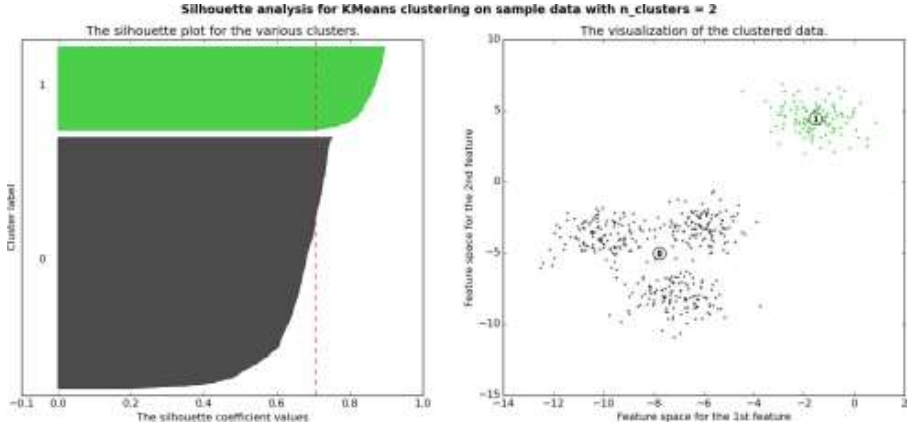
# Đánh giá kết quả phân cụm: Hệ số Silhouette (tiếp)

- Hệ số Silhouette của $x$ là:

$$s(x) = \frac{b(x) - a(x)}{\max\{a(x), b(x)\}} \tag{57}$$

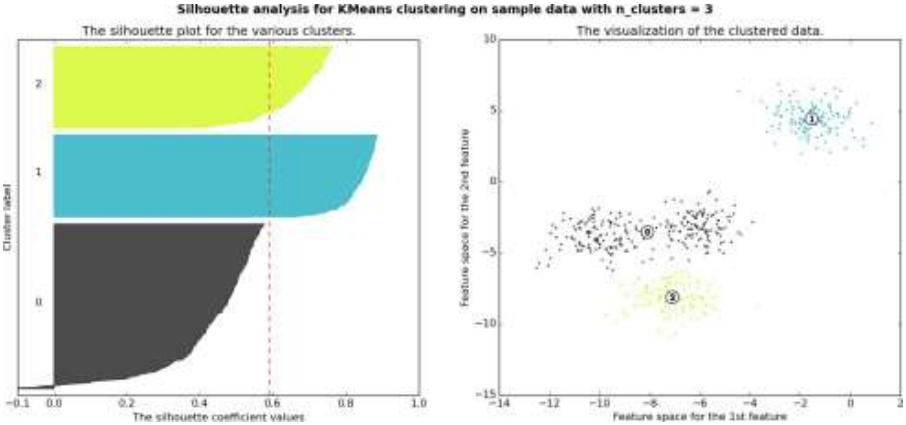
- Giá trị của $s(x)$ thay đổi từ -1.0 đến 1.0
  - Giá trị $a(x)$ nhỏ chỉ ra rằng cụm $C_i$ (chứa $x$) có tính gắn kết cao.
  - Giá trị $b(x)$ lớn chỉ ra rằng $x$ ở xa các cụm khác.
  - $s(x)$ gần 1.0 có nghĩa là cụm $C_i$ (chứa $x$) rất gắn kết và $x$ ở xa các cụm khác.
  - $s(x) < 0$ có nghĩa là $x$ gần với các điểm dữ liệu trong cụm khác hơn là các điểm trong cụm của chính nó (tức là $C_i$).
- Để đo lường chất lượng của giải pháp phân cụm $\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$, chúng ta cần tính hệ số Silhouette **trung bình** trên tất cả các điểm dữ liệu trong $\mathcal{D}$.
- Hệ số Silhouette có thể được dùng để đo lường chất lượng phân cụm cũng như ước lượng số lượng cụm $k$ thực sự trong $\mathcal{D}$.

# Đánh giá kết quả phân cụm: ví dụ hệ số Silhouette



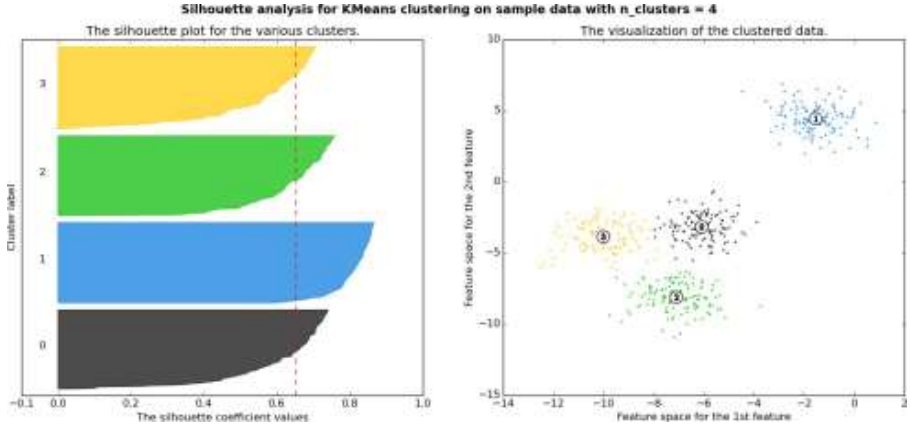

Phân tích Silhouette cho phân cụm KMeans với n_clusters = 2 [Nguồn: scikit-learn.org]

# Đánh giá kết quả phân cụm: ví dụ hệ số Silhouette (tiếp)



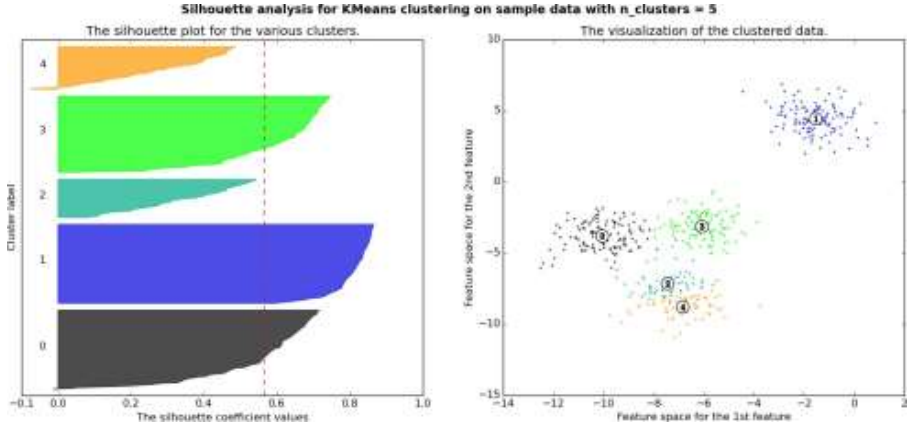

Phân tích Silhouette cho phân cụm KMeans với n_clusters = 3 [Nguồn: scikit-learn.org]

# Đánh giá kết quả phân cụm: ví dụ hệ số Silhouette (tiếp)



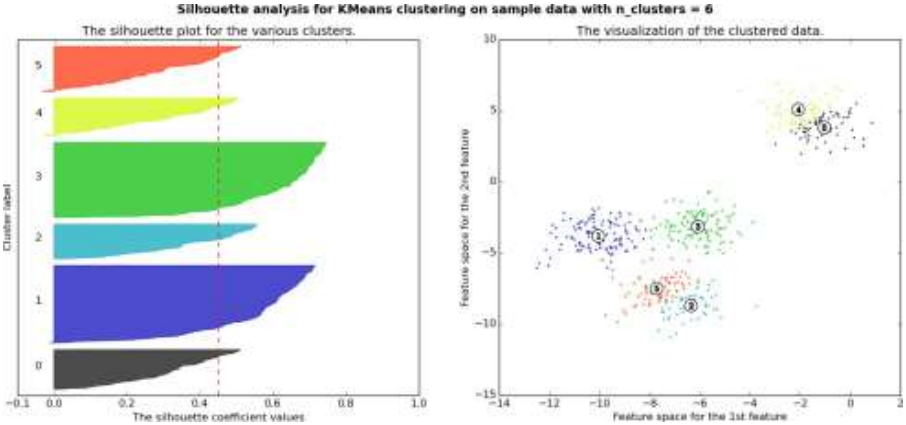

Phân tích Silhouette cho phân cụm KMeans với n_clusters = 4 [Nguồn: scikit-learn.org]

# Đánh giá kết quả phân cụm: ví dụ hệ số Silhouette (tiếp)




Phân tích Silhouette cho phân cụm KMeans với n_clusters = 5 [Nguồn: scikit-learn.org]

# Đánh giá kết quả phân cụm: ví dụ hệ số Silhouette (tiếp)




Phân tích Silhouette cho phân cụm KMeans với n_clusters = 6 [Nguồn: scikit-learn.org]

# Nội dung


1. Khái niệm phân cụm dữ liệu
2. Hiểu dữ liệu trước khi phân cụm
3. Phân cụm phân cấp (Hierarchical clustering)
4. Phân cụm phân vùng (Partitioning clustering)
5. Phân cụm theo phân phối (Distribution-based)
6. Phân cụm theo mật độ (Density-based)
7. Kiểm định và đánh giá kết quả phân cụm
8. **Tài liệu tham khảo và Kết luận**

# Tài liệu tham khảo


1 J. Han, M. Kamber, and J. Pei. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, Elsevier, 2012 [Book1].

2 C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015 [Book2].

3 J. Leskovec, A. Rajaraman, and J. D. Ullman. *Mining of Massive Datasets*. Cambridge University Press, 2014 [Book3].

4 M. J. Zaki and W. M. Jr. *Data Mining and Analysis: Fundamental Concepts and Algorithms*. Cambridge University Press, 2013 [Book4].

5 D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010 [Book5].

6 J. VanderPlas. *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly, 2017 [Book6].

7 J. Grus. *Data Science from Scratch: First Principles with Python*. O'Reilly, 2015 [Book7].

# Tổng kết

- Giới thiệu các khái niệm quan trọng của phân cụm: định nghĩa, loại phân cụm (cứng vs. mềm), yêu cầu chính, các cách tiếp cận phân cụm, thách thức và ứng dụng phân cụm.
- Các kỹ thuật chính để hiểu phân phối dữ liệu trước khi phân cụm: biểu đồ không gian, entropy dựa trên ô, phân phối khoảng cách, và thống kê Hopkins.
- Phương pháp phân cụm phân cấp với kỹ thuật agglomerative (từ dưới lên), dendrogram, các cách khác nhau để gộp cụm (single link, complete link, average link, centroid link, radius, và diameter).
- Phương pháp phân hoạch với thuật toán k-means, khởi tạo $k$ tâm, và các biến thể của k-means bao gồm k-medoids (thuật toán PAM) và k-medians.
- Phân cụm dựa trên phân phối hoặc xác suất với mô hình hỗn hợp Gauss (GMMs) và thuật toán EM; mối liên hệ giữa k-means và GMMs/EM.
- Phương pháp phân cụm dựa trên mật độ với thuật toán DBSCAN.
- Đánh giá phân cụm: xu hướng phân cụm, mật độ dữ liệu, ước lượng số lượng cụm "đúng" ($k$), và các tiêu chí khác nhau để đánh giá kết quả phân cụm.