Tiền xử lý và Chuẩn bị dữ liệu

Trần Hồng Việt

Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội

Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

Mục lục

1. **Giới thiệu**
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

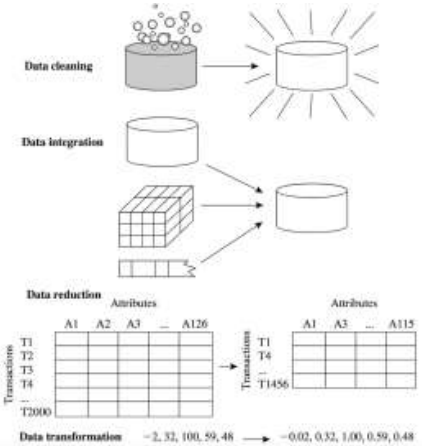
Tại sao cần tiền xử lý dữ liệu?

- Các cơ sở dữ liệu thực tế rất dễ chứa dữ liệu nhiễu, thiếu và không nhất quán do kích thước thường rất lớn (thường từ vài gigabyte trở lên) và có thể xuất phát từ nhiều nguồn khác nhau.
- Dữ liệu gốc thường ở dạng thô, chưa sẵn sàng cho việc phân tích và xây dựng mô hình khai phá.
- Dữ liệu kém chất lượng sẽ dẫn đến kết quả khai phá kém chất lượng.
- Dữ liệu có chất lượng khi đáp ứng được yêu cầu của mục đích sử dụng. Có nhiều yếu tố cấu thành chất lượng dữ liệu, bao gồm *độ chính xác*, *tính đầy đủ*, *tính nhất quán*, *tính kịp thời*, *độ tin cậy* và *khả năng diễn giải*.
- Làm thế nào để tiền xử lý dữ liệu nhằm nâng cao chất lượng dữ liệu và từ đó nâng cao kết quả khai phá? Làm thế nào để tiền xử lý dữ liệu nhằm cải thiện hiệu quả và sự thuận tiện của quá trình khai phá?

Các tác vụ chính trong tiền xử lý dữ liệu

- **Làm sạch dữ liệu (Data cleaning):**
  - "làm sạch" dữ liệu bằng cách điền vào các giá trị bị thiếu, làm mịn dữ liệu nhiễu, xác định hoặc loại bỏ các giá trị ngoại lệ, và giải quyết các mâu thuẫn.
- **Tích hợp dữ liệu (Data integration):**
  - hợp nhất dữ liệu từ nhiều nguồn khác nhau, ví dụ: cơ sở dữ liệu, khối dữ liệu hoặc tệp tin, vào một kho dữ liệu thống nhất như data warehouse.
- **Giảm chiều dữ liệu (Data reduction):**
  - giảm dữ liệu theo nhiều cách khác nhau, ví dụ: giảm số chiều, loại bỏ các biến/thuộc tính không liên quan, giảm dữ liệu bằng lấy mẫu, v.v.
- **Biến đổi dữ liệu (Data transformation):**
  - thực hiện chuyển đổi kiểu dữ liệu, rời rạc hóa, làm mịn, co giãn và chuẩn hóa dữ liệu, v.v.

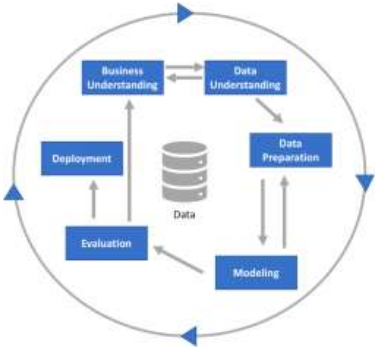
Các tác vụ chính trong tiền xử lý dữ liệu (tiếp theo)



Quy trình chuẩn liên ngành cho khai phá dữ liệu

- Quy trình chuẩn **l**iên **n**gành cho **k**hai **p**há **d**ữ **l**iệu (CRISP–DM) là mô hình quy trình làm nền tảng cho tiến trình khoa học dữ liệu. Nó gồm sáu giai đoạn tuần tự:
  1. Hiểu nghiệp vụ
  2. Hiểu dữ liệu
  3. Chuẩn bị dữ liệu
  4. Mô hình hóa
  5. Đánh giá
  6. Triển khai
- Được công bố năm 1999 nhằm chuẩn hóa các quy trình khai phá dữ liệu giữa các ngành, và từ đó trở thành phương pháp luận phổ biến nhất cho các dự án khai phá dữ liệu, phân tích và khoa học dữ liệu.

Quy trình CRISP–DM



CRISP–DM giai đoạn 1: Hiểu nghiệp vụ

Giai đoạn này tập trung vào việc hiểu mục tiêu và yêu cầu của dự án. Bao gồm bốn tác vụ:

1. **Xác định mục tiêu nghiệp vụ:**
   - hiểu rõ, từ góc độ nghiệp vụ, khách hàng/công ty thực sự muốn đạt được điều gì, sau đó định nghĩa các tiêu chí thành công về nghiệp vụ.
2. **Đánh giá tình huống:**
   - xác định khả năng sẵn có của tài nguyên, yêu cầu dự án, đánh giá rủi ro và phương án dự phòng, thực hiện phân tích chi phí–lợi ích.
3. **Xác định mục tiêu khai phá dữ liệu:**
   - ngoài việc định nghĩa mục tiêu nghiệp vụ, cần xác định thành công trông như thế nào từ góc độ kỹ thuật khai phá dữ liệu.
4. **Lập kế hoạch dự án:**
   - lựa chọn công nghệ và công cụ, định nghĩa kế hoạch chi tiết cho từng giai đoạn.

CRISP–DM giai đoạn 2: Hiểu dữ liệu

Giai đoạn này tập trung vào việc xác định, thu thập và phân tích các tập dữ liệu giúp đạt được mục tiêu dự án. Giai đoạn này cũng có bốn tác vụ:

1. **Thu thập dữ liệu ban đầu:**
   - thu thập dữ liệu cần thiết và (nếu cần) nạp vào công cụ phân tích.
2. **Mô tả dữ liệu:**
   - xem xét dữ liệu và ghi lại các đặc tính bề mặt như định dạng, số lượng bản ghi hoặc thông tin trường dữ liệu.
3. **Khám phá dữ liệu:**
   - đào sâu vào dữ liệu: truy vấn, trực quan hóa và xác định các mối quan hệ.
4. **Xác minh chất lượng dữ liệu:**
   - dữ liệu sạch hay bẩn đến mức nào? Ghi lại các vấn đề về chất lượng.

CRISP–DM giai đoạn 3: Chuẩn bị dữ liệu

Giai đoạn này chuẩn bị dữ liệu cuối cùng cho việc mô hình hóa. Gồm năm tác vụ:

1. **Chọn dữ liệu:**
   - xác định tập dữ liệu nào sẽ được dùng và ghi lại lý do bao gồm/loại trừ.
2. **Làm sạch dữ liệu:**
   - thường là tác vụ tốn nhiều thời gian nhất. Nếu bỏ qua, kết quả sẽ là "rác vào, rác ra". Thực hành phổ biến là sửa, điền thay thế hoặc loại bỏ các giá trị sai.
3. **Xây dựng dữ liệu:**
   - tạo ra các thuộc tính mới hữu ích. Ví dụ: tính chỉ số khối cơ thể (BMI) từ chiều cao và cân nặng.
4. **Tích hợp dữ liệu:**
   - tạo tập dữ liệu mới bằng cách kết hợp dữ liệu từ nhiều nguồn.
5. **Định dạng dữ liệu:**
   - định dạng lại dữ liệu khi cần. Ví dụ: chuyển chuỗi lưu số thành giá trị số để thực hiện các phép tính toán học.

Mục lục

1. Giới thiệu
2. **Làm sạch dữ liệu**
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

Làm sạch dữ liệu

1. Xử lý giá trị bị thiếu
2. Xử lý giá trị không chính xác và không nhất quán
3. Xử lý dữ liệu nhiễu

Xử lý giá trị bị thiếu

1. Bỏ qua các tuple có giá trị bị thiếu
2. Điền giá trị bị thiếu thủ công
3. Dùng hằng số toàn cục để điền giá trị bị thiếu
4. Dùng thước đo xu hướng trung tâm của thuộc tính
5. Dùng giá trị trung bình hoặc trung vị của thuộc tính cho tất cả mẫu thuộc cùng lớp với tuple đang xét
6. Dùng giá trị có xác suất cao nhất để điền vào chỗ thiếu

Bỏ qua các tuple có giá trị bị thiếu

- Thường được thực hiện khi nhãn lớp bị thiếu (giả sử tác vụ khai phá là phân loại).
- Phương pháp này không thực sự hiệu quả, trừ khi tuple chứa nhiều thuộc tính bị thiếu.
- Đặc biệt kém hiệu quả khi tỷ lệ giá trị thiếu trên mỗi thuộc tính chênh lệch đáng kể.
- Khi bỏ qua tuple, chúng ta không tận dụng được giá trị của các thuộc tính còn lại trong tuple đó.

Điền giá trị bị thiếu thủ công

- Nhìn chung, cách tiếp cận này tốn nhiều thời gian và có thể không khả thi với tập dữ liệu lớn có nhiều giá trị bị thiếu.

Dùng hằng số toàn cục để điền giá trị bị thiếu

- Thay thế tất cả giá trị thuộc tính bị thiếu bằng cùng một hằng số, chẳng hạn nhãn "Không rõ" hoặc $-\infty$.
- Nếu giá trị thiếu được thay bằng "Không rõ", chương trình khai phá có thể lầm tưởng chúng tạo thành một khái niệm thú vị vì chúng có chung giá trị là "Không rõ".
- Do đó, dù phương pháp này đơn giản, nó không đáng tin cậy.

Dùng thước đo xu hướng trung tâm của thuộc tính

- Dùng thước đo xu hướng trung tâm của thuộc tính (ví dụ: giá trị trung bình hoặc trung vị) để điền vào các giá trị bị thiếu.
- Với phân phối dữ liệu chuẩn (đối xứng), có thể dùng *giá trị trung bình*; với phân phối lệch, nên dùng *trung vị*.

Điền giá trị theo lớp

- Dùng giá trị trung bình hoặc trung vị của thuộc tính cho tất cả mẫu thuộc cùng lớp với tuple đang xét.
- Ví dụ: nếu phân loại khách hàng theo `rủi_ro_tín_dụng`, ta có thể thay thế giá trị thu nhập bị thiếu bằng giá trị trung bình thu nhập của các khách hàng trong cùng nhóm rủi ro tín dụng với tuple đó.
- Nếu phân phối dữ liệu của một lớp bị lệch, *trung vị* là lựa chọn tốt hơn.

Dùng giá trị có xác suất cao nhất để điền vào chỗ thiếu

- Có thể xác định bằng hồi quy, công cụ suy diễn theo hình thức Bayesian, hoặc cảm ứng cây quyết định.
- Ví dụ: sử dụng các thuộc tính khác của khách hàng trong tập dữ liệu, ta có thể xây dựng cây quyết định để dự đoán giá trị thu nhập bị thiếu.
- Đây là chiến lược phổ biến. So với các phương pháp khác, nó sử dụng nhiều thông tin nhất từ dữ liệu hiện có để dự đoán giá trị thiếu. Bằng cách xem xét các giá trị thuộc tính khác, có khả năng cao hơn rằng mối quan hệ giữa thu nhập và các thuộc tính còn lại được bảo toàn.

Giá trị thiếu không hẳn là lỗi dữ liệu

- Trong một số trường hợp, giá trị thiếu không có nghĩa là dữ liệu bị lỗi!
- Ví dụ: Khi đăng ký thẻ tín dụng, khách hàng có thể để trống mục số bằng lái xe nếu họ không có bằng lái.
- Lý tưởng nhất, mỗi thuộc tính nên có các quy tắc về điều kiện null (cho phép hay không, xử lý thế nào).
- Các trường cũng có thể được để trống có chủ ý để điền sau trong quy trình nghiệp vụ.
- Thiết kế cơ sở dữ liệu và quy trình nhập liệu tốt sẽ giúp giảm thiểu lỗi này ngay từ đầu.

Xử lý giá trị không chính xác và không nhất quán

Các phương pháp chính để loại bỏ hoặc chỉnh sửa các mục nhập sai và không nhất quán:

1. Phát hiện sự không nhất quán (Inconsistency detection)
2. Sử dụng tri thức miền (Domain knowledge)
3. Các phương pháp tập trung vào dữ liệu (Data-centric methods)

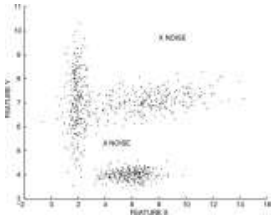
Phát hiện sự không nhất quán

- Thường xảy ra khi dữ liệu đến từ nhiều nguồn khác nhau với các định dạng khác nhau.
- Ví dụ: Tên một người được viết đầy đủ ở nguồn này, nhưng chỉ có chữ cái đầu và họ ở nguồn khác.
- Các vấn đề chính cần giải quyết là phát hiện trùng lặp và phát hiện không nhất quán.
- Những nội dung này thường được nghiên cứu trong lĩnh vực *tích hợp dữ liệu* của cơ sở dữ liệu.

Sử dụng tri thức miền

- Sử dụng các quy tắc về phạm vi thuộc tính hoặc mối quan hệ giữa các thuộc tính.
- Ví dụ: Nếu trường quốc gia là "Hoa Kỳ", thì trường thành phố không thể là "Thượng Hải".
- Nhiều công cụ kiểm tra (data auditing) sử dụng tri thức miền và các ràng buộc để phát hiện mục nhập sai.

Các phương pháp tập trung vào dữ liệu



- Sử dụng hành vi thống kê của dữ liệu để phát hiện các giá trị ngoại lệ (outliers).
- Tuy nhiên, các điểm bất thường có thể là kết quả của một hành vi thú vị của hệ thống.
- Do đó, bất kỳ giá trị ngoại lệ nào cũng cần được kiểm tra thủ công trước khi loại bỏ.
- Việc lạm dụng phương pháp này có thể gây nguy hiểm vì làm mất đi các tri thức hữu ích của hệ thống.

Xử lý dữ liệu nhiễu

- **Nhiễu là gì?** Là lỗi ngẫu nhiên hoặc sự sai khác trong một biến được đo lường.
- Các kỹ thuật làm mịn (smoothing) để xử lý dữ liệu nhiễu:
  - **Phân đoạn (Binning):** tham khảo "láng giềng" xung quanh để làm mịn cục bộ.
  - **Hồi quy (Regression):** khớp dữ liệu vào một hàm số.
  - **Phân tích ngoại lệ (Outlier analysis):** sử dụng phân cụm để xác định các điểm nằm ngoài nhóm.

Làm mịn dữ liệu bằng phân đoạn (Binning)

- Dữ liệu đã sắp xếp được đưa vào các "giỏ" hoặc phân đoạn (bins).
- **Làm mịn bằng trung bình phân đoạn:** Thay mỗi giá trị bằng giá trị trung bình của đoạn đó.
- **Làm mịn bằng trung vị phân đoạn:** Thay mỗi giá trị bằng giá trị trung vị của đoạn.
- **Làm mịn bằng ranh giới phân đoạn:** Thay mỗi giá trị bằng giá trị biên (min hoặc max) gần nó nhất.
- Chiều rộng đoạn càng lớn, hiệu ứng làm mịn càng mạnh.

Ví dụ về phân đoạn (Binning)

Dữ liệu giá đã sắp xếp: 4, 8, 15, 21, 21, 24, 25, 28, 34

Sorted data for *price* (in dollars): 4, 8, 15, 21, 21, 24, 25, 28, 34

Partition into (equal-frequency) bins:

Bin 1: 4, 8, 15
Bin 2: 21, 21, 24
Bin 3: 25, 28, 34

Smoothing by bin means:

Bin 1: 9, 9, 9
Bin 2: 22, 22, 22
Bin 3: 29, 29, 29

Smoothing by bin boundaries:

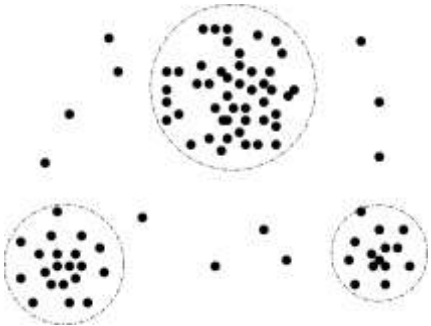
Bin 1: 4, 4, 15
Bin 2: 21, 21, 24
Bin 3: 25, 25, 34

Loại bỏ dữ liệu nhiễu bằng phân cụm

Làm mịn dữ liệu bằng hồi quy

- Hồi quy làm cho các giá trị dữ liệu tuân theo một hàm số.
- **Hồi quy tuyến tính:** Tìm đường thẳng tốt nhất để khớp hai thuộc tính, dùng thuộc tính này dự báo thuộc tính kia.
- **Hồi quy tuyến tính đa biến:** Mở rộng khi có nhiều hơn hai thuộc tính, dữ liệu được khớp vào một bề mặt đa chiều.

Phân tích ngoại lệ (Outlier analysis)



Loại bỏ dữ liệu nhiễu bằng phân cụm

- Các kỹ thuật phân cụm tổ chức các giá trị tương tự nhau vào các nhóm.
- Một cách trực quan, các giá trị nằm ngoài các cụm được coi là giá trị ngoại lệ.

Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. **Tích hợp dữ liệu**
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

Tích hợp dữ liệu

- Khai phá dữ liệu thường yêu cầu tích hợp dữ liệu từ nhiều nguồn khác nhau.
- **Lợi ích của tích hợp cẩn thận:**
  - Giảm và tránh dư thừa, không nhất quán.
  - Cải thiện độ chính xác và tốc độ của quá trình khai phá.
- **Các tác vụ chính:**
  1. Vấn đề định danh thực thể.
  2. Phân tích dư thừa và tương quan.
  3. Trùng lặp bản ghi (tuple).
  4. Phát hiện và giải quyết xung đột giá trị.

Vấn đề định danh thực thể

- Làm sao để khớp các thực thể tương đương từ nhiều nguồn khác nhau?
- Ví dụ: `customer_id` ở database A và `cust_number` ở database B có cùng là một thuộc tính?
- **Siêu dữ liệu (Meta-data) giúp khớp lược đồ:**
  - Tên, mô tả, kiểu dữ liệu và phạm vi của thuộc tính.
  - Các quy tắc null.

Phân tích dư thừa và tương quan

- Thuộc tính là dư thừa nếu nó có thể "suy ra" từ các thuộc tính khác.
- **Phân tích tương quan:** Đo lường mức độ một thuộc tính hàm ý thuộc tính kia.
- **Dữ liệu định danh/phân loại:** Sử dụng kiểm định Chi-bình phương (χ^2).
- **Dữ liệu số:** Sử dụng hiệp biến hoặc hệ số tương quan (như Pearson).

Trùng lặp bản ghi (Tuple duplication)

- Cần phát hiện trùng lặp ở cấp độ bản ghi (tuple).
- Sự không nhất quán phát sinh khi cập nhật một số nhưng không phải tất cả các bản ghi trùng lặp.
- Ví dụ: Một khách hàng xuất hiện với hai địa chỉ khác nhau trong cùng một cơ sở dữ liệu đơn hàng do lỗi nhập liệu.

Xung đột giá trị dữ liệu

- Giá trị thuộc tính từ các nguồn khác nhau có thể khác nhau cho cùng một thực thể thực tế.
- **Nguyên nhân:** Khác biệt về biểu diễn, thang đo hoặc mã hóa.
- Ví dụ: Cân nặng được lưu theo hệ mét ở hệ thống này nhưng theo hệ Anh ở hệ thống khác.
- Ví dụ: Hệ thống điểm số của các trường đại học khác nhau (thang chữ A-F so với thang số 1-10).

Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. **Biến đổi dữ liệu**
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

Biến đổi dữ liệu

1. Chuyển đổi và rời rạc hóa dữ liệu
2. Làm mịn dữ liệu (Data smoothing)
3. Tổng hợp dữ liệu (Data aggregation)
4. Xây dựng thuộc tính (Construction of attributes)
5. Co giãn và chuẩn hóa dữ liệu
6. Tạo phân cấp khái niệm cho dữ liệu định danh

Chuyển đổi và rời rạc hóa dữ liệu

- **Số** $\rightarrow$ **Phân loại:** Rời rạc hóa (Discretization).
- **Phân loại** $\rightarrow$ **Số:** Nhị phân hóa (Binarization).
- **Văn bản** $\rightarrow$ **Số:** (Vector hóa).
- **Chuỗi thời gian** $\rightarrow$ **Chuỗi rời rạc.**

Rời rạc hóa dữ liệu số

- Chia dải giá trị của thuộc tính số thành k khoảng.
- Sau đó, thuộc tính được gắn nhãn phân loại tùy theo khoảng mà nó nằm trong.
- Ví dụ: Thuộc tính tuổi có thể chia thành các khoảng [0-10], [11-20],... tương ứng với các ký hiệu "1", "2",...
- Rời rạc hóa làm mất đi một phần thông tin chi tiết nhưng có thể hữu ích cho một số mô hình.

Thách thức và kỹ thuật rời rạc hóa

- Thách thức lớn là dữ liệu có thể phân bố không đồng đều trên các khoảng.
- Ví dụ: Thuộc tính thu nhập có thể tập trung đông ở khoảng [40,000, 80,000] nhưng rất ít ở khoảng [1,040,000, 1,080,000].
- Do đó, việc sử dụng các khoảng có độ rộng bằng nhau có thể không hiệu quả trong việc phân biệt các phân đoạn dữ liệu.
- Các kỹ thuật rời rạc hóa chính:
  - Các khoảng có độ rộng bằng nhau (Equi-width).
  - Các khoảng theo logarit bằng nhau (Equi-log).
  - Các khoảng có độ sâu bằng nhau (Equi-depth).
  - Rời rạc hóa dựa trên phân cụm (Clustering-based).

Rời rạc hóa: Độ rộng bằng nhau (Equi-width)

- Mỗi khoảng con $[a, b]$ được chọn sao cho giá trị $b - a$ là giống nhau cho mọi khoảng.
- **Nhược điểm:** Không hoạt động tốt với các tập dữ liệu phân bố không đồng đều.
- **Cách thực hiện:** Xác định giá trị nhỏ nhất (min) và lớn nhất (max) của thuộc tính, sau đó chia phạm vi $[min, max]$ thành k khoảng có độ dài bằng nhau.

Rời rạc hóa: Độ rộng Logarit bằng nhau (Equi-log)

- Mỗi khoảng con $[a, b]$ được chọn sao cho $\log(b) - \log(a)$ có giá trị bằng nhau.
- Cách chọn này tạo ra các khoảng con tăng dần theo cấp số nhân:
  $[a, a\alpha], [a\alpha, a\alpha^2], \ldots$ với $\alpha > 1$.
- Hữu ích khi thuộc tính có phân phối theo hàm mũ trên một phạm vi giá trị.
- Ý tưởng là chọn hàm $f(\cdot)$ sao cho mỗi khoảng chứa số lượng bản ghi xấp xỉ nhau.

Ví dụ minh họa rời rạc hóa

(Slide này dành cho các ví dụ tính toán cụ thể về chia khoảng)

Rời rạc hóa: Độ sâu bằng nhau (Equi-depth)

- Các khoảng con được chọn sao cho mỗi khoảng chứa một số lượng bản ghi bằng nhau.
- Mục tiêu là cung cấp cùng một mức độ chi tiết (granularity) cho mỗi khoảng con.
- **Cách thực hiện:** Sắp xếp thuộc tính, sau đó chọn các điểm chia sao cho mỗi đoạn có số lượng bản ghi như nhau.

Rời rạc hóa dựa trên phân cụm [1]

- Phân tích cụm là một phương pháp rời rạc hóa dữ liệu phổ biến.
- Thuật toán phân cụm chia các giá trị của thuộc tính số X thành các nhóm hoặc cụm.
- Phương pháp này xem xét đến sự phân phối của X và khoảng cách giữa các điểm dữ liệu, tạo ra kết quả chất lượng cao.

Chuyển đổi phân loại sang số: Nhị phân hóa

- Chuyển đổi các thuộc tính phân loại thành dạng nhị phân để sử dụng các thuật toán khai phá dữ liệu số.
- Nếu một thuộc tính phân loại có k giá trị, k thuộc tính nhị phân mới sẽ được tạo ra.
- Tại mỗi bản ghi, đúng một trong k thuộc tính nhận giá trị 1 (tương ứng với giá trị hiện tại), các thuộc tính còn lại nhận giá trị 0.

ID	Male	Female	IsStudent	IsEmployee	IsRetired
001	1	0	1	0	0
002	0	1	1	0	0
003	1	0	0	1	0
004	1	0	0	0	1
005	0	1	0	1	0

Chuyển đổi văn bản sang dữ liệu số

- **Mô hình không gian vectơ (Bag of words):** Chuyển tài liệu thành các vectơ thưa thớt với trọng số nhị phân, tần suất hoặc TF-IDF.
- **Mô hình N-gram:** Kết hợp các từ liên tiếp để tạo thành các n-gram (uni-grams, bi-grams...).
- **Mô hình chủ đề:** Biến đổi văn bản thành các vectơ ngữ nghĩa dày đặc với số chiều nhỏ hơn (LSA, LDA).
- **Text embeddings:** Sử dụng học sâu (Word2Vec, GloVe, PhoBERT) để tạo vectơ đặc trưng.

Chuỗi thời gian sang dữ liệu rời rạc

Sử dụng phương pháp Xấp xỉ ký hiệu tổng hợp (SAX) gồm hai bước:

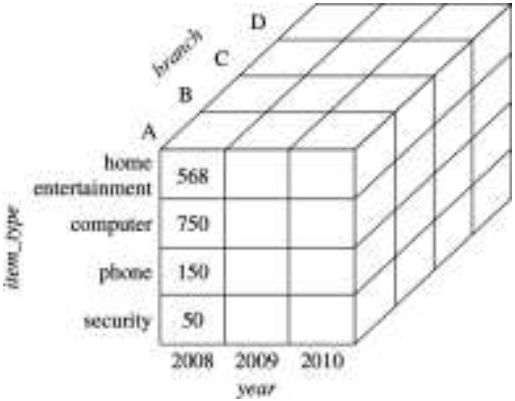
- **Tính trung bình theo cửa sổ:** Chia chuỗi thành các cửa sổ độ dài w và tính giá trị trung bình cho mỗi cửa sổ.
- **Rời rạc hóa giá trị:** Các giá trị trung bình được rời rạc hóa thành các khoảng có độ sâu bằng nhau.
- Các ranh giới khoảng được xác định dựa trên giả định phân phối Gaussian.

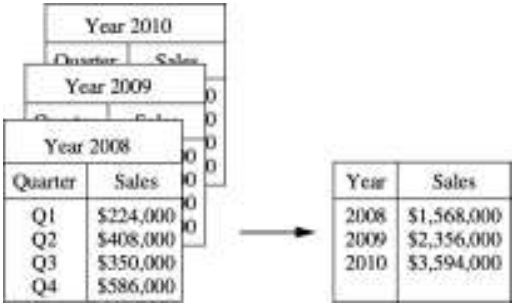
Làm mịn dữ liệu (Data smoothing)

- Làm mịn giúp loại bỏ nhiễu khỏi dữ liệu.
- Các kỹ thuật chính bao gồm: phân đoạn (binning), hồi quy (regression) và phân cụm (clustering).
- Nội dung này đã được trình bày chi tiết trong phần Làm sạch dữ liệu (Xử lý dữ liệu nhiễu).

Tổng hợp dữ liệu (Data aggregation)

- Áp dụng các phép toán tóm tắt hoặc tổng hợp cho dữ liệu.
- Bước này thường dùng để xây dựng khối dữ liệu (Data cube) cho phân tích đa chiều.
- Ví dụ: Thuộc tính Thời gian có thể tổng hợp theo phân cấp: năm > quý > tháng > tuần > ngày > giờ.





Xây dựng thuộc tính (Construction of attributes)

- Tạo ra các thuộc tính mới để hỗ trợ quá trình khai phá và cải thiện độ chính xác trong dữ liệu cao chiều.
- Ví dụ: Thêm thuộc tính `diện_tích` dựa trên `chiều_cao` và `chiều_rộng`.
- Giúp các nhà phân tích khám phá và hiểu cấu trúc dữ liệu dễ dàng hơn.

Co giãn và chuẩn hóa dữ liệu

- Các đặc trưng thường có thang đo khác nhau (ví dụ: tuổi so với lương).
- Thuộc tính có độ lớn lớn hơn sẽ chiếm ưu thế trong các phép toán như khoảng cách Euclidean.
- Giải pháp là co giãn (re-scale) dữ liệu về một phạm vi phù hợp.
- Ba kỹ thuật chuẩn hóa chính:
  1. Chuẩn hóa Min-max.
  2. Chuẩn hóa điểm tiêu chuẩn (Standard score/Z-score).
  3. Co giãn thập phân (Decimal scaling).

Chuẩn hóa Min-max

- Giả sử $D = \{x_1, x_2, ..., x_n\}$ là mẫu dữ liệu đơn biến của thuộc tính X. Trong chuẩn hóa Min-max, mỗi giá trị được co giãn theo công thức:

$$x'_i = \frac{x_i - min_X}{max_X - min_X}(max_X^{new} - min_X^{new}) + min_X^{new}$$

- **Giải thích các chỉ số:**
  - min_X và max_X: Là giá trị nhỏ nhất và lớn nhất của thuộc tính X trong tập dữ liệu gốc ban đầu.
  - min_X^{new} và max_X^{new}: Là phạm vi giá trị mới muốn thiết lập sau khi chuẩn hóa, thường là 0 và 1.
- Sau khi biến đổi, tất cả các giá trị mới x'_i sẽ nằm gọn trong khoảng $[min_X^{new}, max_X^{new}]$.
- Kỹ thuật này còn được gọi là chuẩn hóa phạm vi (range normalization).

Chuẩn hóa điểm tiêu chuẩn (Standard score normalization)

- Còn được gọi là chuẩn hóa z (z-normalization), mỗi giá trị được thay thế bằng điểm z tương ứng:

$$x'_i = \frac{x_i - \hat{\mu}}{\hat{\sigma}}$$

- **Giải thích các chỉ số:**
  - $\hat{\mu}$: Giá trị trung bình của mẫu dữ liệu (sample mean).
  - $\hat{\sigma}$: Độ lệch chuẩn của mẫu dữ liệu (sample standard deviation).
- Sau khi biến đổi, thuộc tính mới sẽ có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1.
- Đa số các giá trị chuẩn hóa thường rơi vào khoảng $[-3, 3]$ theo giả định phân phối chuẩn.

Co giãn thập phân (Decimal scaling)

- Chuẩn hóa bằng cách di chuyển dấu phẩy thập phân của các giá trị thuộc tính X.
- Số vị trí dịch chuyển phụ thuộc vào giá trị tuyệt đối lớn nhất trong tập dữ liệu.

$$x_i' = \frac{x_i}{10^j}$$

- **Giải thích chỉ số j:**
  - j là số nguyên nhỏ nhất sao cho giá trị tuyệt đối lớn nhất sau khi chia phải nhỏ hơn 1 ($max(|x_i'|) < 1$).
- **Ví dụ:** Nếu giá trị lớn nhất là 986, ta chọn $j = 3$ (chia cho 1000) để được 0.986.

Mẫu dữ liệu hai biến (Bivariate data sample)

$$\mathcal{D} = \begin{pmatrix} \mathbf{x}_i & Age\ (X_1) & Income\ (X_2) \\ \mathbf{x}_1 & 12 & 300 \\ \mathbf{x}_2 & 14 & 500 \\ \mathbf{x}_3 & 18 & 1000 \\ \mathbf{x}_4 & 23 & 2000 \\ \mathbf{x}_5 & 27 & 3500 \\ \mathbf{x}_6 & 28 & 4000 \\ \mathbf{x}_7 & 34 & 4300 \\ \mathbf{x}_8 & 37 & 6000 \\ \mathbf{x}_9 & 39 & 2500 \\ \mathbf{x}_{10} & 40 & 2700 \end{pmatrix}$$

- Xét tập dữ liệu D gồm 10 quan sát điểm dữ liệu được rút ra từ hai thuộc tính: Tuổi (X_1) và Thu nhập (X_2).

Ví dụ chuẩn hóa Min-max

- $max_{Age} = 40$ and $min_{Age} = 12$. For example, $x_{31} = 18$, after normalization, $x'_{31} = \frac{18-12}{40-12} = 0.214$.
- Similarly, $max_{Income} = 6000$ and $min_{Income} = 300$.
- After normalization, we have the new data sample $\mathcal{D}'$ with two new attributes Age' and $Income'$ as follows:

$$\mathcal{D}' = \begin{pmatrix} \mathbf{x}_i & Age'\ (X'_1) & Income'\ (X'_2) \\ \mathbf{x}_1 & 0.0 & 0.0 \\ \mathbf{x}_2 & 0.071 & 0.035 \\ \mathbf{x}_3 & 0.214 & 0.123 \\ \mathbf{x}_4 & 0.393 & 0.298 \\ \mathbf{x}_5 & 0.536 & 0.561 \\ \mathbf{x}_6 & 0.571 & 0.649 \\ \mathbf{x}_7 & 0.786 & 0.702 \\ \mathbf{x}_8 & 0.893 & 1.0 \\ \mathbf{x}_9 & 0.964 & 0.386 \\ \mathbf{x}_{10} & 1.0 & 0.421 \end{pmatrix}$$

Ví dụ chuẩn hóa điểm tiêu chuẩn (Z-score)

- For z–normalization, we first compute the mean and standard deviation of both attributes:

$$\hat{\mu}_{Age} = 27.2 \text{ and } \hat{\sigma}_{Age} = 9.77$$
$$\hat{\mu}_{Income} = 2680 \text{ and } \hat{\sigma}_{Income} = 1726.15$$

- The new data after z–normalization is as follows:

$$\mathcal{D}' = \begin{pmatrix} \mathbf{x}_i & Age'\ (X_1') & Income'\ (X_2') \\ \mathbf{x}_1 & -1.56 & -1.38 \\ \mathbf{x}_2 & -1.35 & -1.26 \\ \mathbf{x}_3 & -0.94 & -0.97 \\ \mathbf{x}_4 & -0.43 & -0.39 \\ \mathbf{x}_5 & -0.02 & 0.48 \\ \mathbf{x}_6 & 0.08 & 0.76 \\ \mathbf{x}_7 & 0.70 & 0.94 \\ \mathbf{x}_8 & 1.0 & 1.92 \\ \mathbf{x}_9 & 1.21 & -0.10 \\ \mathbf{x}_{10} & 1.31 & 0.01 \end{pmatrix}$$

Khoảng cách trước và sau chuẩn hóa

- The Euclidean distance between $\mathbf{x}_1$ and $\mathbf{x}_2$ according to the original data:

$$\begin{aligned}\|\mathbf{x}_1 - \mathbf{x}_2\| &= \|(-2, -200)^T\| \\ &= \sqrt{(-2)^2 + (-200)^2} = \sqrt{40004} = \mathbf{200.01}\end{aligned}$$

- According to the data after min–max normalization:

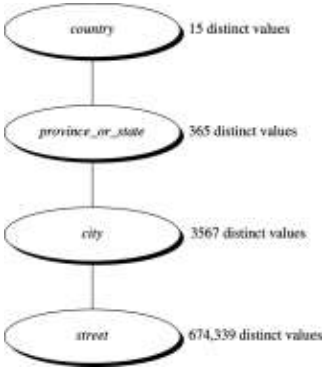
$$\begin{aligned}\|\mathbf{x}_1' - \mathbf{x}_2'\| &= \|(0, 0)^T - (0.071, 0.035)^T\| \\ &= \|(-0.071, -0.035)^T\| = \mathbf{0.079}\end{aligned}$$

- According to the data after z–normalization:

$$\begin{aligned}\|\mathbf{x}_1' - \mathbf{x}_2'\| &= \|(-1.56, -1.38)^T - (1.35, -1.26)^T\| \\ &= \|(-0.21, -0.12)^T\| = \mathbf{0.242}\end{aligned}$$

Tạo phân cấp khái niệm cho dữ liệu định danh

- Phân cấp khái niệm cho phép các thuộc tính định danh (như tên đường) được tổng quát hóa thành các khái niệm cấp cao hơn (như thành phố hoặc quốc gia).
- Nhiều phân cấp được ngầm định trong lược đồ cơ sở dữ liệu và có thể được xác định tự động ở cấp độ định nghĩa lược đồ.



Ví dụ khái niệm phân cấp

Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. **Giảm chiều dữ liệu**
6. Lấy mẫu dữ liệu
7. Tài liệu tham khảo và Tổng kết

Tổng quan về giảm dữ liệu

- Kỹ thuật giảm dữ liệu giúp thu được một biểu diễn nhỏ hơn của tập dữ liệu về mặt khối lượng, nhưng vẫn duy trì tính toàn vẹn của dữ liệu gốc.
- Mục tiêu: Khai phá trên tập dữ liệu đã giảm hiệu quả hơn nhưng vẫn mang lại kết quả phân tích tương đương.
- **Hai chiến lược chính:**
  - **Giảm số chiều (Dimensionality reduction):** Giảm số lượng biến ngẫu nhiên hoặc thuộc tính đang xem xét (ví dụ: PCA, lựa chọn tập con).
  - **Giảm số lượng (Numerosity reduction):** Thay thế khối lượng dữ liệu gốc bằng các hình thức biểu diễn nhỏ hơn như hồi quy hay phân cụm.

Các phương pháp giảm dữ liệu

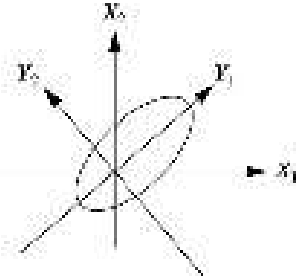
Các kỹ thuật phổ biến để thực hiện giảm dữ liệu bao gồm:

1. Phân tích thành phần chính (PCA)
2. Lựa chọn tập con các thuộc tính (Attribute subset selection)
3. Biểu đồ tần suất (Histograms)
4. Phân cụm (Clustering)
5. Lấy mẫu dữ liệu (Data sampling)
6. Tổng hợp khối dữ liệu (Data cube aggregation)

Phân tích thành phần chính (PCA)

- PCA là phương pháp tìm kiếm k vectơ trực giao n chiều ($k \leq n$) có thể biểu diễn dữ liệu tốt nhất.
- **Cơ chế:** Dữ liệu gốc được chiếu lên một không gian nhỏ hơn, giúp giảm số chiều đáng kể.
- PCA "kết hợp" bản chất của các thuộc tính để tạo ra một tập hợp các biến thay thế mới.
- Kỹ thuật này thường tiết lộ các mối quan hệ ẩn giữa các thuộc tính mà các phương pháp thông thường không thấy được.

Các bước thực hiện PCA



PCA: Y1 và Y2 là hai thành phần chính đầu tiên cho dữ liệu đã cho.

- **Bước 1: Chuẩn hóa dữ liệu.** Đưa các thuộc tính về cùng một phạm vi để đảm bảo các thuộc tính có miền giá trị lớn không chiếm ưu thế.
- **Bước 2: Tính toán vectơ trực chuẩn.** PCA tìm k vectơ đơn vị vuông góc với nhau làm cơ sở cho dữ liệu mới.
- Các vectơ này được gọi là các **thành phần chính**. Dữ liệu đầu vào sẽ được biểu diễn dưới dạng tổ hợp tuyến tính của các thành phần này.

Các bước thực hiện PCA (tiếp theo)

- Bước 3: Các thành phần chính được sắp xếp theo thứ tự giảm dần về "tầm quan trọng" hoặc độ mạnh. Các thành phần chính về cơ bản đóng vai trò như một tập hợp trục mới cho dữ liệu, cung cấp thông tin quan trọng về phương sai. Cụ thể, các trục được sắp xếp sao cho trục đầu tiên thể hiện phương sai lớn nhất trong dữ liệu, trục thứ hai thể hiện phương sai một mức cao tiếp theo, và cứ tiếp tục như vậy. Ví dụ, hình trước đó hiển thị hai thành phần chính đầu tiên, Y1 và Y2, cho tập dữ liệu đã được ánh xạ ban đầu lên các trục X1 và X2. Thông tin này giúp xác định các nhóm hoặc các mô hình trong dữ liệu.
- Bước 4: Bởi vì các thành phần được sắp xếp theo thứ tự giảm dần về "tầm quan trọng," kích thước dữ liệu có thể được giảm bằng cách loại bỏ các thành phần yếu hơn, tức là những thành phần có phương sai thấp. Sử dụng các thành phần chính mạnh nhất, có thể tái tạo một gần đúng tốt của dữ liệu gốc.

PCA có thể xử lý dữ liệu thưa và dữ liệu lệch. Dữ liệu đa chiều có thể được xử lý bằng cách giảm xuống hai chiều. Các thành phần chính có thể được sử dụng làm dữ liệu đầu vào cho hồi quy và phân tích cụm.

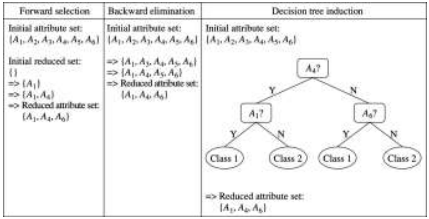
Lựa chọn tập con các thuộc tính

- Các tập dữ liệu để phân tích có thể chứa hàng trăm thuộc tính, nhiều thuộc tính trong đó có thể không liên quan đến tác vụ khai phá hoặc bị dư thừa.
- **Ví dụ:** Nếu tác vụ là phân loại khách hàng dựa trên khả năng họ mua một đĩa CD mới tại AllElectronics, các thuộc tính như `telephone_number` thường không liên quan, không giống như age hay `music_taste`.
- Mặc dù chuyên gia về miền có thể chọn ra một số thuộc tính hữu ích, đây có thể là một nhiệm vụ khó khăn và tốn thời gian, đặc biệt khi hành vi của dữ liệu chưa được biết rõ.
- Việc loại bỏ các thuộc tính liên quan hoặc giữ lại các thuộc tính không liên quan có thể gây hại, gây nhầm lẫn cho thuật toán khai phá, dẫn đến các mẫu tìm thấy có chất lượng kém.
- Ngoài ra, khối lượng thuộc tính dư thừa làm chậm quá trình khai phá.

Mục tiêu của lựa chọn tập con các thuộc tính

- Lựa chọn tập con thuộc tính giúp giảm kích thước tập dữ liệu bằng cách loại bỏ các thuộc tính (hoặc số chiều) không liên quan hoặc dư thừa.
- **Mục tiêu:** Tìm kiếm một tập hợp tối thiểu các thuộc tính sao cho phân phối xác suất của các lớp dữ liệu thu được là gần nhất có thể với phân phối gốc khi sử dụng tất cả thuộc tính.
- **Lợi ích bổ sung:** Khai phá trên một tập hợp thuộc tính đã giảm giúp giảm số lượng thuộc tính xuất hiện trong các mẫu khám phá được, giúp các mẫu này dễ hiểu hơn đối với người dùng.

Cách tìm tập con "tốt" của các thuộc tính gốc



Các phương pháp tham lam (heuristic) để chọn tập con thuộc tính

- Đối với n thuộc tính, có 2^n tập con có thể có. Một cuộc tìm kiếm vét cạn cho tập con tối ưu có thể cực kỳ tốn kém.
- Cách tiếp cận tham lam (Greedy/heuristic) thường được sử dụng.
- Các thuộc tính "tốt nhất" (và "tệ nhất") thường được xác định bằng các kiểm định thống kê.

Các phương pháp lựa chọn tập con thuộc tính

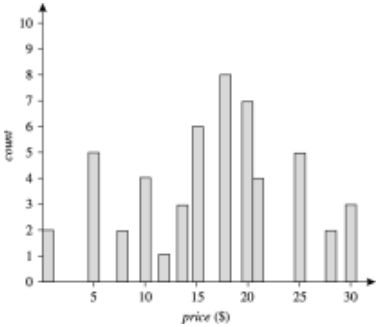
- **Lựa chọn tiến từng bước (Stepwise forward selection):** Quy trình bắt đầu với một tập thuộc tính rỗng. Thuộc tính tốt nhất trong số các thuộc tính gốc được xác định và thêm vào tập, tương tự cho các bước tiếp theo.
- **Loại bỏ lùi từng bước (Stepwise backward elimination):** Quy trình bắt đầu với tập hợp đầy đủ các thuộc tính. Tại mỗi bước, nó loại bỏ thuộc tính tệ nhất còn lại trong tập hợp.
- **Kết hợp lựa chọn tiến và loại bỏ lùi:** Hai phương pháp trên có thể được kết hợp trong mỗi bước.
- **Cảm ứng cây quyết định:** Các thuật toán cây quyết định (ID3, C4.5, CART) được thiết kế cho phân loại. Tất cả các thuộc tính xuất hiện trong cây được coi là có liên quan.
- Tiêu chí dừng có thể thay đổi, ví dụ như sử dụng một ngưỡng (threshold) cho thước đo được chọn.

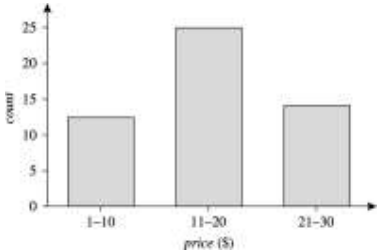
Biểu đồ tần suất (Histograms)

- Biểu đồ tần suất sử dụng kỹ thuật phân đoạn (binning) để xấp xỉ phân phối dữ liệu và là một hình thức giảm dữ liệu phổ biến.
- Một biểu đồ tần suất cho thuộc tính X chia phân phối của X thành các tập con không giao nhau, gọi là các giỏ (buckets) hoặc đoạn (bins).
- Nếu mỗi giỏ chỉ đại diện cho một cặp giá trị-thuộc tính/tần suất duy nhất, chúng được gọi là **singleton buckets**. Thông thường, các giỏ đại diện cho các phạm vi liên tục.
- **Các phương pháp phân chia:**
  - **Độ rộng bằng nhau (Equal-width):** Chiều rộng của mỗi khoảng giỏ là đồng nhất.
  - **Tần suất bằng nhau (Equal-frequency/depth):** Mỗi giỏ chứa số lượng mẫu dữ liệu xấp xỉ như nhau.
- Biểu đồ tần suất rất hiệu quả trong việc xấp xỉ cả dữ liệu thưa thớt, dữ liệu dày đặc, dữ liệu bị lệch hoặc đồng nhất.

Ví dụ về biểu đồ tần suất

- Dữ liệu sau đây là danh sách giá của AllElectronics cho các mặt hàng phổ biến được bán [1]. Các con số đã được sắp xếp: 1, 1, 5, 5, 5, 5, 5, 8, 8, 10, 10, 10, 10, 12, 14, 14, 14, 15, 15, 15, 15, 15, 15, 18, 18, 18, 18, 18, 18, 18, 18, 20, 20, 20, 20, 20, 20, 20, 21, 21, 21, 21, 25, 25, 25, 25, 25, 28, 28, 30, 30, 30.





Phân cụm (Clustering)

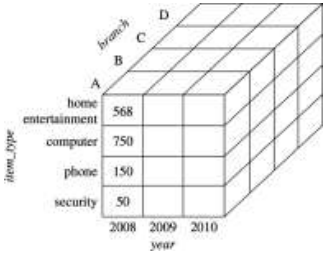
- Các kỹ thuật phân cụm phân chia các đối tượng dữ liệu thành các nhóm (cụm) sao cho các đối tượng trong cùng một cụm thì "tương tự" nhau và "khác biệt" với các đối tượng ở cụm khác.
- Độ tương tự thường được định nghĩa dựa trên mức độ "gần nhau" của các đối tượng trong không gian, dựa trên một hàm khoảng cách.
- **Trong giảm dữ liệu:** Các biểu diễn cụm của dữ liệu được sử dụng để thay thế cho dữ liệu thực tế.
- Hiệu quả của kỹ thuật này phụ thuộc vào bản chất của dữ liệu: Nó hiệu quả hơn nhiều đối với dữ liệu có thể tổ chức thành các cụm rõ rệt thay vì dữ liệu bị nhòe (smeared data).
- Các phương pháp phân cụm khác nhau sẽ được trình bày trong chương **Data clustering**.

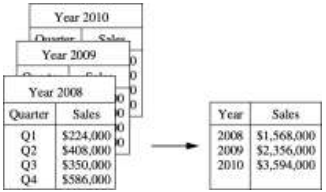
Lấy mẫu dữ liệu (Data sampling)

- Lấy mẫu dữ liệu có thể được sử dụng như một phương pháp giảm dữ liệu vì nó cho phép một tập dữ liệu lớn được đại diện bởi một tập con dữ liệu nhỏ hơn nhiều (ngẫu nhiên hoặc phi ngẫu nhiên).
- Các kỹ thuật lấy mẫu chính:
  - **Lấy mẫu ngẫu nhiên (Random):** Ngẫu nhiên đơn giản (có/không thay thế), phân tầng, phân cụm, hệ thống, nhiều giai đoạn.
  - **Lấy mẫu phi ngẫu nhiên (Non-random):** Thuận tiện (convenience), phán đoán (judgement), định mức (quota), quả cầu tuyết (snowball).
- Các kỹ thuật lấy mẫu sẽ được trình bày chi tiết trong phần tiếp theo.

Tổng hợp khối dữ liệu (Data cube aggregation)

- Khối dữ liệu (Data cube) là một khái niệm phổ biến trong kho dữ liệu, đại diện cho một tập dữ liệu đa chiều, nơi mỗi thuộc tính có thể có một phân cấp khái niệm.
- Ví dụ: Thuộc tính Thời gian có các mức độ chi tiết như {năm > quý > tháng > tuần > ngày > giờ}.
- **Drill-down:** Cho phép xem dữ liệu ở mức chi tiết hơn.
- **Roll-up:** Cho phép xem dữ liệu ở mức tổng quát hơn hoặc tóm tắt.





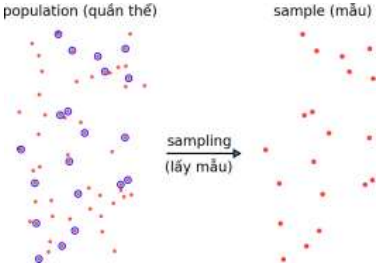
Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. **Lấy mẫu dữ liệu**
7. Tài liệu tham khảo và Tổng kết

Lấy mẫu dữ liệu

- Lấy mẫu dữ liệu là quá trình chọn một tập con các quan sát dữ liệu (các đối tượng dữ liệu, phần tử, các trường hợp, điểm), được gọi là mẫu dữ liệu, từ một tập hợp dữ liệu lớn.
- Mẫu dữ liệu thu được thường bao gồm các điểm dữ liệu là những đại diện tốt của quần thể, phản ánh đúng bản chất và đặc điểm của quần thể.
- Lấy mẫu dữ liệu là quan trọng vì hầu hết các nhiệm vụ phân tích dữ liệu sẽ được thực hiện trên một mẫu dữ liệu thay vì toàn bộ dân số.
- Lấy mẫu dữ liệu có thể được xem như một kỹ thuật giảm dữ liệu vì nó cho phép một tập dữ liệu lớn được thể hiện bằng một mẫu dữ liệu nhỏ hơn nhiều (ngẫu nhiên/phi ngẫu nhiên).
- Kỹ thuật lấy mẫu dữ liệu được phân loại thành hai loại chính: Lấy mẫu ngẫu nhiên và Lấy mẫu phi ngẫu nhiên

Phương pháp lấy mẫu ngẫu nhiên



Lấy mẫu dữ liệu

Trong lấy mẫu ngẫu nhiên, mỗi phần tử dữ liệu trong quần thể có cơ hội được chọn thông qua một quá trình lựa chọn ngẫu nhiên. Các kỹ thuật lấy mẫu ngẫu nhiên phổ biến như sau:

- Lấy mẫu ngẫu nhiên đơn
- Phân tầng mẫu
- Lấy mẫu cụm
- Lấy mẫu có hệ thống
- Lấy mẫu nhiều giai đoạn

Lấy mẫu ngẫu nhiên đơn giản (Simple random sampling)

- Là một tập con của quần thể thống kê, trong đó mỗi thành viên của tập con có xác suất được chọn như nhau.
- Điều này có nghĩa là không có sự thiên vị (bias) khi lấy mẫu.
- Một mẫu ngẫu nhiên đơn giản lấy một phần nhỏ, ngẫu nhiên của toàn bộ quần thể để đại diện cho toàn bộ dữ liệu.
- Có thể thực hiện bằng các phương pháp như xổ số hoặc bốc thăm ngẫu nhiên.
- Kỹ thuật này thường được sử dụng khi chúng ta có ít hoặc không có thông tin về quần thể.
- Có hai hình thức: Lấy mẫu có thay thế và lấy mẫu không thay thế.
- **Ví dụ:**
  - Chọn ngẫu nhiên 30 nhân viên từ 100 nhân viên của một công ty (không thay thế).
  - Chọn ngẫu nhiên 10.000 tài liệu từ tập hợp 100.000 tài liệu văn bản (có thay thế).

Tái lấy mẫu Bootstrap (Bootstrap resampling)

- Gọi $D = \{x_1, x_2, \ldots, x_n\}$ là một tập dữ liệu gồm n phần tử.
- Tạo tập dữ liệu D' bằng cách lặp lại n lần phép lấy mẫu ngẫu nhiên đơn giản **có hoàn lại**.
- Do lấy mẫu có hoàn lại, xác suất để mỗi phần tử được chọn trong một lần lấy mẫu là $\frac{1}{n}$, và xác suất **không được chọn** là $1 - \frac{1}{n}$.
- Xác suất để một phần tử $x_i \in D$ **không xuất hiện** trong D' sau n lần lấy mẫu là:

$$P(x_i \notin D') = \left(1 - \frac{1}{n}\right)^n \approx e^{-1} = 0.368$$

- Do đó, xác suất để phần tử $x_i \in D$ **xuất hiện ít nhất một lần** trong D' là:

$$P(x_i \in D') = 1 - P(x_i \notin D') = 1 - 0.368 = 0.632$$

- Khi thực hiện kỹ thuật lấy mẫu này k lần để tạo ra các tập $D_1, D_2, \ldots, D_k$ thì gọi là **Bootstrap (lấy mẫu lại)**.
- Phương pháp này được sử dụng rộng rãi trong **thống kê, phân tích dữ liệu và học máy**.

Lấy mẫu phân tầng (Stratified sampling)

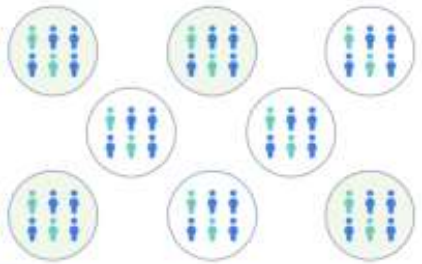


- Trong kỹ thuật này, các phần tử dữ liệu trước tiên được chia thành các nhóm hoặc tầng (strata) khác nhau.
- Các phần tử trong mỗi tầng có tính chất tương tự nhau và khác biệt với các phần tử ở các tầng khác.
- Sau khi phân chia, lấy mẫu ngẫu nhiên đơn giản sẽ được áp dụng cho từng tầng để chọn các phần tử vào mẫu cuối cùng.
- Kỹ thuật này yêu cầu người thực hiện phải có hiểu biết về quần thể để chia tầng một cách chính xác.

Ví dụ về lấy mẫu phân tầng

- **Bài toán:** Chọn ngẫu nhiên 30 nhân viên từ 100 nhân viên sao cho một nửa số được chọn (15 người) là nữ.
- Lấy mẫu ngẫu nhiên đơn giản không phải lúc nào cũng đáp ứng được ràng buộc này.
- **Cách thực hiện:**
  - Giả sử trong 100 nhân viên có 25 nữ và 75 nam.
  - Chia quần thể thành 2 tầng: Tầng nữ (25 người) và Tầng nam (75 người).
  - Áp dụng lấy mẫu ngẫu nhiên đơn giản cho từng nhóm: chọn 15 người từ nhóm nữ và 15 người từ nhóm nam.
- **Ứng dụng:** Thường dùng khi có các ràng buộc cụ thể cho mẫu dữ liệu hoặc khi phân phối quần thể bị lệch.

Lấy mẫu phân cụm (Cluster sampling)

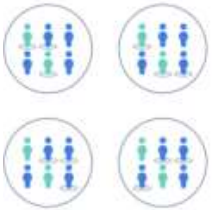


- **Bước 1:** Xác định quần thể.
- **Bước 2:** Chia quần thể thành các cụm (clusters).
- **Yêu cầu của cụm:**
  - Mỗi cụm nên đa dạng nhất có thể; mọi đặc điểm của toàn bộ quần thể nên được đại diện trong từng cụm.
  - Mỗi cụm nên có phân phối đặc điểm tương tự như phân phối của toàn bộ quần thể.
  - Các cụm phải bao phủ toàn bộ quần thể và không chồng lấn lên nhau.

Quy trình lấy mẫu phân cụm (tiếp theo)

- **Bước 3:** Chọn ngẫu nhiên các cụm để làm mẫu.
  - Nếu mỗi cụm là một "đại diện thu nhỏ" của quần thể, việc chọn ngẫu nhiên các cụm cho phép mô phỏng lấy mẫu ngẫu nhiên đơn giản.
  - Nếu các cụm không mang tính đại diện, lấy mẫu ngẫu nhiên vẫn giúp thu thập dữ liệu từ một dãy các cụm đa dạng, cung cấp cái nhìn tổng quát.
- **Bước 4:** Thu thập tất cả phần tử trong các cụm đã chọn để tạo thành mẫu dữ liệu cuối cùng.

Lấy mẫu phân cụm nhiều giai đoạn



- Thay vì thu thập dữ liệu từ mọi phần tử trong cụm đã chọn, chúng ta chọn ngẫu nhiên các cá thể bên trong cụm đó.
- **Lấy mẫu hai giai đoạn (Double-stage):** Chọn cụm, sau đó chọn phần tử trong cụm.
- **Lấy mẫu nhiều giai đoạn (Multi-stage):** Tiếp tục quy trình chia nhỏ cụm và lấy mẫu ngẫu nhiên qua nhiều cấp độ.
- Kỹ thuật này giúp giảm bớt khối lượng công việc so với việc khảo sát toàn bộ cụm.

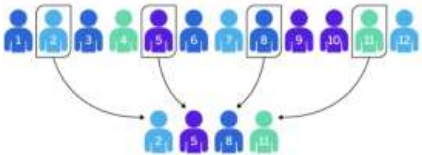
Ưu và nhược điểm của lấy mẫu phân cụm

- **Ưu điểm:**
  - Hiệu quả về thời gian và chi phí, đặc biệt với các mẫu phân tán rộng về địa lý.
  - Có tính xác thực ngoại vi (external validity) cao nếu việc phân cụm được thực hiện đúng cách.
- **Nhược điểm:**
  - Tính xác thực nội vi (internal validity) yếu hơn lấy mẫu ngẫu nhiên đơn giản, đặc biệt khi dùng nhiều giai đoạn.
  - Khó tin cậy nếu các cụm không phải là đại diện tốt cho quần thể.
  - Phức tạp trong việc lập kế hoạch hơn các hình thức lấy mẫu khác.

Lấy mẫu hệ thống (Systematic sampling)

- Chỉ có phần tử đầu tiên được chọn ngẫu nhiên. Từ phần tử thứ hai, việc lựa chọn dựa trên phần tử trước đó.
- **Quy trình:**
  1. Sắp xếp toàn bộ quần thể (quy mô N) thành một dãy theo thứ tự ngẫu nhiên.
  2. Chia dãy thành n phân đoạn với độ dài bước $k = \lfloor N/n \rfloor$.
  3. Chọn ngẫu nhiên phần tử đầu tiên tại vị trí i_1 trong phân đoạn đầu.
  4. Các phần tử tiếp theo sẽ ở vị trí: $i_2 = i_1 + k, i_3 = i_1 + 2k, ..., i_n = i_1 + (n-1)k$.
- **Ví dụ:** Với $N = 22, n = 5 \Rightarrow k = 4$. Nếu phần tử đầu chọn ở vị trí 2, các phần tử tiếp theo là 6, 10, 14, 18.

Ví dụ minh họa lấy mẫu hệ thống



- Trong hình trên, quần thể có $N = 12$, cần lấy mẫu $n = 4$.
- Độ dài bước $k = 12/4 = 3$.
- Phần tử đầu tiên được chọn ngẫu nhiên là số 2.
- Các phần tử tiếp theo được chọn cách nhau đúng 3 đơn vị: 5, 8, và 11.

Lấy mẫu nhiều giai đoạn (Multi-stage sampling)

- Được coi là phiên bản mở rộng của lấy mẫu phân cụm.
- Chia quần thể thành các cụm lớn và chọn một số cụm ở giai đoạn đầu.
- Ở các giai đoạn tiếp theo, tiếp tục chia nhỏ các cụm đã chọn và lặp lại quy trình.
- **Đặc điểm quan trọng:** Không cần một khung lấy mẫu (sampling frame) liệt kê mọi thành viên của toàn bộ quần thể ngay từ đầu.
- Rất hữu ích cho việc thu thập dữ liệu từ quần thể lớn và phân tán rộng.

Ví dụ lấy mẫu nhiều giai đoạn

- **Bối cảnh:** Bộ Giáo dục và Đào tạo (MOET) muốn phỏng vấn 10.000 học sinh THPT trên toàn quốc để đánh giá kiến thức độc lập với kỳ thi tốt nghiệp.
- **Thử thách:** Không thể phỏng vấn tất cả học sinh do giới hạn thời gian, nhân lực và chi phí.
- **Bước 1: Phân cụm địa lý**
  - Chia các tỉnh/thành thành 8 vùng: Tây Bắc, Đông Bắc, Đồng bằng sông Hồng, Bắc Trung Bộ, Nam Trung Bộ, Tây Nguyên, Đông Nam Bộ, Đồng bằng sông Cửu Long.
  - Chọn ngẫu nhiên một số tỉnh từ mỗi vùng (Ví dụ: Hà Nội từ vùng ĐBSH, Cần Thơ từ vùng ĐBSCL).

Ví dụ lấy mẫu nhiều giai đoạn (tiếp theo)

- **Bước 2: Phân cụm trường học**
  - Phân loại các trường THPT trong các tỉnh đã chọn thành các khu vực: KV1, KV2, KV2-NT, KV3.
  - Chọn ngẫu nhiên 25 trường từ mỗi nhóm khu vực để có tổng cộng 100 trường.
- **Bước 3: Chọn học sinh**
  - Từ mỗi trường trong số 100 trường, chọn ngẫu nhiên 100 học sinh lớp 12.
- **Kết quả:** Thu được mẫu 10.000 học sinh rất đa dạng, đại diện cho mọi vùng miền, thành thị, nông thôn và dân tộc.

Phương pháp lấy mẫu phi ngẫu nhiên

- Là cách tiếp cận mà việc lựa chọn các phần tử không dựa trên tính ngẫu nhiên.
- Thay vào đó, việc lựa chọn dựa trên hiểu biết hoặc sự thuận tiện của con người.
- Mẫu dữ liệu thu được có thể bị thiên vị (biased).
- **Các kỹ thuật phổ biến:**
  1. Lấy mẫu thuận tiện (Convenience sampling)
  2. Lấy mẫu phán đoán (Judgement sampling)
  3. Lấy mẫu định mức (Quota sampling)
  4. Lấy mẫu quả cầu tuyết (Snowball sampling)

Lấy mẫu thuận tiện (Convenience sampling)

- Thu thập dữ liệu từ một nhóm đối tượng có sẵn một cách thuận tiện.
- Được sử dụng phổ biến vì tính nhanh chóng, đơn giản và tiết kiệm.
- Các thành viên thường dễ dàng tiếp cận để tham gia vào mẫu.
- Thường dùng khi việc kiểm tra toàn bộ cộng đồng là bất khả thi hoặc khi không cần thêm các đầu vào khắt khe.
- Không có tiêu chí bắt buộc để trở thành một phần của mẫu này.
- Người nghiên cứu chọn thành viên dựa trên khoảng cách địa lý hoặc sự sẵn sàng mà không xem xét tính đại diện.

Ứng dụng và rủi ro của lấy mẫu thuận tiện

- **Ứng dụng:** Các thương hiệu đo lường hình ảnh thị trường, thu thập ý kiến về sản phẩm mới ra mắt.
- **Ví dụ:** Phát tờ rơi quảng cáo và đặt câu hỏi tại trung tâm thương mại hoặc trên đường phố đông đúc.
- **Hạn chế:** Có rủi ro cao là quần thể được chọn không đại diện chính xác cho quần thể mục tiêu, làm tăng khả năng sai lệch kết quả.

Ưu điểm của lấy mẫu thuận tiện

- **Thu thập dữ liệu nhanh:** Các quy tắc thu thập đơn giản nhất so với các phương pháp ngẫu nhiên.
- **Chi phí thấp:** Đây là lý do chính khiến nhiều nhà nghiên cứu áp dụng kỹ thuật này.
- **Mẫu sẵn có:** Dữ liệu dễ tiếp cận, thường là quần thể ngay trước mắt.
- **Ít quy tắc:** Không yêu cầu danh sách kiểm tra (checklist) phức tạp để lọc đối tượng.

Lấy mẫu phán đoán (Judgement sampling)

- Còn được gọi là lấy mẫu có mục đích hoặc lấy mẫu có thẩm quyền.
- Các thành viên của mẫu được chọn chỉ dựa trên kiến thức và phán đoán của người nghiên cứu.
- Quy trình lựa chọn được thực hiện cẩn thận bởi chuyên gia để đảm bảo chọn đúng cá nhân có phẩm chất mong muốn.
- **Hiệu quả nhất khi:** Chỉ có một số lượng hạn chế người trong quần thể sở hữu những đặc điểm mà nhà nghiên cứu kỳ vọng.
- Thường dùng cho các nhóm đối tượng có trí tuệ cao hoặc chuyên gia đầu ngành.

Ưu điểm của lấy mẫu phán đoán

- **Tiết kiệm thời gian thực hiện:** Do chuyên môn của nhà nghiên cứu đóng vai trò chủ đạo, không có rào cản tiêu chí khác.
- **Tiếp cận trực tiếp thị trường mục tiêu:** Nhà nghiên cứu có thể giao tiếp thẳng với đối tượng lựa chọn để ra kết quả mong muốn.
- **Kết quả gần như thời gian thực:** Có thể thực hiện các cuộc thăm dò nhanh vì các thành viên đều có kiến thức phù hợp về chủ đề.

Lấy mẫu định mức (Quota sampling)

- Quần thể được chia thành các nhóm con riêng biệt theo các tiêu chí cụ thể.
- Việc phân chia có thể thực hiện ở nhiều cấp độ khác nhau.
- **Quy trình:** Sau khi chia nhóm, việc lấy mẫu trong mỗi nhóm được thực hiện bằng phương pháp thuận tiện hoặc phán đoán cho đến khi đạt được định mức (quota) định trước.
- **Ví dụ:** Chính quyền địa phương muốn lấy ý kiến từ 200 người gồm: 50 người già, 100 nhân viên và 50 nội trợ. Họ sẽ phân loại dân cư và lấy mẫu cho đến khi đủ số lượng cho mỗi nhóm.

Lấy mẫu quả cầu tuyết (Snowball sampling)

- Thường dùng khi có ít thông tin hoặc khó tiếp cận các phần tử trong quần thể.
- **Quy trình:** Tìm phần tử thích hợp đầu tiên, sau đó nhờ họ giới thiệu thêm những người khác trong cộng đồng mà nhà nghiên cứu không biết.
- Theo cách này, mẫu sẽ mở rộng nhanh chóng như một quả cầu tuyết đang lăn.
- **Ví dụ:** Phỏng vấn nhóm cộng đồng LGBT. Tìm người đầu tiên và nhờ họ giới thiệu các thành viên khác trong mạng lưới của họ.
- Kỹ thuật này còn được gọi là lấy mẫu giới thiệu (referral sampling).

Mục lục

1. Giới thiệu
2. Làm sạch dữ liệu
3. Tích hợp dữ liệu
4. Biến đổi dữ liệu
5. Giảm chiều dữ liệu
6. Lấy mẫu dữ liệu
7. **Tài liệu tham khảo và Tổng kết**

Tài liệu tham khảo

1. J. Han, M. Kamber, and J. Pei. Data Mining: Concepts and Techniques. Morgan Kaufmann, Elsevier, 2012[cite: 1088].
2. C. Aggarwal. Data Mining: The Textbook. Springer, 2015[cite: 1089].
3. J. Leskovec et al. Mining of Massive Datasets. Cambridge University Press, 2014[cite: 1090].
4. M. J. Zaki et al. Data Mining and Analysis: Fundamental Concepts and Algorithms. Cambridge University Press, 2013[cite: 1091].
5. D. Easley et al. Networks, Crowds, and Markets. Cambridge University Press, 2010[cite: 1092].
6. J. VanderPlas. Python Data Science Handbook. O'Reilly, 2017[cite: 1093].
7. J. Grus. Data Science from Scratch. O'Reilly, 2015[cite: 1094].

Tổng kết: Tiền xử lý và chuẩn bị dữ liệu

- Tiền xử lý dữ liệu là bước quan trọng trong phân tích và khai phá dữ liệu, bao gồm các công việc chính như làm sạch dữ liệu, tích hợp dữ liệu, biến đổi dữ liệu và giảm dữ liệu.
- Các kỹ thuật làm sạch dữ liệu giúp xử lý giá trị thiếu, dữ liệu sai và không nhất quán, cũng như xử lý dữ liệu nhiễu.
- Tích hợp dữ liệu bao gồm các khái niệm như nhận diện thực thể, loại bỏ dư thừa, phân tích tương quan và xử lý trùng lặp dữ liệu.
- Biến đổi dữ liệu bao gồm các kỹ thuật như chuyển đổi dữ liệu, rời rạc hóa, làm trơn dữ liệu, tổng hợp dữ liệu, chuẩn hóa và co giãn dữ liệu.
- Giảm dữ liệu bao gồm các phương pháp như PCA, chọn thuộc tính, histogram, phân cụm, tổng hợp data cube và các phương pháp lấy mẫu dữ liệu.