Hiểu dữ liệu

TS. Trần Hồng Việt

Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội

Mục lục

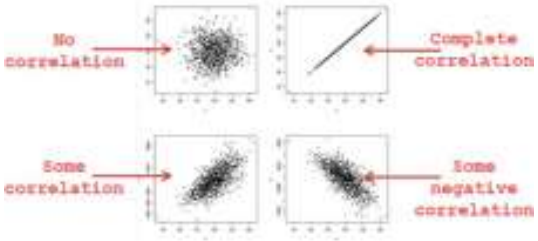
1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Mục lục

1. **Giới thiệu**
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Hãy khám phá dữ liệu trước

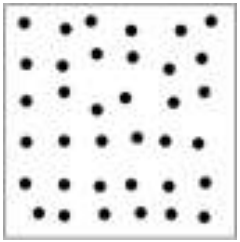
- Hiểu bản chất và đặc điểm của dữ liệu trước tiên.
  - Kiểu dữ liệu
  - Dữ liệu nhiễu, thiếu, mâu thuẫn, mất cân bằng...
  - Tóm tắt dữ liệu (thống kê mô tả)
  - Hình dạng và phân phối dữ liệu
  - Tương quan trong dữ liệu
  - Các phụ thuộc rõ ràng và ẩn trong dữ liệu



- Xây dựng mô hình học máy và học sâu sau đó!

Làm đúng việc hay làm việc đúng?

- Liệu có mối tương quan mạnh giữa đầu vào và mục tiêu?
  - Hiển thị quảng cáo dựa trên sở thích? Tại sao "có" và tại sao "không"?
  - Dự đoán giới tính người dùng dựa trên hành vi đọc?

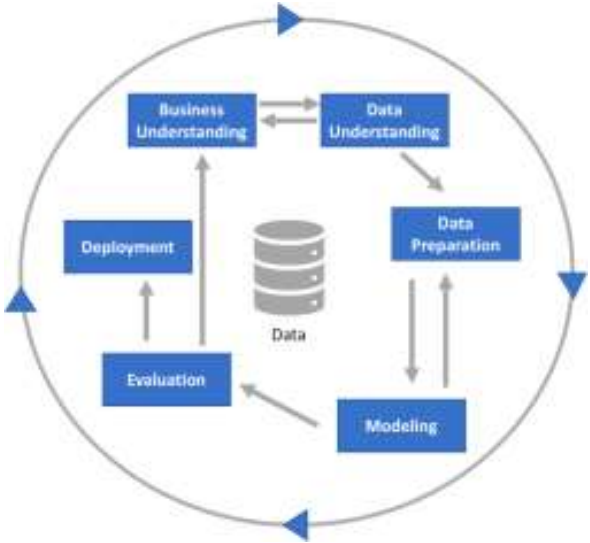


- Phân cụm dữ liệu cho bất kỳ tập dữ liệu nào?
- Phân tích chủ đề cho dữ liệu rất thưa (thiếu các từ cùng xuất hiện)?
- Khai thác mẫu phổ biến từ cơ sở dữ liệu có nhiều mục rất phổ biến?

Quy trình chuẩn liên ngành cho khai phá dữ liệu (CRISP-DM)

- CRISP-DM là mô hình quy trình làm nền tảng cho tiến trình khoa học dữ liệu. Gồm sáu giai đoạn tuần tự:
  1. Hiểu nghiệp vụ
  2. **Hiểu dữ liệu**
  3. Chuẩn bị dữ liệu
  4. Mô hình hóa
  5. Đánh giá
  6. Triển khai
- Được công bố năm 1999, đã trở thành phương pháp luận phổ biến nhất cho các dự án khai phá dữ liệu và khoa học dữ liệu.

Quy trình CRISP-DM



CRISP-DM giai đoạn 1: Hiểu nghiệp vụ

Giai đoạn này tập trung hiểu mục tiêu và yêu cầu dự án. Gồm bốn tác vụ:

1. **Xác định mục tiêu nghiệp vụ:** Hiểu rõ từ góc độ nghiệp vụ khách hàng thực sự muốn đạt được điều gì; định nghĩa tiêu chí thành công.
2. **Đánh giá tình huống:** Xác định tài nguyên, yêu cầu dự án, đánh giá rủi ro và phân tích chi phí-lợi ích.
3. **Xác định mục tiêu khai phá dữ liệu:** Định nghĩa thành công từ góc độ kỹ thuật khai phá dữ liệu.
4. **Lập kế hoạch dự án:** Lựa chọn công nghệ và công cụ, định nghĩa kế hoạch chi tiết.

CRISP-DM giai đoạn 2: Hiểu dữ liệu

Giai đoạn này xác định, thu thập và phân tích các tập dữ liệu. Gồm bốn tác vụ:

1. **Thu thập dữ liệu ban đầu:** Thu thập và nạp vào công cụ phân tích.
2. **Mô tả dữ liệu:** Xem xét và ghi lại các đặc tính bề mặt: định dạng, số bản ghi, thông tin trường.
3. **Khám phá dữ liệu:** Đào sâu vào dữ liệu: truy vấn, trực quan hóa, xác định mối quan hệ.
4. **Xác minh chất lượng dữ liệu:** Dữ liệu sạch hay bẩn? Ghi lại các vấn đề chất lượng.

CRISP-DM giai đoạn 3: Chuẩn bị dữ liệu

Giai đoạn này chuẩn bị dữ liệu cuối cùng cho mô hình hóa. Gồm năm tác vụ:

1. **Chọn dữ liệu:** Xác định tập dữ liệu nào sẽ được dùng và ghi lại lý do.
2. **Làm sạch dữ liệu:** Tác vụ tốn thời gian nhất. Không làm sạch, kết quả sẽ là "rác vào, rác ra".
3. **Xây dựng dữ liệu:** Tạo thuộc tính mới hữu ích (ví dụ: BMI từ chiều cao và cân nặng).
4. **Tích hợp dữ liệu:** Kết hợp dữ liệu từ nhiều nguồn.
5. **Định dạng dữ liệu:** Định dạng lại khi cần (ví dụ: chuỗi số $\rightarrow$ giá trị số).

Mục lục

1. Giới thiệu
2. **Tìm hiểu dữ liệu của bạn**
   - **Thuộc tính dữ liệu**
   - **Dữ liệu đơn biến, song biến và đa biến**
   - **Dữ liệu phức tạp và có cấu trúc**
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Mục lục

1. Giới thiệu
2. **Tìm hiểu dữ liệu của bạn**
   - **Thuộc tính dữ liệu**
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Thuộc tính dữ liệu (Data attribute)

- Một thuộc tính là một trường dữ liệu, biểu diễn một đặc điểm của đối tượng dữ liệu.
- Thường được gọi là:
  - Trường, cột, thuộc tính (trong Cơ sở dữ liệu).
  - Chiều (dimension) trong kho dữ liệu.
  - Biến (variable) trong thống kê.
  - Đặc trưng (feature) trong học máy.
- Ví dụ thuộc tính mô tả sinh viên: `Mã SV`, `Họ tên`, `Giới tính`, `Năm sinh`, `Địa chỉ`, v.v.
- Giá trị quan sát được của một thuộc tính gọi là các *quan sát* (observations).

Kiểu dữ liệu của thuộc tính

- Thuộc tính định danh hoặc phân loại (Nominal / Categorical)
- Thuộc tính nhị phân (Binary)
- Thuộc tính thứ tự (Ordinal)
- Thuộc tính số (Numeric)
  - Thuộc tính định khoảng (Interval-scaled)
  - Thuộc tính định tỷ lệ (Ratio-scaled)
  - Thuộc tính rời rạc và liên tục (Discrete vs. Continuous)

Thuộc tính định danh / phân loại

- Giá trị là các ký hiệu hoặc tên gọi. Mỗi giá trị đại diện cho một danh mục hoặc trạng thái.
- Không có thứ tự và phép toán số học không có ý nghĩa.
- Ví dụ:
  - Nghề nghiệp: giáo viên, bác sĩ, lập trình viên...
  - Màu tóc: đen, nâu, vàng...
  - Mã khách hàng: (CustomerID) dù là số nhưng bản chất là chuỗi ký tự.
- Góc độ thống kê: Không có ý nghĩa khi tính trung bình/trung vị. Có thể tìm **Mode** (giá trị xuất hiện nhiều nhất).

Thuộc tính nhị phân (Binary attributes)

- Là thuộc tính định danh chỉ có hai trạng thái: 0 hoặc 1.
- 0 thường là vắng mặt, 1 là có mặt. Gọi là Boolean nếu là True/False.
- **Đối xứng:** Hai trạng thái có giá trị ngang nhau (ví dụ: Giới tính nam/nữ).
- **Bất đối xứng:** Hai trạng thái không quan trọng như nhau.
  - Ví dụ: Kết quả xét nghiệm HIV (Dương tính/Âm tính).
  - Quy ước mã hóa kết quả quan trọng/hiếm hơn là 1.

Thuộc tính thứ tự (Ordinal attributes)

- Có thứ tự hoặc xếp hạng có ý nghĩa, nhưng không biết độ lớn khoảng cách giữa các giá trị.
- Ví dụ:
  - Kích cỡ: nhỏ, vừa, lớn.
  - Xếp loại: A+, A, B...
  - Đánh giá: 1 (rất không hài lòng) đến 5 (rất hài lòng).
- Có thể thu được từ việc rời rạc hóa các đại lượng số.
- Thống kê: Có thể tìm Mode và Trung vị (Median), nhưng không tính được Trung bình.

Thuộc tính số (Numeric attributes)

- Là đại lượng có thể đo lường và định lượng, biểu diễn bằng số nguyên hoặc số thực.
- Gồm hai loại chính:
  - **Định khoảng (Interval-scaled)**
  - **Định tỷ lệ (Ratio-scaled)**

Thuộc tính định khoảng (Interval-scaled)

- Có các đơn vị đo bằng nhau. Cho phép so sánh sự khác biệt.
- Ví dụ:
  - Nhiệt độ Celsius: 15°C, 30°C... (Không có điểm 0 tuyệt đối: 30°C không nóng gấp đôi 15°C).
  - Năm dương lịch: 1945, 2024...
- Thống kê: Tính được trung bình, trung vị và mode.

Thuộc tính định tỷ lệ (Ratio-scaled)

- Là thuộc tính số có điểm 0 thực sự (điểm gốc).
- Một giá trị là bội số hoặc tỷ lệ của giá trị khác.
- Ví dụ:
  - Lương: 2000 USD gấp đôi 1000 USD.
  - Cân nặng, Chiều cao, Khoảng cách.
- Thống kê: Tính được trung bình, trung vị và mode.

Thuộc tính rời rạc và liên tục

Các thuật toán khai phá thường chia thuộc tính thành hai loại: rời rạc hoặc liên tục. Mỗi loại có thể được xử lý theo những cách khác nhau.

- **Thuộc tính rời rạc (Discrete):** Có tập hợp các giá trị hữu hạn hoặc vô hạn đếm được.
  - Có thể hoặc không được biểu diễn dưới dạng số nguyên.
  - Ví dụ: Màu tóc, Giới tính, Kích thước đồ uống có số lượng giá trị hữu hạn.
  - Có thể có giá trị số: 0 và 1 cho thuộc tính nhị phân; 0 đến 150 cho thuộc tính Tuổi.
- **Vô hạn đếm được:** Nếu tập hợp các giá trị là vô hạn nhưng có thể thiết lập tương ứng 1-1 với tập số tự nhiên. Ví dụ: `CustomerID`.

Thuộc tính rời rạc và liên tục (tiếp theo)

- Nếu một thuộc tính không phải là rời rạc, nó là **thuộc tính liên tục**.
- Trong các tài liệu, thuật ngữ **thuộc tính số (numeric)** và **thuộc tính liên tục (continuous)** thường được sử dụng thay thế cho nhau.
- Điều này có thể gây nhầm lẫn vì theo nghĩa cổ điển:
  - Giá trị liên tục là các số thực (*realnumbers*).
  - Giá trị số có thể là số nguyên (*integers*) hoặc số thực.

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - **Dữ liệu đơn biến, song biến và đa biến**
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Dữ liệu đơn biến (Univariate data)

- Dữ liệu đơn biến là loại dữ liệu chỉ bao gồm các quan sát từ một biến duy nhất (X), tức là một đặc điểm hoặc thuộc tính đơn lẻ.

$$\mathcal{D} = \begin{pmatrix} X \\ \hline x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

- Các kiểu dữ liệu đơn biến bao gồm:
  - **Định danh/Phân loại:** nhị phân, hữu hạn, vô hạn.
  - **Dữ liệu số:** rời rạc, liên tục.

Ví dụ dữ liệu đơn biến

- **Kết quả xét nghiệm Covid-19** (12 người): $D = \{neg, pos, neg, \dots\}$
- **Điểm của một sinh viên** (15 học phần): $D = \{A, A+, B, \dots\}$
- **Số bàn thắng của Messi** (Barcelona 2004-2021): $D = \{1, 8, 17, \dots, 38\}$
- **Nhiệt độ cao trung bình tại Hà Nội** (12 tháng): $D = \{19.7, 20.1, \dots, 22.0\}$
- **Phân tích:** Thống kê mô tả (trung bình, trung vị, yếu vị, phương sai, độ lệch chuẩn).
- **Trực quan hóa:** Bảng phân phối tần suất, biểu đồ cột, biểu đồ tròn, histogram.

Dữ liệu song biến (Bivariate data)

- Dữ liệu song biến gồm các quan sát từ hai biến (X, Y), xem xét hai đặc điểm cùng một lúc.

$$\mathcal{D} = \begin{pmatrix} X & Y \\ \hline x_1 & y_1 \\ x_2 & y_2 \\ \vdots & \vdots \\ x_n & y_n \end{pmatrix}$$

- Tương tự dữ liệu đơn biến, cả X và Y có thể là dữ liệu phân loại hoặc dữ liệu số.
- Mục tiêu chính là tìm hiểu mối quan hệ hoặc sự phụ thuộc giữa hai đại lượng này.

Ví dụ dữ liệu song biến

Ad spend	Revenue
$14,500	$59,000
$19,000	$64,000
$22,400	$89,000
$28,900	$86,000
$30,000	$94,000
$32,000	$104,000
$29,000	$89,000
$28,000	$82,000
$32,000	$88,000
$35,000	$103,000
$29,000	$94,000
$38,000	$140,000

The advertising spend and the total revenue of 12 consecutive quarters

Season	**Apps**	**Goals**
2004-05	9	1
2005-06	25	8
2006-07	36	17
2007-08	40	16
2008-09	51	38
2009-10	53	47
2010-11	55	53
2011-12	60	73
2012-13	50	60
2013-14	46	41
2014-15	57	58
2015-16	49	41
2016-17	52	54
2017-18	54	45
2018-19	50	51
2019-20	44	31
2020-21	47	38

Messi's #apps, #goals for Barcelona

Hours	GPA
6	3.2
9	3.8
10	3.9
13	3.6
6	2.5
5	2.7
7	2.9
19	3.9
20	3.8
14	3.4
10	3.1
7	2.6
4	2.2
8	2.9
4	3.2

The number of hours studied per week and the GPA

Phân tích dữ liệu song biến

- **Xác định mối quan hệ:** Tìm hiểu tương quan (*correlation*), hiệp biến (*association*), hoặc quan hệ nhân quả (*causality*).
- **Hồi quy và Phân loại:**
  - Dự báo giá trị của một biến (biến phụ thuộc Y) nếu biết giá trị của biến kia (biến độc lập X).
  - Suy diễn mối quan hệ nhân quả giữa các biến.
- Phân tích hai biến cũng có thể là mô tả (xu hướng trung tâm, độ biến thiên) hoặc suy diễn (ví dụ, suy ra các đặc tính của một phân phối cơ bản, các đặc tính của một quần thể, v.v.).
- Trực quan hóa hai biến với bảng tần số hai chiều, bảng tỷ lệ hai chiều, biểu đồ cột xếp chồng, biểu đồ cột cạnh nhau, biểu đồ phân tán, biểu đồ chấm, biểu đồ hộp nhóm, biểu đồ tần số nhóm, bản đồ nhiệt, v.v..

Dữ liệu đa biến (Multivariate data)

- Gồm các quan sát từ d biến/thuộc tính $(X_1, X_2, \ldots, X_d)$, xem xét nhiều đặc điểm cùng lúc.

$$\mathcal{D} = \begin{pmatrix} X_1 & X_2 & \cdots & X_d \\ x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

- Thực tế đây là một ma trận $n \times d$:
  - Mỗi hàng là một vectơ thuộc tính: $x_i = (x_{i1}, x_{i2}, \ldots, x_{id})^T$ đại diện cho một điểm trong không gian d chiều.
- Các biến thành phần có thể là định danh hoặc số.

- Vector trung bình đa biến:

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}] = \begin{pmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_d] \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_d \end{pmatrix}$$

- Ma trận hiệp phương sai:

$$\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_d^2 \end{pmatrix}$$

- Phân loại, hồi quy, phân cụm, khai thác kết hợp, v.v.
- Trực quan hóa: nhiều cách và công cụ.

Dữ liệu IID (Độc lập và Phân phối chuẩn)

- **Định nghĩa:** Tất cả quan sát trong mẫu dữ liệu được giả định là độc lập (*Independent*) và có cùng phân phối (*IdenticallyDistributed*).
- Các loại dữ liệu đơn biến, song biến, đa biến thông thường đều giả định là IID.
- **Trong thực tế:** Giả định IID thường rất mạnh. Dữ liệu thường có các phụ thuộc rõ ràng hoặc ngầm định.
- **Các loại phụ thuộc:** Thời gian (*temporal*), không gian (*spatial*), cấu trúc (*structural*/*links*).
- Dữ liệu có phụ thuộc được gọi là **dữ liệu phức tạp và có cấu trúc**.

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - **Dữ liệu phức tạp và có cấu trúc**
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Dữ liệu phức tạp và có cấu trúc

Các dạng dữ liệu phổ biến:

- Dữ liệu chuỗi thời gian ($Time - seriesdata$)
- Chuỗi rời rạc và chuỗi ký tự ($Discretesequencesandstrings$)
- Dữ liệu không gian ($Spatialdata$)
- Dữ liệu không-thời gian ($Spatiotemporaldata$)
- Dữ liệu mạng và đồ thị ($Networkandgraphdata$)

Dữ liệu chuỗi thời gian (Time-series data)

- Chứa các giá trị được tạo ra bởi việc đo lường liên tục theo thời gian.
- Ví dụ: Cảm biến môi trường đo nhiệt độ liên tục, điện tâm đồ (ECG) đo nhịp tim.
- Dữ liệu như vậy thường có các phụ thuộc ngầm được xây dựng trong các giá trị nhận được theo thời gian. Ví dụ, các giá trị liền kề được ghi lại bởi cảm biến nhiệt độ thường thay đổi một cách mượt mà theo thời gian, và yếu tố này cần được sử dụng một cách rõ ràng trong quá trình khai thác dữ liệu.
- Bản chất của sự phụ thuộc theo thời gian có thể thay đổi đáng kể tùy thuộc vào ứng dụng. Ví dụ, một số dạng dữ liệu cảm biến có thể cho thấy các mẫu chu kỳ của thuộc tính được đo theo thời gian.

Dữ liệu chuỗi thời gian (Time-series data) (tiếp)

- Các thuộc tính trong dữ liệu theo chuỗi thời gian được phân thành hai loại:
  - **Thuộc tính ngữ cảnh (Contextual):** Đây là những thuộc tính xác định ngữ cảnh mà dựa vào đó các phụ thuộc ngầm xảy ra trong dữ liệu. Ví dụ, trong trường hợp dữ liệu cảm biến, dấu thời gian khi giá trị đo được có thể được coi là thuộc tính ngữ cảnh. Đôi khi, dấu thời gian không được sử dụng một cách rõ ràng, mà thay vào đó một chỉ số vị trí được sử dụng.
  - **Thuộc tính hành vi (Behavioral):** Chúng đại diện cho các giá trị được đo trong một bối cảnh cụ thể. Trong ví dụ về cảm biến, nhiệt độ là giá trị thuộc tính hành vi. Có thể có nhiều hơn một thuộc tính hành vi. Ví dụ, nếu nhiều cảm biến ghi nhận các phép đo tại các mốc thời gian đồng bộ, thì điều này dẫn đến một tập dữ liệu chuỗi thời gian đa chiều.
- Các thuộc tính ngữ cảnh thường có ảnh hưởng mạnh đến các mối phụ thuộc giữa các giá trị thuộc tính hành vi trong dữ liệu.

Định nghĩa chuỗi thời gian đa biến

- Một chuỗi thời gian có độ dài n và số chiều d bao gồm d đặc trưng số tại mỗi mốc trong số n mốc thời gian $t_1, t_2, \ldots, t_n$. Tại mỗi mốc thời gian t_i, dữ liệu chứa một thành phần cho mỗi chuỗi trong số d chuỗi thành phần, do đó tập hợp các giá trị nhận được được ký hiệu là $\bar{Y}_i = (y_i^1, y_i^2, \ldots, y_i^d)$, trong đó y_i^j là giá trị của chuỗi thứ j tại thời điểm i. Toàn bộ tập dữ liệu chuỗi thời gian được biểu diễn dưới dạng tập hợp $\{\bar{Y}_1, \bar{Y}_2, \ldots, \bar{Y}_n\}$.
- Ví dụ, hãy xem xét trường hợp hai cảm biến tại một vị trí nhất định theo dõi nhiệt độ và áp suất mỗi giây trong một phút. Điều này tương ứng với một chuỗi đa chiều với d = 2 và n = 60. Trong một số trường hợp, các dấu thời gian t1, t2, ..., tn có thể được thay thế bằng các giá trị chỉ số từ 1 đến n, đặc biệt khi các giá trị dấu thời gian được chia đều.
- Phổ biến trong ứng dụng cảm biến, y tế, dự báo thời tiết và phân tích thị trường tài chính.

Chuỗi rời rạc và chuỗi ký tự

- Các dãy rời rạc có thể được xem như là tương tự loại danh mục của dữ liệu chuỗi thời gian. Giống như trong trường hợp dữ liệu chuỗi thời gian, thuộc tính bối cảnh là một dấu thời gian hoặc chỉ số vị trí trong thứ tự. Thuộc tính hành vi là một giá trị danh mục;
- Do đó, dữ liệu tuần tự rời rạc được định nghĩa theo cách tương tự như dữ liệu chuỗi thời gian.
- **Chuỗi rời rạc đa biến:** Một chuỗi rời rạc có độ dài n và số chiều d bao gồm d giá trị thuộc tính rời rạc tại mỗi trong n mốc thời gian $t_1, t_2, \ldots, t_n$. Mỗi thành phần $\bar{Y}_i$ tương ứng với thời điểm t_i là một vectơ d chiều gồm các thuộc tính hành vi rời rạc $(y_i^1, y_i^2, \ldots, y_i^d)$ được thu thập tại thời điểm thứ i.

Chuỗi rời rạc và chuỗi ký tự (tiếp theo)

- Ví dụ, hãy xem xét một chuỗi các truy cập Web, trong đó địa chỉ trang Web và địa chỉ IP nguồn của yêu cầu được thu thập cho 100 lượt truy cập khác nhau. Điều này đại diện cho một chuỗi rời rạc có độ dài $n = 100$ và độ chiều $d = 2$.
- Một trường hợp đặc biệt phổ biến trong dữ liệu chuỗi là kịch bản đơn biến, trong đó giá trị của d bằng 1. Dữ liệu chuỗi như vậy cũng được gọi là chuỗi ký tự.
- Về lý thuyết, có thể có các chuỗi dữ liệu pha trộn giữa dữ liệu phân loại và dữ liệu số.
- Một biến thể quan trọng khác là trường hợp mà một chuỗi không chứa các thuộc tính phân loại, mà là một tập hợp bất kỳ số lượng giá trị phân loại không theo thứ tự nào. Ví dụ, các giao dịch siêu thị có thể chứa một chuỗi các tập hợp mặt hàng. Mỗi tập hợp có thể chứa bất kỳ số lượng mặt hàng nào. Các chuỗi theo tập hợp như vậy thực ra không phải là các chuỗi đa biến, mà là các chuỗi đơn biến.
- Thus, discrete sequences can be defined in a wider variety of ways, as compared to time–series data because of the ability to define sets on discrete elements.

Chuỗi rời rạc và chuỗi ký tự (tiếp theo)

- Trong một số trường hợp, thuộc tính ngữ cảnh có thể là một vị trí dựa trên vị trí vật lý. Trong những trường hợp như vậy, dấu thời gian có thể được thay thế bằng một chỉ số đại diện cho vị trí của giá trị trong chuỗi, bắt đầu từ 0 hoặc 1. Ví dụ:
  - Nhật ký sự kiện: Một loạt các hệ thống máy tính, máy chủ Web tạo nhật ký sự kiện dựa trên hoạt động của người dùng. Một ví dụ về nhật ký sự kiện là một chuỗi các hành động của người dùng trên một trang Web tài chính: Mật khẩu đăng nhập Mật khẩu đăng nhập Mật khẩu đăng nhập ... Chuỗi cụ thể này có thể đại diện cho một kịch bản trong đó người dùng đang cố gắng xâm nhập vào một hệ thống được bảo vệ bằng mật khẩu, và nó có thể thú vị trong việc phát hiện bất thường.
  - Dữ liệu sinh học: Trong trường hợp này, các chuỗi có thể tương ứng với các chuỗi nucleotide hoặc amino acid. Việc sắp xếp các đơn vị như vậy cung cấp thông tin về đặc điểm chức năng của protein. Do đó, khai thác dữ liệu có thể được sử dụng để xác định các mẫu thú vị phản ánh các đặc tính sinh học khác nhau.
- Các chuỗi rời rạc thường khó khăn hơn đối với các thuật toán khai thác vì chúng không có tính liên tục giá trị mượt mà như dữ liệu chuỗi thời gian.

Dữ liệu không gian (Spatial data)

- Trong dữ liệu không gian, nhiều thuộc tính phi không gian (ví dụ: nhiệt độ, áp suất, cường độ màu pixel) được đo tại các vị trí không gian cụ thể.
- Ví dụ, nhiệt độ bề mặt biển thường được các nhà khí tượng học thu thập để dự báo sự hình thành của bão. Trong trường hợp này, tọa độ không gian đóng vai trò là thuộc tính ngữ cảnh, còn các đại lượng như nhiệt độ là thuộc tính hành vi.
- Thông thường có hai thuộc tính không gian (tọa độ). Tương tự dữ liệu chuỗi thời gian, có thể tồn tại nhiều thuộc tính hành vi. Ví dụ, ngoài nhiệt độ bề mặt biển, có thể đo thêm các đại lượng khác như áp suất.

Dữ liệu không gian d chiều

Một bản ghi không gian d chiều chứa d thuộc tính hành vi và một hoặc nhiều thuộc tính ngữ cảnh chứa vị trí không gian. Tập dữ liệu không gian là tập n bản ghi $\bar{X}_1, \bar{X}_2, \ldots, \bar{X}_n$ cùng với n vị trí $L_1, L_2, \ldots, L_n$, trong đó $\bar{X}_i$ liên kết với vị trí L_i.

- Định nghĩa này cho phép linh hoạt trong cách xác định $\bar{X}_i$ và L_i.
- **Ví dụ:** Thuộc tính hành vi có thể là số, phân loại hoặc hỗn hợp. Trong ứng dụng khí tượng, $\bar{X}_i$ có thể chứa nhiệt độ và áp suất tại vị trí L_i.
- L_i có thể được xác định bằng tọa độ chính xác (kinh độ/vĩ độ) hoặc vị trí logic (thành phố, tiểu bang).

Dữ liệu không gian (tiếp theo)

- Khai phá dữ liệu không gian liên quan chặt chẽ đến khai phá chuỗi thời gian, vì thuộc tính hành vi trong hầu hết các ứng dụng không gian đều là liên tục (một số dùng thuộc tính phân loại).
- Do đó, tính liên tục giá trị được quan sát giữa các vị trí không gian liền kề, tương tự như tính liên tục giá trị theo thời gian trong chuỗi thời gian.

Dữ liệu không gian–thời gian (Spatiotemporal data)

- Dữ liệu không gian–thời gian là dạng đặc biệt của dữ liệu không gian, chứa cả thuộc tính không gian lẫn thời gian.
- **Hai dạng phổ biến nhất:**
  - **Cả không gian lẫn thời gian đều là ngữ cảnh:** Dạng này hữu ích khi đồng thời đo động lực không gian và thời gian của thuộc tính hành vi. Ví dụ: đo biến động nhiệt độ bề mặt biển theo thời gian – nhiệt độ là hành vi, các thuộc tính không gian và thời gian là ngữ cảnh.
  - **Thời gian là ngữ cảnh, không gian là hành vi:** Dạng này có thể coi là dữ liệu chuỗi thời gian. Bản chất không gian của thuộc tính hành vi cho khả năng phân tích tập trung hơn. Dạng phổ biến nhất xuất hiện trong phân tích quỹ đạo (trajectory analysis).

- Trong dữ liệu mạng và đồ thị, các giá trị dữ liệu tương ứng với các nút, còn quan hệ giữa chúng tương ứng với các cạnh.
- Thuộc tính có thể được liên kết với nút (phổ biến) hoặc cạnh (ít phổ biến hơn).

Dữ liệu mạng

Mạng $G = (N, E)$ chứa tập nút N và tập cạnh E, trong đó các cạnh trong E biểu diễn mối quan hệ giữa các nút. Thuộc tính $\bar{X}_i$ có thể liên kết với nút i, hoặc $\bar{Y}_{ij}$ liên kết với cạnh (i, j).

Dữ liệu mạng và đồ thị (tiếp theo)

- Cạnh (i, j) có thể có hướng hoặc không có hướng. Ví dụ: đồ thị web có cạnh có hướng (hyperlink); bạn bè trên Facebook không có hướng.
- **Một số ví dụ dữ liệu dạng đồ thị:**
  - **Đồ thị web:** Nút là trang web, cạnh là hyperlink. Nút có thuộc tính văn bản tương ứng nội dung trang.
  - **Mạng xã hội:** Nút là người dùng, cạnh là liên kết bạn bè. Các dạng đặc biệt: mạng email, chat messenger.
  - **Cơ sở dữ liệu hợp chất:** Nút là nguyên tố, cạnh là liên kết hóa học. Rất hữu ích để xác định tính chất dược lý.

Dữ liệu mạng và đồ thị (tiếp theo)

- Dữ liệu mạng là biểu diễn rất tổng quát và có thể được dùng cho nhiều ứng dụng dựa trên độ tương đồng các kiểu dữ liệu khác.
- **Ví dụ:** Dữ liệu đa chiều có thể chuyển thành dữ liệu mạng bằng cách tạo một nút cho mỗi bản ghi và biểu diễn độ tương đồng bằng các cạnh – phương pháp này phổ biến trong phân tích cụm.
- Có thể ứng dụng các thuật toán phát hiện cộng đồng để xác định các cụm trong dữ liệu mạng, rồi ánh xạ trở lại dữ liệu đa chiều.

Các dạng dữ liệu khác

- **Dữ liệu văn bản (Text data):** Xem như chuỗi rời rạc; mỗi phần tử là một từ hoặc token.
- **Dữ liệu ngôn ngữ tự nhiên (Natural language):** Xem như chuỗi rời rạc; mỗi phần tử có thể là ký tự, token, từ, cụm từ, câu, đoạn văn.
- **Dữ liệu giọng nói (Speech data):** Xem như chuỗi rời rạc hoặc chuỗi thời gian.
- **Dữ liệu hình ảnh (Image data):** Xem như dữ liệu không gian.
- **Dữ liệu video (Video data):** Xem như chuỗi rời rạc hoặc chuỗi thời gian, trong đó mỗi phần tử là một khung hình (frame).

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. **Thống kê mô tả dữ liệu**
   - **Đo xu hướng trung tâm**
   - **Đo độ phân tán**
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. **Thống kê mô tả dữ liệu**
   - **Đo xu hướng trung tâm**
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Đo xu hướng trung tâm của dữ liệu

- Giả sử $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ là một mẫu dữ liệu (dữ liệu đơn biến) gồm n quan sát của biến X.
- Nếu biểu diễn các quan sát trong $\mathcal{D}$, hầu hết các giá trị sẽ rơi vào khu vực nào? Đây cho ta ý tưởng về xu hướng trung tâm của dữ liệu.
- **Các độ đo xu hướng trung tâm bao gồm:**
  - **Trung bình (Mean)**
  - **Trung vị (Median)**
  - **Yếu vị (Mode)**
  - **Trung điểm (Midrange)**

Mean (Trung bình)

- Trung bình (mean) là thước đo phổ biến và hiệu quả nhất để xác định "tâm" của một tập dữ liệu, còn gọi là giá trị trung bình cộng.
- Trung bình của tập $D = \{x_1, x_2, \ldots, x_n\}$, ký hiệu $\bar{x}$:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- Ví dụ:
  - Bàn thắng của Messi:

$$D = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$$

$$\bar{x} = \frac{672}{17} \approx 39.53$$

  - Lương (nghìn USD):

$$D = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$$

$$\bar{x} = \frac{840}{12} = 70$$

Trung bình có trọng số (Weighted mean)

- Đôi khi mỗi giá trị x_i trong $\mathcal{D}$ được gán một trọng số w_i $(i = 1..n)$. Trọng số phản ánh mức độ quan trọng, ý nghĩa hoặc tần suất xuất hiện của giá trị.
- Trong trường hợp này, trung bình có trọng số là:

$$\bar{x} = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n} \quad (1)$$

Trung bình và hạn chế của nó

- Mặc dù trung bình là đại lượng nổi tiếng nhất để mô tả một mẫu dữ liệu, nó không phải luôn là cách tốt nhất để đo xu hướng trung tâm.
- **Vấn đề chính:** Trung bình **rất nhạy cảm với các giá trị cực đoan (ngoại lệ)**. Chỉ cần một vài giá trị cực đoan cũng có thể làm sai lệch trung bình đáng kể.
- **Ví dụ:** Trung bình lương ($\bar{x} = 70$) bị đẩy lên bởi một vài quản lý lương cao ($110k, $215k).
- **Trung bình cắt xén (Trimmed mean):** Trung bình tính sau khi loại các giá trị cực đoan ở hai đầu (ví dụ: loại 2% trên và dưới).

Trung vị (Median)

- Với dữ liệu lệch (không đối xứng), độ đo tốt hơn là **trung vị**.
- Trung vị là giá trị ở giữa trong tập dữ liệu đã sắp xếp – giá trị phân chia nửa trên và nửa dưới của tập dữ liệu.
- Cho $\mathcal{D}' = \{x'_1, x'_2, \ldots, x'_n\}$ là $\mathcal{D}$ đã sắp xếp tăng dần:
  - Nếu n lẻ: Trung vị là giá trị giữa.
  - Nếu n chẵn: Trung vị là trung bình của hai giá trị giữa.
- Nếu n là số lẻ, thì trung vị là giá trị chính giữa của D. Nếu n là số chẵn, thì trung vị không duy nhất; đó là hai giá trị ở giữa nhất và bất kỳ giá trị nào nằm giữa chúng. Nếu X là một thuộc tính số trong trường hợp này, theo quy ước, trung vị được lấy là trung bình cộng của hai giá trị ở giữa nhất.

Trung vị (tiếp theo)

- Nếu X là thuộc tính số, trung vị là:

$$\text{median} = \frac{x'_a + x'_b}{2} \tag{2}$$

- Trong đó $a = \lceil n/2 \rceil$ và $b = \lfloor n/2 + 1 \rfloor$.
- **Ví dụ:**
  - Số bàn thắng của Messi cho Barcelona từ mùa 2004–2005 đến 2020–2021:
    $D = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$,
    $D' = \{1, 8, 16, 17, 31, 38, 38, 41, 41, 45, 47, 51, 53, 54, 58, 60, 73\}$
    $(n = 17)$: $x'_9 = 41$
  - Mức lương (nghìn USD) của 12 nhân viên (đã sắp xếp tăng dần):
    $D = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$. Median $= \frac{52 + 56}{2} = 54$ (hợp lý hơn so với $\bar{x} = 70$).

Yếu vị (Mode)

- Yếu vị (mode) là một thước đo khác của xu hướng trung tâm.
- Yếu vị của một tập dữ liệu là giá trị xuất hiện với tần suất cao nhất trong tập. Do đó, nó có thể được xác định cho cả dữ liệu định tính và định lượng.
- Có thể tồn tại nhiều giá trị cùng đạt tần suất lớn nhất, dẫn đến nhiều yếu vị. Khi đó, tập dữ liệu được gọi là:
  - **Unimodal**: 1 yếu vị
  - **Bimodal**: 2 yếu vị
  - **Trimodal**: 3 yếu vị
  - Tổng quát: **Multimodal**
- Nếu mỗi giá trị chỉ xuất hiện một lần thì không tồn tại yếu vị.
- Ví dụ:
  - Bàn thắng của Messi: $\{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\} \Rightarrow$ mode $= 38$ hoặc 41 (bimodal)
  - Lương (nghìn USD): $\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\} \Rightarrow$ mode $= 52$
  - Điểm sinh viên: $\{A, A^+, B, B, A, B^+, A^+, A, B, C, C, A, B^+, B, A\} \Rightarrow$ mode $= A$

Trung điểm phạm vi (Midrange)

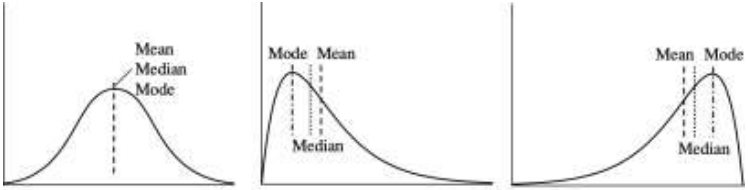
- Midrange là một thước đo xu hướng trung tâm của dữ liệu số, được tính bằng trung bình của giá trị nhỏ nhất và lớn nhất trong tập dữ liệu.
- Ví dụ: lương (nghìn USD) của 12 nhân viên:

$$D = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$$

$$\text{midrange} = \frac{30 + 215}{2} = 122.5$$

- Midrange bị ảnh hưởng mạnh bởi các giá trị ngoại lai (outliers), thậm chí còn nhạy hơn cả mean.

Trung bình, trung vị và mode với dữ liệu lệch



(Giá trị trung bình, trung vị và mode của dữ liệu đối xứng so với dữ liệu lệch phải và lệch trái)

- **Phân phối đối xứng:** trung bình = trung vị = mode.
- **Phân phối lệch phải:** mode < trung vị < trung bình.
- **Phân phối lệch trái:** mode > trung vị > trung bình.

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. **Thống kê mô tả dữ liệu**
   - Đo xu hướng trung tâm
   - **Đo độ phân tán**
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Đo độ phân tán của dữ liệu

1. Khoảng giá trị (Range)
2. Lượng phân vị (Quantiles)
3. Tứ phân vị (Quartiles)
4. Khoảng tứ phân vị (Interquartile range)
5. Tóm tắt năm số (Five-number summary)
6. Biểu đồ hộp (Boxplots)
7. Giá trị ngoại lệ (Outliers)
8. Phương sai và độ lệch chuẩn (Variance and standard deviation)

Khoảng giá trị (Range)

- Cho $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ là dữ liệu đơn biến gồm n quan sát từ biến số X.
- Khoảng giá trị của $\mathcal{D}$ là hiệu giữa giá trị lớn nhất và nhỏ nhất:

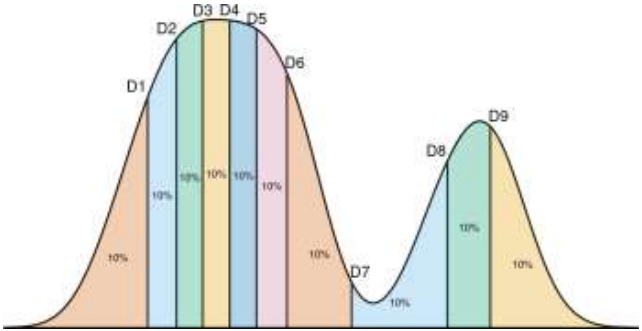
$$\text{Range} = \max(\mathcal{D}) - \min(\mathcal{D})$$

- **Ví dụ:**
  - Bàn thắng của Messi (2004–2021):
    $\mathcal{D} = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$
    $\text{Range} = 73 - 1 = 72$
  - Lương (nghìn \$) của 12 nhân viên:
    $\mathcal{D} = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$
    $\text{Range} = 215 - 30 = 185$

Lượng phân vị (Quantiles)

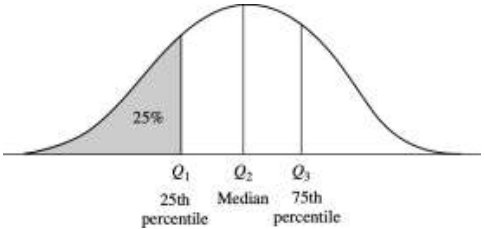
- Giả sử các điểm dữ liệu trong $\mathcal{D}$ đã được sắp xếp tăng dần. Các lượng phân vị là các điểm chia $\mathcal{D}$ thành các phần có kích thước bằng nhau.
- Hãy tưởng tượng rằng chúng ta có thể chọn một số điểm dữ liệu nhất định để chia D thành các tập/phần liên tiếp có kích thước bằng nhau.
- Những điểm dữ liệu này được gọi là các phân vị. Phân vị là các điểm được lấy theo khoảng đều trên một mẫu dữ liệu, chia nó thành các tập/phần liên tiếp về cơ bản có kích thước bằng nhau.
- Lượng phân vị thứ k của phân vị q là giá trị x sao cho tối đa k/q giá trị nhỏ hơn x và tối đa $(q-k)/q$ giá trị lớn hơn x, với $0 < k < q$. Có $q-1$ lượng phân vị q.
- **Các lượng phân vị phổ biến:**
  - **Tứ phân vị (4-quantile / Quartiles):** 3 giá trị chia dữ liệu thành 4 phần.
  - **Thập phân vị (10-quantile / Deciles):** 9 giá trị chia thành 10 phần.
  - **Bách phân vị (100-quantile / Percentiles):** 99 giá trị chia thành 100 phần.

Thập phân vị (10-quantiles hay Deciles)



Thập phân vị (deciles) gồm 9 giá trị $(D_1, D_2, \ldots, D_9)$ *chia phân phối dữ liệu thành 10 phần có kích thước bằng nhau.*

Tứ phân vị (Quartiles)



Tứ phân vị chia phân phối thành bốn phần có kích thước bằng nhau [**?**]

- Tứ phân vị gồm ba giá trị (Q_1, Q_2, Q_3) chia phân phối thành bốn phần bằng nhau.
- Q_1 tương ứng bách phân vị thứ 25.
- Q_2 tương ứng bách phân vị thứ 50, tức là **trung vị**.
- Q_3 tương ứng bách phân vị thứ 75.

Khoảng tứ phân vị (IQR)

- Khoảng cách giữa tứ phân vị thứ nhất và thứ ba là độ đo phân tán đơn giản, cho biết khoảng mà nửa giữa dữ liệu bao phủ. Đó gọi là **khoảng tứ phân vị (IQR)**:

$$IQR = Q_3 - Q_1 \tag{9}$$



- **Ví dụ:** Lương 12 nhân viên: $\mathcal{D} = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$
$Q_1 = \$47,000$, $Q_3 = \$62,000$, $IQR = \$62,000 - \$47,000 = \$15,000$

Tóm tắt năm số (Five-number summary)

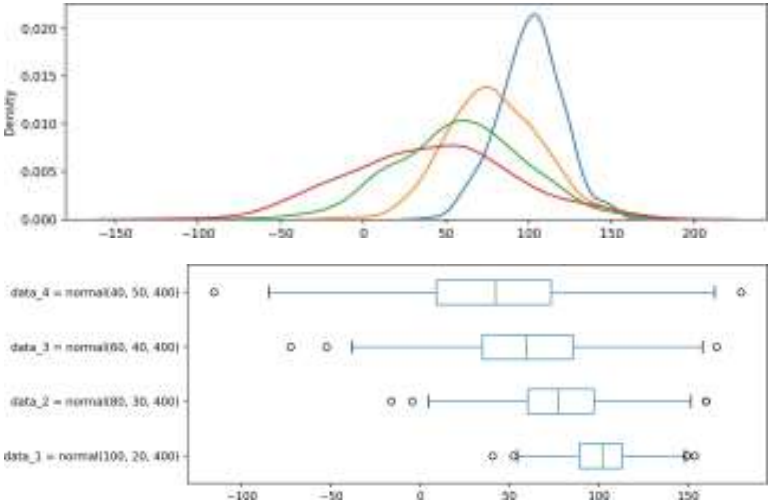
- Không có một độ đo phân tán đơn lẻ nào đủ để mô tả phân phối lệch.
- Do đó, sẽ cung cấp nhiều thông tin hơn nếu cũng đưa ra hai tứ phân vị Q1 và Q3, cùng với trung vị.
- Bởi vì Q1, trung vị và Q3 cùng nhau không chứa thông tin về các điểm cuối (ví dụ, đuôi) của dữ liệu, một bản tóm tắt đầy đủ hơn về hình dạng của một phân phối có thể được thu được bằng cách cung cấp cả giá trị dữ liệu thấp nhất và cao nhất.
- Điều này được biết đến như là tóm tắt năm số. Tóm tắt năm số của một phân phối bao gồm trung vị (Q2), các tứ phân vị Q1 và Q3, và các quan sát cá nhân nhỏ nhất và lớn nhất, được viết theo thứ tự của
- Đây gọi là **tóm tắt năm số**:

$$\{\text{Nhỏ nhất},\ Q_1,\ \text{Trung vị},\ Q_3,\ \text{Lớn nhất}\}$$

Biểu đồ hộp (Boxplots)

- Boxplot là cách trực quan hóa phổ biến cho một phân phối, sử dụng tóm tắt năm số:
  - Hai đầu hộp chính là Q_1 và Q_3, chiều dài hộp bằng IQR.
  - Trung vị được đánh dấu bằng đường thẳng trong hộp.
  - Hai "râu" (whiskers) kéo ra ngoài hộp tới phía giá trị nhỏ nhất và lớn nhất.
- **Boxplot với ngoại lệ:**
  - Râu chỉ kéo tới các quan sát nếu chúng nằm trong phạm vi $1.5 \times IQR$ tính từ tứ phân vị.
  - Nếu không, râu dừng lại tại quan sát gần nhất trong phạm vi $1.5 \times IQR$.
  - Các điểm vượt ra ngoài được vẽ riêng là **ngoại lệ**.

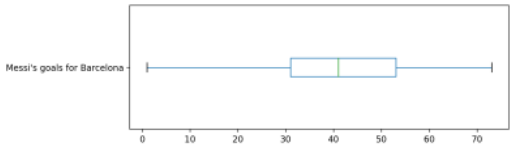
Ví dụ biểu đồ hộp



Ví dụ biểu đồ hộp – Bàn thắng của Messi

Các bàn thắng của Messi cho Barcelona từ 2004–2005 đến 2020–2021:

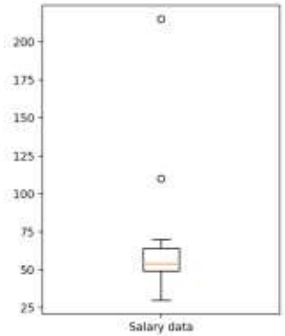
- $\mathcal{D} = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$
- $\mathcal{D}' = \{1, 8, 16, 17, 31, 38, 38, 41, 41, 45, 47, 51, 53, 54, 58, 60, 73\}$



- Nhỏ nhất $= 1$
- $Q_1 = 31$
- Trung vị $(Q_2) = 41$
- $Q_3 = 53$
- Lớn nhất $= 73$

Ví dụ biểu đồ hộp – Lương nhân viên

Salary (in \$k) of 12 employees in a company:
$\mathcal{D} = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$



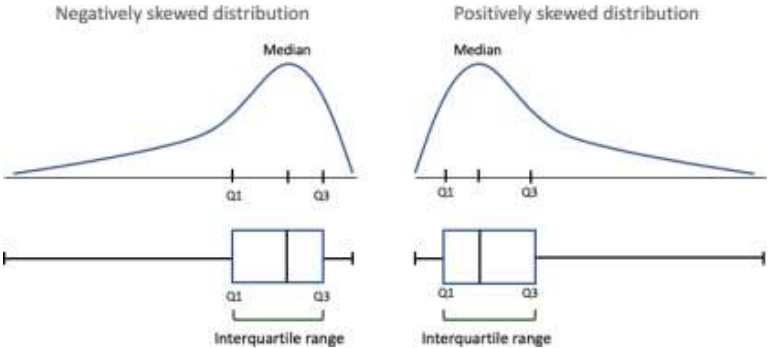
- $Minimum = \$30,000$
- $Q_1 = \$48,500$
- $Median\ (Q_2) = \$54,000$
- $Q_3 = \$66,000$
- $Maximum = \$215,000$
- $IQR = Q_3 - Q_1 = \$17,500$
- $1.5 \times IQR = \$26,250$
- $Outliers$ are 110 and 215

Biểu đồ hộp hữu ích ở điểm nào?

- Biểu đồ hộp (boxplot) giúp trực quan hóa:
  - **Xu hướng trung tâm**: thể hiện qua vị trí của trung vị (median).
  - **Độ phân tán**: thể hiện qua chiều dài của hộp (IQR).
  - **Độ lệch (skewness)**: dựa vào vị trí của hộp so với giá trị nhỏ nhất và lớn nhất.
  - **Giá trị ngoại lai (outliers)**:

$$x < Q_1 - 1.5 \times IQR \quad \text{hoặc} \quad x > Q_3 + 1.5 \times IQR$$

Biểu đồ hộp biểu diễn dữ liệu lệch



Boxplot cho phân phối lệch trái và lệch phải

Phương sai và độ lệch chuẩn

- Phương sai và độ lệch chuẩn cho biết dữ liệu trải rộng đến mức nào.
- Độ lệch chuẩn nhỏ nghĩa là dữ liệu tập trung gần trung bình; lớn nghĩa là dữ liệu trải rộng.
- Cho $\mathcal{D} = \{x_1, \ldots, x_n\}$ với trung bình $\bar{x}$. **Phương sai** σ^2:

$$\sigma^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \left(\frac{1}{n}\sum_{i=1}^{n}x_i^2\right) - \bar{x}^2 \tag{10}$$

- **Độ lệch chuẩn** σ là căn bậc hai của phương sai: $\sigma = \sqrt{\sigma^2}$

Ví dụ: Phương sai và độ lệch chuẩn

- **Lương (nghìn USD) của 12 nhân viên** (tăng dần):

$$D = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}, \quad \bar{x} = 70$$

$$\sigma^2 = \frac{1}{12} \sum x_i^2 - \bar{x}^2 \approx 2276.5$$

$$\sigma \approx \sqrt{2276.5} \approx 47.71$$

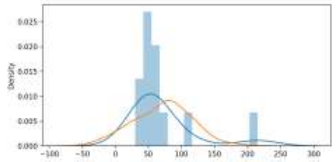
- **Bàn thắng của Messi** (2004–2005 đến 2020–2021):

$$D = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}, \quad \bar{x} \approx 39.53$$

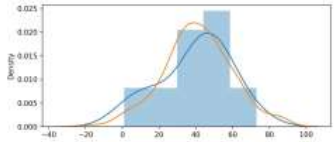
$$\sigma^2 = \frac{1}{17} \sum x_i^2 - \bar{x}^2 \approx 359.38$$

$$\sigma \approx \sqrt{359.38} \approx 18.96$$

Phân phối mẫu và phân phối suy diễn



Lương: đường xanh – mẫu; đường vàng – chuẩn $\mathcal{N}(70, 47.71)$.



Messi: đường xanh – mẫu thực; đường vàng – chuẩn $\mathcal{N}(39.53, 18.96)$.

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. **Mối quan hệ trong dữ liệu**
   - **Tương quan và hệ số tương quan Pearson**
   - **Tương quan hàng Spearman**
   - **Kiểm định chi-square Pearson cho dữ liệu định danh**
   - **Tương quan và quan hệ nhân quả**
5. Bài tập, Tài liệu tham khảo và Tổng kết

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. **Mối quan hệ trong dữ liệu**
   - **Tương quan và hệ số tương quan Pearson**
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Tương quan (Correlation)

- Tương quan phản ánh cường độ và chiều hướng liên kết giữa hai biến ngẫu nhiên (dữ liệu song biến).
  - **Tương quan dương:** Hai biến thay đổi cùng chiều.
  - **Tương quan âm:** Hai biến thay đổi ngược chiều.
  - **Tương quan bằng 0:** Không có mối quan hệ tuyến tính.
- **Tương quan Pearson**: Đo mức độ tương quan tuyến tính. Hoạt động tốt khi quan hệ là tuyến tính và dữ liệu xấp xỉ chuẩn.
- Pearson nhạy cảm với ngoại lệ. Nếu dữ liệu có ngoại lệ hoặc phi tuyến, nên dùng **tương quan hạng Spearman**.

Hệ số tương quan Pearson (tổng thể)

- Hệ số tương quan Pearson giữa hai biến X và Y được định nghĩa là hiệp phương sai của chúng chia cho tích độ lệch chuẩn:

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y}$$

- Trong đó:
  - $\text{cov}(X, Y)$: hiệp phương sai giữa X và Y, độ lệch chuẩn của X, độ lệch chuẩn của Y
- Vì:

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

nên ta có:

$$\rho_{XY} = \frac{\mathbb{E}[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

- Trong đó:
  - μ_X, μ_Y: giá trị trung bình của X, Y
  - $\mathbb{E}$: kỳ vọng

Hệ số tương quan Pearson (tổng thể) – tiếp

- Because:
  - $\mu_X = \mathbb{E}[X]$
  - $\mu_Y = \mathbb{E}[Y]$
  - $\sigma_X^2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$
  - $\sigma_Y^2 = \mathbb{E}[(Y - \mathbb{E}[Y])^2] = \mathbb{E}[Y^2] - (\mathbb{E}[Y])^2$
  - $\mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$
    $= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$
- Then:

$$\rho_{XY} = \frac{\mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]}{\sqrt{\mathbb{E}[X^2] - (\mathbb{E}[X])^2}\sqrt{\mathbb{E}[Y^2] - (\mathbb{E}[Y])^2}} \tag{13}$$

Hệ số tương quan Pearson (mẫu)

- Xét dữ liệu song biến D_{xy} gồm n cặp (x_i, y_i) từ hai biến X, Y.

$$\mathcal{D}_{xy} = \begin{pmatrix} X & Y \\ \hline x_1 & y_1 \\ x_2 & y_2 \\ \vdots & \vdots \\ x_n & y_n \end{pmatrix}$$

- Hệ số tương quan Pearson mẫu:

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

- Trong đó $\bar{x}, \bar{y}$ là giá trị trung bình của X và Y.

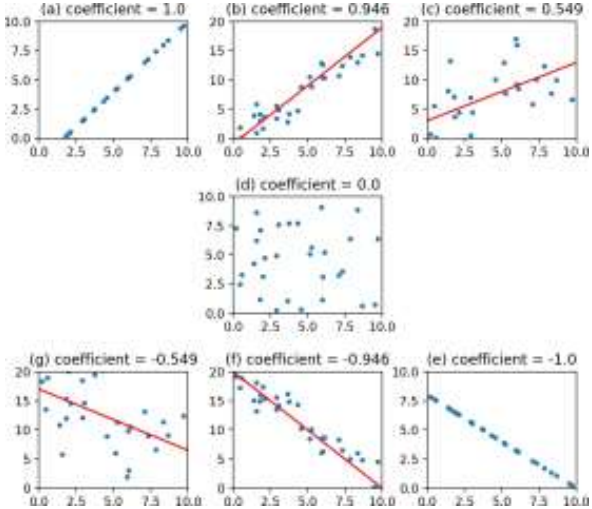
Ý nghĩa hệ số tương quan

- Let $a_i = x_i - \bar{x}$ and $b_i = y_i - \bar{y}$ for $1 \leq i \leq n$. The correlation coefficient r_{xy} is exactly the cosine of θ – the angle between the vector $\mathbf{a} = \{a_1, a_2, \ldots, a_n\}$ and the vector $\mathbf{b} = \{b_1, b_2, \ldots, b_n\}$:

$$r_{xy} = \cos\theta = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\|\|\mathbf{b}\|} \tag{16}$$

- The value of r_{xy} varies in $[-1, 1]$.
  - $r_{xy} = -1$: completely negative correlation;
  - $-1 < r_{xy} < 0$: negative correlation;
  - $r_{xy} = 0$: no correlation, i.e., X and Y are independent;
  - $0 < r_{xy} < 1$: positive correlation;
  - $r_{xy} = 1$: completely positive correlation.

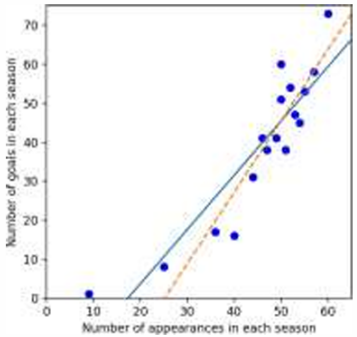
Mức độ tương quan



Ví dụ: Messi (số trận vs số bàn)

Season	**Apps**	**Goals**
2004-05	9	1
2005-06	25	8
2006-07	36	17
2007-08	40	16
2008-09	51	38
2009-10	53	47
2010-11	55	53
2011-12	60	73
2012-13	50	60
2013-14	46	41
2014-15	57	58
2015-16	49	41
2016-17	52	54
2017-18	54	45
2018-19	50	51
2019-20	44	31
2020-21	47	38

Messi's appss and goals for Barcelona

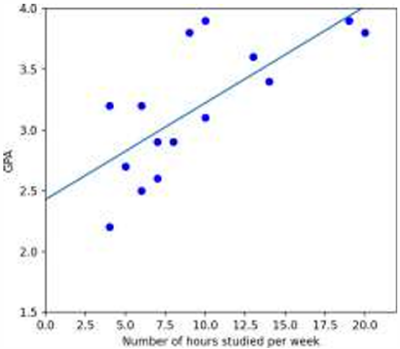


- Pearson correlation coefficient = 0.9021
- Blue line: regression with all data
- Yellow line: regression after removing the data of the first season

Ví dụ: Giờ học vs GPA

Hours	GPA
6	3.2
9	3.8
10	3.9
13	3.6
6	2.5
5	2.7
7	2.9
19	3.9
20	3.8
14	3.4
10	3.1
7	2.6
4	2.2
8	2.9
4	3.2

The number of hours studied per week and the GPA



- Pearson correlation coefficient = 0.7315
- Blue line: linear regression

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. **Mối quan hệ trong dữ liệu**
   - Tương quan và hệ số tương quan Pearson
   - **Tương quan hàng Spearman**
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

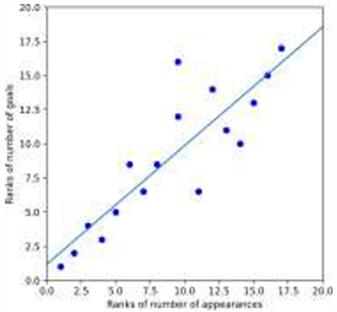
Tương quan Spearman

- Spearman là biến thể của Pearson, ít nhạy với outliers.
- Ý tưởng:
  - Chuyển dữ liệu sang thứ hạng (rank)
  - Sau đó tính Pearson trên các rank
- Ví dụ: $[1, 2, 5, 7] \Rightarrow$ rank của 5 là 3.

Ví dụ Spearman: Messi

Season	**Apps (Ranks)**	**Goals (Ranks)**
04-05	9 (**1.0**)	1 (**1.0**)
05-06	25 (**2.0**)	8 (**2.0**)
06-07	36 (**3.0**)	17 (**4.0**)
07-08	40 (**4.0**)	16 (**3.0**)
08-09	51 (**11.0**)	38 (**6.5**)
09-10	53 (**13.0**)	47 (**11.0**)
10-11	55 (**15.0**)	53 (**13.0**)
11-12	60 (**17.0**)	73 (**17.0**)
12-13	50 (**9.5**)	60 (**16.0**)
13-14	46 (**6.0**)	41 (**8.5**)
14-15	57 (**16.0**))	58 (**15.0**)
15-16	49 (**8.0**)	41 (**8.5**)
16-17	52 (**12.0**)	54 (**14.0**)
17-18	54 (**14.0**)	45 (**10.0**)
18-19	50 (**9.5**)	51 (**12.0**)
19-20	44 (**5.0**)	31 (**5.0**)
20-21	47 (**7.0**)	38 (**6.5**)

Messi's apps and goals for Barcelona



- Spearman correlation coefficient = 0.8692

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. **Mối quan hệ trong dữ liệu**
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - **Kiểm định chi-square Pearson cho dữ liệu định danh**
   - Tương quan và quan hệ nhân quả
5. Bài tập, Tài liệu tham khảo và Tổng kết

Kiểm định Chi-square (dữ liệu phân loại)

- Đối với dữ liệu phân loại (categorical), mối quan hệ giữa hai biến X và Y có thể được kiểm tra bằng kiểm định thống kê χ^2 (chi-bình phương).
- Giả sử X có r giá trị riêng biệt: $a_1, a_2, \ldots, a_r$, và Y có c giá trị riêng biệt: $b_1, b_2, \ldots, b_c$.
- Xét một mẫu dữ liệu song biến gồm n quan sát, được lấy từ hai biến X và Y.

$$\mathcal{D} = \begin{pmatrix} X & Y \\ \hline x_1 & y_1 \\ x_2 & y_2 \\ \vdots & \vdots \\ x_n & y_n \end{pmatrix}$$

- Ký hiệu $(X = a_i,\ Y = b_j)$ là biến cố đồng thời khi X nhận giá trị a_i và Y nhận giá trị b_j.

Bảng chéo (Contingency table)

- n quan sát của tập dữ liệu tạo thành một **bảng chéo**, trong đó:
  - r giá trị của X tạo thành các hàng
  - c giá trị của Y tạo thành các cột
- Bảng tần số:

	b_1	b_2	$\cdots$	b_c	Tổng
a_1	n_{11}	n_{12}	$\cdots$	n_{1c}	n_1
a_2	n_{21}	n_{22}	$\cdots$	n_{2c}	n_2
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
a_r	n_{r1}	n_{r2}	$\cdots$	n_{rc}	n_r
Tổng	m_1	m_2	$\cdots$	m_c	n

- Trong đó:
  - n_{ij}: số quan sát với $X = a_i$, $Y = b_j$
  - $n_i = \sum_j n_{ij}$: tổng hàng
  - $m_j = \sum_i n_{ij}$: tổng cột
  - $n = \sum_{i,j} n_{ij}$: tổng toàn bộ dữ liệu

Tính giá trị thống kê

- Giá trị χ^2 (Pearson chi-square) được tính như sau:

$$\chi^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

- Trong đó:
  - n_{ij}: tần số quan sát
  - e_{ij}: tần số kỳ vọng
- Tần số kỳ vọng được tính:

$$e_{ij} = \frac{n_i \, m_j}{n}$$

- Với:
  - n_i: tổng hàng
  - m_j: tổng cột
  - n: tổng số quan sát

Giả thuyết kiểm định χ^2

- Tổng trong công thức χ^2 được tính trên tất cả $r \times c$ ô của bảng chéo.
- Các ô đóng góp lớn nhất vào χ^2 là những ô có:

$$n_{ij} \text{ khác xa } e_{ij}$$

- Giả thuyết:
  - H_0: X và Y độc lập (không có tương quan)
  - H_a: X và Y có tương quan
- Bậc tự do:

$$(r-1)(c-1)$$

- Nếu bác bỏ $H_0 \Rightarrow$ kết luận:

$$X \text{ và } Y \text{ có tương quan thống kê}$$

Ví dụ kiểm định χ^2

- Khảo sát 1500 người:
  - Thuộc tính 1: giới tính (nam, nữ)
  - Thuộc tính 2: sở thích đọc (fiction, non-fiction)
- Bảng tần số quan sát:

	Nam	Nữ	Tổng
Fiction	250	200	450
Non-fiction	50	1000	1050
Tổng	300	1200	1500

- Tần số kỳ vọng được tính theo:

$$e_{ij} = \frac{n_i m_j}{n}$$

- Ví dụ:

$$e_{12} = \frac{1200 \times 450}{1500} = 360$$

Ví dụ kiểm định Chi-bình phương Pearson (tiếp theo)

Sử dụng phương trình (18) để tính giá trị χ^2[cite: 1324, 1325]:

$$\chi^2 = \frac{(250-90)^2}{90} + \frac{(50-210)^2}{210} + \frac{(200-360)^2}{360} + \frac{(1000-840)^2}{840}$$
$$= 284.44 + 121.90 + 71.11 + 30.48 = 507.93$$

- Đối với bảng 2×2 này, bậc tự do là $(2-1)(2-1) = 1$.
- Với 1 bậc tự do, giá trị χ^2 cần thiết để bác bỏ giả thuyết không ở mức ý nghĩa 0.001 là 10.828[cite: 1327].
- Vì giá trị tính toán của chúng ta cao hơn mức này, chúng ta có thể bác bỏ giả thuyết không rằng giới tính và sở thích đọc sách là độc lập[cite: 1328].
- Kết luận: hai thuộc tính này có tương quan (mạnh) đối với nhóm người được khảo sát.

Các giá trị tới hạn đuôi trên của phân phối Chi-bình phương

Giá trị tới hạn đuôi trên với ν bậc tự do:

	Probability less than the critical value				
ν	0.90	0.95	0.975	0.99	0.999
1	2.706	3.841	5.024	6.635	10.828
2	4.605	5.991	7.378	9.210	13.816
3	6.251	7.815	9.348	11.345	16.266
4	7.779	9.488	11.143	13.277	18.467
5	9.236	11.070	12.833	15.086	20.515
6	10.645	12.592	14.449	16.812	22.458
7	12.017	14.067	16.013	18.475	24.322
8	13.362	15.507	17.535	20.090	26.125
9	14.684	16.919	19.023	21.666	27.877
10	15.987	18.307	20.483	23.209	29.588
11	17.275	19.675	21.920	24.725	31.264
12	18.549	21.026	23.337	26.217	32.910
13	19.812	22.362	24.736	27.688	34.528
14	21.064	23.685	26.119	29.141	36.123
15	22.307	24.996	27.488	30.578	37.697
16	23.542	26.296	28.845	32.000	39.252

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. **Mối quan hệ trong dữ liệu**
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - **Tương quan và quan hệ nhân quả**
5. Bài tập, Tài liệu tham khảo và Tổng kết

Tương quan và quan hệ nhân quả

- **Tương quan** mô tả sự liên kết giữa các biến: khi một biến thay đổi, biến kia cũng thay đổi. Tương quan là một chỉ số thống kê về mối quan hệ giữa các biến.
- **Nhân quả** có nghĩa là những thay đổi ở biến này dẫn đến những thay đổi ở biến kia. Có mối quan hệ nhân-quả giữa các biến.
- Nếu X và Y tương quan, có nhiều cách giải thích: X gây ra Y, Y gây ra X, X và Y gây ra lẫn nhau, hoặc một nhóm các yếu tố khác gây ra cả X và Y (vấn đề biến thứ ba).
- Nhân quả đi kèm tương quan, nhưng tương quan không nhất thiết ngụ ý nhân quả.

Mục lục

1. Giới thiệu
2. Tìm hiểu dữ liệu của bạn
   - Thuộc tính dữ liệu
   - Dữ liệu đơn biến, song biến và đa biến
   - Dữ liệu phức tạp và có cấu trúc
3. Thống kê mô tả dữ liệu
   - Đo xu hướng trung tâm
   - Đo độ phân tán
4. Mối quan hệ trong dữ liệu
   - Tương quan và hệ số tương quan Pearson
   - Tương quan hàng Spearman
   - Kiểm định chi-square Pearson cho dữ liệu định danh
   - Tương quan và quan hệ nhân quả
5. **Bài tập, Tài liệu tham khảo và Tổng kết**

Bài tập

- Giả sử dữ liệu về độ tuổi (tăng dần):

$$\{13, 15, 16, 16, 19, 20, 20, 21, 22, 22, 25, 25, 25, 25, 30, 33, 33, 35, 35, 35, 35, 36, 40, 45, 46, 52, 70\}$$

(a) Tính mean và median
(b) Tìm mode và nhận xét tính đa mode (bimodal, trimodal,...)
(c) Tính midrange
(d) Tìm Q_1, Q_3
(e) Tóm tắt 5 số (five-number summary)
(f) Vẽ boxplot
(g) Tính variance và standard deviation

Bài tập (tiếp)

- Giả sử một bệnh viện đã thử nghiệm dữ liệu về độ tuổi và lượng mỡ cơ thể của 18 người lớn được chọn ngẫu nhiên với các kết quả sau:

age	23	23	27	27	39	41	47	49	50
%fat	9.5	26.5	7.8	17.8	31.4	25.9	27.4	27.2	31.2
age	52	54	54	56	57	58	58	60	61
%fat	34.6	42.5	28.8	33.4	30.2	34.1	32.9	41.2	35.7

(a) Tính mean, median, variance, std.
(b) Vẽ biểu đồ hộp cho tuổi và % mỡ.
(c) Vẽ một đồ thị phân tán cho hai biến này.
(d) Tính hệ số tương quan Pearson và Spearman giữa hai thuộc tính.

Bài tập (tiếp)

$\mathcal{D} =$

Club	*Season*	*Appearances*	*Goals*	*Assists*
Man United	03/04	5	0	1
Man United	04/05	7	0	2
Man United	05/06	6	0	0
Man United	06/07	11	3	5
Man United	07/08	11	8	1
Man United	08/09	12	4	3
Real Madrid	09/10	6	7	1
Real Madrid	10/11	12	6	4
Real Madrid	11/12	10	10	3
Real Madrid	12/13	12	12	1
Real Madrid	13/14	11	17	5
Real Madrid	14/15	12	10	4
Real Madrid	15/16	12	16	4
Real Madrid	16/17	13	12	6
Real Madrid	17/18	13	15	3
Juventus	18/19	9	6	2
Juventus	19/20	8	4	1
Juventus	20/21	6	4	2
Man United	21/22	7	6	0

Bài tập (tiếp)

- Gọi D (ở slide trước) là số: appearances (số lần ra sân), goals (bàn thắng), assists (kiến tạo)

  của Cristiano Ronaldo tại Champions League từ mùa giải 2003/2004 đến 2021/2022.

(a) Tính **mean, median, mode, variance, standard deviation** của ba thuộc tính appearances, goals, và assists.

(b) Tìm **phân vị thứ nhất** (Q_1) và **phân vị thứ ba** (Q_3) của ba thuộc tính appearances, goals, và assists.

(c) Vẽ **biểu đồ hộp (boxplot)** cho ba thuộc tính appearances, goals, và assists.

(d) Vẽ **biểu đồ phân tán (scatter plot)**:

- appearances vs goals
- appearances vs assists
- goals vs assists

(e) Tính **ma trận hiệp phương sai (covariance matrix)** của ba thuộc tính appearances, goals, và assists.

Bài tập (tiếp)

- 800 sinh viên thuộc ba ngành (Toán, Lịch sử, Khoa học máy tính) được hỏi liệu họ có thích chơi game hay không. Dữ liệu được tổng hợp như sau:

	Thích chơi	Không thích	Tổng
Toán	130	100	230
Lịch sử	35	165	200
Khoa học máy tính	280	90	370
Tổng	445	355	800

(a) Tính tần số kỳ vọng cho mỗi ô.

(b) Sử dụng kiểm định χ^2 để xác định liệu có mối liên hệ giữa ngành học và việc chơi game hay không.

Tài liệu tham khảo

1. J. Han, M. Kamber, J. Pei. *Data Mining: Concepts and Techniques*. Elsevier, 2012.
2. C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015.
3. J. Leskovec, A. Rajaraman, J. Ullman. *Mining of Massive Datasets*. Cambridge, 2014.
4. M. Zaki, W. Meira Jr. *Data Mining and Analysis*. Cambridge, 2013.
5. D. Easley, J. Kleinberg. *Networks, Crowds, and Markets*. Cambridge, 2010.
6. J. VanderPlas. *Python Data Science Handbook*. O'Reilly, 2017.
7. J. Grus. *Data Science from Scratch*. O'Reilly, 2015.

Tổng kết

- Giải thích tại sao việc hiểu dữ liệu là rất quan trọng trước khi thực hiện bất kỳ nhiệm vụ phân tích và khai phá dữ liệu nào.
- Nhận biết các loại thuộc tính dữ liệu khác nhau như dữ liệu phân loại, nhị phân, số, v.v.
- Giới thiệu các dạng dữ liệu như đơn biến, hai biến, đa biến, cũng như các dạng dữ liệu phức tạp và có cấu trúc hơn như chuỗi thời gian, chuỗi, dữ liệu không gian, mạng/đồ thị và dữ liệu luồng.
- Hiểu và biết cách đo lường xu hướng trung tâm cũng như độ biến thiên của dữ liệu; nắm được một số thống kê và công cụ trực quan như biểu đồ hộp (boxplot) để hiểu phân phối mẫu.
- Nghiên cứu các mối quan hệ tiềm năng giữa các biến/thuộc tính dữ liệu thông qua các khái niệm quan trọng như hiệp phương sai, tương quan, tương quan Pearson, tương quan Spearman, kiểm định chi-bình phương (Pearson's chi-square), cũng như phân biệt giữa tương quan và quan hệ nhân quả.