Distance and similarity

Trần Hồng Việt – UET VNU

Outline

1. Introduction
2. Similarity measures for numeric vectors
3. Similarity measures for data distributions
4. Similarity measures for nominal data
5. Similarity measures for ordinal data
6. Similarity measures for mix of data types
7. Similarity measures for sets
8. Similarity measures for sequence data
9. References and Summary

Outline

1. Introduction
2. Similarity measures for numeric vectors
3. Similarity measures for data distributions
4. Similarity measures for nominal data
5. Similarity measures for ordinal data
6. Similarity measures for mix of data types
7. Similarity measures for sets
8. Similarity measures for sequence data
9. References and Summary

Why is distance and similarity measurement important?

- Khoảng cách (distance) và độ tương tự (similarity) là những thành phần quan trọng trong nhiều bài toán khai phá dữ liệu, nơi ta cần so sánh hai hoặc nhiều đối tượng dữ liệu.
- Các ví dụ điển hình bao gồm k-NN, các phương pháp dựa trên kernel, hoặc nhiều thuật toán phân cụm (clustering).
- Việc thay đổi thước đo khoảng cách/độ tương tự có thể dẫn đến sự thay đổi đáng kể trong kết quả khai phá dữ liệu.
- Việc sử dụng thước đo tương tự "phù hợp" cho một bài toán cụ thể và một tập dữ liệu cụ thể là rất quan trọng.
- Có nhiều loại thước đo khoảng cách và độ tương tự khác nhau cho các kiểu/dạng dữ liệu khác nhau.
- Bài giảng này giới thiệu các thước đo khoảng cách và độ tương tự cơ bản, phổ biến, thường được sử dụng trong các ứng dụng khai phá dữ liệu.

Distance metric

Gọi X là một tập hợp hoặc không gian. Một độ đo khoảng cách (distance metric) trên X là một hàm: $\mathbf{X} \times \mathbf{X} \rightarrow [0, +\infty)$. Với

Tất cả điểm dữ liệu $\mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbf{X}$, khoảng cách d phải thỏa mãn các tiên đề sau:

Tính đồng nhất (Identity) – khoảng cách từ một điểm đến chính nó bằng 0:

$$d(\mathbf{x}, \mathbf{x}) = 0 \quad (1)$$

- Tính dương (Positivity) – khoảng cách giữa hai điểm phân biệt luôn dương:

$$d(\mathbf{x}, \mathbf{y}) > 0 \quad (2)$$

- Tính đối xứng (Symmetry) – khoảng cách từ x đến y bằng khoảng cách từ y đến x:

$$d(\mathbf{x}, \mathbf{y}) = d(\mathbf{y}, \mathbf{x}) \quad (3)$$

- Bất đẳng thức tam giác: $d(\mathbf{x}, \mathbf{z}) \leq d(\mathbf{x}, \mathbf{y}) + d(\mathbf{y}, \mathbf{z})$ (4)

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

Minkowski distance

- Gọi $\mathbf{x} = (x_1, x_2, \ldots, x_m)$ và $\mathbf{y} = (y_1, y_2, \ldots, y_m)$ là hai điểm dữ liệu trong $\mathbb{R}^m$.
- **Khoảng cách Minkowski** giữa $\mathbf{x}$ và $\mathbf{y}$ được định nghĩa như sau:

$$d_r(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_r = \left(\sum_{i=1}^{m} |x_i - y_i|^r \right)^{\frac{1}{r}} \quad (5)$$

- d_r là một độ đo khoảng cách khi $r \geq 1$.
  Khi $r < 1$, d_r **vi phạm bất đẳng thức tam giác.**

  Ví dụ:

$$d_r((0,0),(1,1)) > d_r((0,0),(0,1)) + d_r((0,1),(1,1))$$

vì:

$$2^{1/r} > 1^{1/r} + 1^{1/r} = 2 \quad \text{khi } r < 1$$

- Khi $r \geq 1$, khoảng cách Minkowski **thỏa mãn cả bốn tiên đề của một độ đo khoảng cách.**

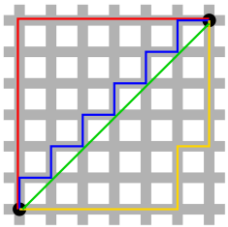
Euclidean distance

Khi $r = 2$, khoảng cách Minkowski trở thành **khoảng cách Euclid (Euclidean distance)**:

$$d_2(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^{m} |x_i - y_i|^2} \quad (6)$$

- Khoảng cách Euclid là **độ dài đoạn thẳng** nối từ điểm $\mathbf{x}$ đến điểm $\mathbf{y}$.
- Đây là **loại khoảng cách phổ biến nhất** và được sử dụng trong nhiều thuật toán như **phân loại (classification)**, **phân cụm (clustering)** và **so khớp (matching)**.

Manhattan distance



Euclidean and Manhattan distances [source: Wikipedia/Quora]

- Khi $r = 1$, khoảng cách Minkowski trở thành **khoảng cách Manhattan**:

$$d_1(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| = \sum_{i=1}^{m} |x_i - y_i| \quad (7)$$

- Trong hình minh họa, đường màu xanh lá là **khoảng cách Euclid**; các đường màu đỏ, xanh dương và vàng đều là **khoảng cách Manhattan**.
- Khoảng cách Manhattan còn được gọi là **khoảng cách "city block"** (khoảng cách theo lưới đường phố).

Hamming distance

- Khoảng cách Hamming giữa hai vector số được định nghĩa là số chiều mà tại đó các giá trị của chúng khác nhau.
- Khoảng cách Hamming thường được sử dụng cho các vector có giá trị nhị phân (binary) hoặc phân loại (categorical).
- Khoảng cách Hamming thỏa mãn bốn tiên đề của một độ đo khoảng cách.

Ví dụ: khoảng cách Hamming giữa $(1, 0, 1, 0, 1)^T$ và $(1, 1, 1, 1, 0)^T$ là 3.

Cosine distance

- **Cosine** của hai vector $\mathbf{x}$ và $\mathbf{y}$ là cos của góc θ giữa hai vector đó:

$$\cos\theta = \frac{\mathbf{x}\cdot\mathbf{y}}{\|\mathbf{x}\|\|\mathbf{y}\|} = \frac{\sum_{i=1}^{m} x_i y_i}{\sqrt{\sum_{i=1}^{m} x_i^2}\sqrt{\sum_{i=1}^{m} y_i^2}} \quad (8)$$

- **Khoảng cách cosine** được định nghĩa là:

$$d(\mathbf{x},\mathbf{y}) = 1 - \cos\theta \quad (9)$$

- Khoảng cách cosine **vi phạm tiên đề đồng nhất (identity)**.
  Hai vector **khác nhau nhưng cùng hướng** (ví dụ: $(1,1,1)$ và $(2,2,2)$) có $\cos\theta = 1$ nên khoảng cách = 0.
- Giá trị của khoảng cách cosine nằm trong $[0,2]$.
  Trong không gian dương, khi $\cos\theta$ thay đổi từ 1 đến 0, khoảng cách cosine nằm trong $[0,1]$.
- Cosine distance/similarity được sử dụng rộng rãi trong khai phá dữ liệu, đặc biệt để **đo độ tương tự giữa các văn bản (text documents)**.

Outline

1. Introduction
2. Similarity measures for numeric vectors
3. Similarity measures for data distributions
4. Similarity measures for nominal data
5. Similarity measures for ordinal data
6. Similarity measures for mix of data types
7. Similarity measures for sets
8. Similarity measures for sequence data
9. References and Summary

Kullback–Leibler distance

- Gọi $P = (p_1, p_2, \ldots, p_m)$ và $Q = (q_1, q_2, \ldots, q_m)$ là hai phân phối xác suất rời rạc.
  Khoảng cách Kullback–Leibler (KL divergence) từ Q đến P được định nghĩa như sau:

$$D_{KL}(P \parallel Q) = \sum^{m} p_i \log \frac{p_i}{a_i} \quad (10)$$

- Công thức trên bỏ qua các vị trí mà $p_i = 0$ hoặc $q_i = 0$.
- Trong lý thuyết thông tin, Kullback–Leibler còn được gọi là **entropy tương đối (relative entropy)**, là hiệu giữa **cross-entropy** $H(P, Q)$ và **entropy** $H(P)$.
- $D_{KL}(P \parallel Q) \geq 0$.
  $D_{KL}(P \parallel Q) = 0$ khi hai phân phối giống hệt nhau.
  $D_{KL}(P \parallel Q)$ nhỏ khi hai phân phối có dạng tương tự, và lớn nếu khác biệt nhiều.
- Khoảng cách Kullback–Leibler thỏa mãn tính **đồng nhất** và **tính dương**, nhưng **không thỏa mãn tính đối xứng** vì:

$$D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P)$$

Kullback–Leibler distance (cont'd)

■ Để đảm bảo tính đối xứng, chúng ta sử dụng một phân phối khác $S = (s_1, s_2, \ldots, s_m)$ trong đó $s_i = \frac{p_i + q_i}{2}$. Khi đó, khoảng cách sau đây là đối xứng:

$$d_{KL}(P, Q) = D_{KL}(P \| S) + D_{KL}(Q \| S) \tag{11}$$

Hoặc sử dụng giá trị trung bình của cả hai:

$$d_{KL}(P, Q) = \frac{D_{KL}(P \| Q) + D_{KL}(Q \| P)}{2} \tag{12}$$

■ Khoảng cách Kullback–Leibler rất hữu ích cho các ứng dụng khai phá dữ liệu khác nhau. Nó thường được sử dụng để đo lường sự tương đồng giữa hai phân phối hoặc các vector số (sau khi chuẩn hóa). Khoảng cách này đo lường sự tương đồng tại mọi chiều thay vì chỉ một số chiều có giá trị lớn hơn.

Examples of Kullback–Leibler or cosine distances

■ Tính toán khoảng cách Kullback–Leibler và khoảng cách cosine giữa hai phân phối (vector) $P = (0.1, 0.899, 0.001)$ và $Q = (0.001, 0.95, 0.049)$:

$$D_{KL}(P\|Q) = 0.1 \log \frac{0.1}{0.001} + 0.899 \log \frac{0.899}{0.95} + 0.001 \log \frac{0.001}{0.049} = 0.407$$

$$D_{KL}(Q\|P) = 0.001 \log \frac{0.001}{0.1} + 0.95 \log \frac{0.95}{0.889} + 0.049 \log \frac{0.049}{0.001} = 0.239$$

$$d_{KL}(P,Q) = \frac{D_{KL}(P\|Q) + D_{KL}(Q\|P)}{2} = \frac{0.407 + 0.239}{2} = \mathbf{0.323}$$

■ Độ tương đồng Cosine (Cosine similarity):

$$\begin{aligned} d(P,Q) &= 1 - \cos\theta \\ &= 1 - \frac{0.1 \times 0.001 + 0.899 \times 0.95 + 0.001 \times 0.049}{\sqrt{0.1^2 + 0.899^2 + 0.001^2}\sqrt{0.001^2 + 0.95^2 + 0.049^2}} \\ &= 1 - 0.993 = \mathbf{0.007} \end{aligned}$$

Using Kullback–Leibler or cosine distances?

- Trong ví dụ trước, chiều thứ hai của hai vector ($p_2 = 0.899$ và $q_2 = 0.95$) chiếm ưu thế trong độ tương đồng cosine mặc dù thực tế là các giá trị ở chiều thứ nhất và chiều thứ ba (0.1 so với 0.001 và 0.001 so với 0.049) rất khác biệt.
- Xét về góc θ, độ tương đồng cosine bằng 0.007 là phù hợp vì góc θ giữa hai vector là rất nhỏ.
- Tuy nhiên, xét về mặt phân phối xác suất, hai vector này lại rất khác nhau. Nếu chúng ta muốn làm nổi bật sự khác biệt này, phân kỳ KL (KL divergence) sẽ phù hợp hơn để sử dụng.
- Do đó, khoảng cách KL không chỉ đơn thuần là một phép đo khoảng cách, nó có thể được xem như một ràng buộc trên mọi chiều khi đo lường sự tương đồng.

Outline

1. Introduction
2. Similarity measures for numeric vectors
3. Similarity measures for data distributions
4. Similarity measures for nominal data
5. Similarity measures for ordinal data
6. Similarity measures for mix of data types
7. Similarity measures for sets
8. Similarity measures for sequence data
9. References and Summary

Similarity measure for nominal/categorical attributes

■ Một thuộc tính định danh (nominal) hoặc phân loại (categorical) có thể nhận hai (nhị phân) hoặc nhiều trạng thái. Ví dụ: giới tính = *nam* hoặc *nữ*; tỉnh thành = *Hà Nội*, *Thái Nguyên*, *Nghệ An*, v.v.

■ Các trạng thái của một thuộc tính định danh có thể được ký hiệu bằng các chữ cái, ký hiệu hoặc số nguyên. Lưu ý rằng, trong trường hợp này, các số nguyên được sử dụng để mã hóa các trạng thái/danh mục. Chúng không có ý nghĩa về mặt thứ tự hay so sánh.

■ Giả sử $\mathbf{x_i} = (x_{i1}, x_{i2}, \ldots, x_{im})$ và $\mathbf{x_j} = (x_{j1}, x_{j2}, \ldots, x_{jm})$ là hai thực thể dữ liệu được biểu diễn bởi m thuộc tính định danh. Khoảng cách giữa hai thực thể này là:

$$d(\mathbf{x_i}, \mathbf{x_j}) = \frac{m - s}{m} \tag{13}$$

trong đó s là số lượng các *khớp* (matches), nghĩa là số lượng các thuộc tính mà tại đó $\mathbf{x_i}$ và $\mathbf{x_j}$ có cùng một trạng thái (cùng giá trị).

■ Trọng số cho các thuộc tính có thể được sử dụng để làm nổi bật các thuộc tính quan trọng hơn những thuộc tính khác.

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

Similarity measure for ordinal attributes

- Các giá trị của một thuộc tính thứ bậc (ordinal) có thứ tự hoặc xếp hạng mang ý nghĩa rõ ràng. Ví dụ, thuộc tính kích cỡ có ba giá trị: *nhỏ (small)*, *trung bình (medium)*, và *lớn (large)*.
- Các thuộc tính thứ bậc cũng có thể thu được từ việc rời rạc hóa các thuộc tính số bằng cách chia phạm vi giá trị thành một số lượng hữu hạn các danh mục. Các danh mục này được tổ chức thành các cấp bậc.
- "Các thuộc tính thứ bậc được xử lý như thế nào?" Việc xử lý các thuộc tính thứ bậc khá giống với các thuộc tính số khi tính toán khoảng cách giữa các thực thể dữ liệu.

Similarity measure for ordinal attributes (cont'd)

■ Giả sử một thuộc tính thứ bậc X_a có K_a trạng thái/giá trị được sắp xếp, đại diện cho thứ hạng $1, 2, \ldots, K_a$. Giả sử một thực thể dữ liệu $\mathbf{x_i}$ có giá trị x_{ia} trên thuộc tính X_a. Thay thế x_{ia} bằng thứ hạng của nó, $r_{ia} \in \{1, 2, \ldots, K_a\}$.

■ Nếu chúng ta muốn chuẩn hóa giá trị thứ hạng của nó về đoạn $[0.0, 1.0]$, thì:

$$z_{ia} = \frac{r_{ia} - 1}{K_a - 1} \tag{14}$$

■ Sau đó, chúng ta có thể áp dụng bất kỳ phép đo khoảng cách nào cho dữ liệu số như Euclidean, Manhattan, cosine, v.v. cho thuộc tính thứ bậc đã được chuyển đổi (sử dụng r_{ia} hoặc giá trị chuẩn hóa z_{ia} của nó).

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

Multivariate data revisited

Dữ liệu đa biến (Multivariate data) là loại dữ liệu gồm các quan sát từ mmm biến/thuộc tính (X_1, X_2, . . . , X_m), i.e., tức là xem xét đồng thời mmm đặc trưng hoặc thuộc tính.. Thực chất, dữ liệu này có dạng một ma trận n×m như sau:

$$\mathbf{D} = \begin{pmatrix} X_1 & X_2 & \cdots & X_m \\ \hline x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{pmatrix} \tag{15}$$

Theo góc nhìn theo hàng (row view), dữ liệu có thể được xem như tập gồm n điểm dữ liệu trong không gian thuộc tính d-chiều:

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \ldots, x_{im})^T$$

Tương tự như dữ liệu đơn biến và hai biến, các thuộc tính , $X_1, X_2, \ldots, X_m$ có thể là định danh (categorical/nominal) (bao gồm cả nhị phân), thứ bậc (ordinal) hoặc dữ liệu số (numeric).

Similarity measure for mix of nominal, ordinal, and numeric data

- Gọi $d(x_i, x_j)$ là khoảng cách giữa x_i và $x_j \in (X_1, X_2, \ldots, X_m)$.
  Thuộc tính X_k ($k = 1..m$) có thể là **định danh (nominal)**, **thứ bậc (ordinal)** hoặc **số (numeric)**.
  Khoảng cách được tính như sau:

$$d(x_i, x_j) = \frac{\sum_{k=1}^{m} \delta_{ij}^{X_k} d_{ij}^{X_k}(x_{ik}, x_{jk})}{\sum_{k=1}^{m} \delta_{ij}^{X_k}} \quad (16)$$

Trong đó:

- Chỉ báo $\delta_{ij}^{X_k} = 0$ nếu x_{ik} hoặc x_{jk} bị thiếu. Ngược lại, $\delta_{ij}^{X_k} = 1$
- Nếu X_k là **dữ liệu số**:

$$d_{ij}^{X_k}(x_{ik}, x_{jk}) = \frac{|x_{ik} - x_{jk}|}{\max(X_k) - \min(X_k)}$$

- Nếu X_k là **định danh hoặc nhị phân**:

$$d_{ij}^{X_k}(x_{ik}, x_{jk}) = \begin{cases} 0, & \text{nếu } x_{ik} = x_{jk} \\ 1, & \text{ngược lại} \end{cases}$$

- Nếu X_k là **thứ bậc**: sử dụng hạng r_{ik} hoặc chuẩn hóa z_{ik}, và xử lý như dữ liệu số
- Giá trị khoảng cách nằm trong $[0, 1]$.
  Có thể dùng $\delta_{ij}^{X_k}$ làm **trọng số** thể hiện mức độ quan trọng của X_k trong tính toán khoảng cách.

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

Jaccard distance

Gọi A và B là hai tập hợp. Chỉ số Jaccard (Jaccard index) của A và B được định nghĩa như sau:

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} \tag{17}$$

- Khi đó, khoảng cách Jaccard (Jaccard distance) giữa A và B được định nghĩa là:

$$d(A,B) = 1 - J(A,B) = 1 - \frac{|A \cap B|}{|A \cup B|} \tag{18}$$

- Khoảng cách Jaccard thỏa mãn cả bốn tiên đề của một độ đo khoảng cách (metric).
- Khoảng cách Jaccard được dùng để đo mức độ tương tự giữa hai tập hợp mà thứ tự của các phần tử không quan trọng.
- Khác với khoảng cách trên vector, khoảng cách Jaccard có thể được tính giữa hai tập hợp có số lượng phần tử khác nhau (tức là khác về lực lượng phần tử – cardinality).

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

Edit distance

- Khoảng cách chỉnh sửa (Edit distance) là một thước đo quen thuộc để đo mức độ tương tự giữa các chuỗi rời rạc như chuỗi văn bản, chuỗi DNA, v.v.
- Cho hai chuỗi, khoảng cách này đo số lượng phép toán tối thiểu cần thiết để biến đổi chuỗi này thành chuỗi kia.
- Khoảng cách này được sử dụng rộng rãi trong khai phá văn bản (text mining), xử lý ngôn ngữ tự nhiên (NLP), tìm kiếm xấp xỉ (approximate search) và tin sinh học (bioinformatics).
- Có nhiều biến thể của khoảng cách này tùy thuộc vào các phép toán được sử dụng để biến đổi chuỗi. Khoảng cách Levenshtein sử dụng ba phép toán: xóa, chèn, và thay thế một ký tự trong chuỗi.
- Khoảng cách Levenshtein là một trong những thước đo phổ biến nhất trong họ edit distance và thường được sử dụng thay thế cho thuật ngữ edit distance.

Levenshtein distance – algorithm

Gọi $s_a = a_1 a_2 \dots a_n$ và $s_b = b_1 b_2 \dots b_m$ là hai chuỗi rời rạc (discrete sequences) hoặc chuỗi ký tự đầu vào.

Khoảng cách Levenshtein từ s_a đến s_b là chi phí để biến đổi s_a thành s_b bằng ba phép toán: xóa (deletion), chèn (insertion) và thay thế (substitution).

Khoảng cách này, ký hiệu là $d_{n,m}$, được định nghĩa đệ quy như sau với $i = 1..n$ và $j = 1..m$:

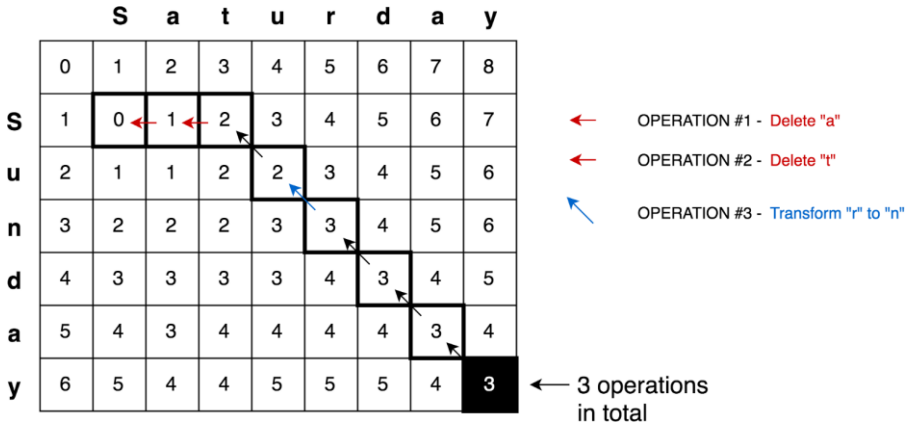
$$d_{i,0} = \sum_{k=1}^{i} w_{del}(a_k) \quad (19)$$

$$d_{0,j} = \sum_{k=1}^{j} w_{ins}(b_k) \quad (20)$$

$$d_{i,j} = \begin{cases} d_{i-1,j-1}, & \text{khi } a_i = b_j \\ \min \begin{cases} d_{i-1,j} + w_{del}(a_i) \\ d_{i,j-1} + w_{ins}(b_j) \\ d_{i-1,j-1} + w_{sub}(a_i, b_j) \end{cases}, & \text{khi } a_i \neq b_j \end{cases} \quad (21)$$

Trong đó, w_{del}, w_{ins}, và w_{sub} lần lượt là chi phí cho các phép toán xóa, chèn và thay thế.

Example



Levenshtein distance calculation by dynamic programming [source: Internet]

Outline

1 Introduction

2 Similarity measures for numeric vectors

3 Similarity measures for data distributions

4 Similarity measures for nominal data

5 Similarity measures for ordinal data

6 Similarity measures for mix of data types

7 Similarity measures for sets

8 Similarity measures for sequence data

9 References and Summary

References

1 J. Han, M. Kamber, and J. Pei. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, Elsevier, 2012 [Book1].

2 C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015 [Book2].

3 J. Leskovec, A. Rajaraman, and J. D. Ullman. *Mining of Massive Datasets*. Cambridge University Press, 2014 [Book3].

4 M. J. Zaki and W. M. Jr. *Data Mining and Analysis: Fundamental Concepts and Algorithms*. Cambridge University Press, 2013 [Book4].

5 D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010 [Book5].

6 J. VanderPlas. *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly, 2017 [Book6].

7 J. Grus. *Data Science from Scratch: First Principles with Python*. O'Reilly, 2015 [Book7].

Summary

- Giới thiệu các thước đo khoảng cách phổ biến cho dữ liệu số như Euclidean, Manhattan, và cosine. Trình bày khoảng cách giữa các phân phối dữ liệu là độ lệch Kullback–Leibler (Kullback–Leibler divergence) và giải thích sự khác biệt của nó so với cosine.
- Giới thiệu cách tính khoảng cách cho dữ liệu định danh (nominal/categorical) (bao gồm cả dữ liệu nhị phân), dữ liệu thứ bậc (ordinal), cũng như dữ liệu hỗn hợp gồm định danh, thứ bậc và số.
- Giới thiệu thước đo khoảng cách giữa các tập hợp: chỉ số Jaccard (Jaccard index) và khoảng cách Jaccard (Jaccard distance).
- Giới thiệu một trong những thước đo độ tương tự quan trọng nhất cho các chuỗi rời rạc hoặc chuỗi ký tự: khoảng cách chỉnh sửa (edit distance) và biến thể phổ biến nhất của nó là khoảng cách Levenshtein (Levenshtein distance).