Khai phá mẫu kết hợp

Trần Hồng Việt

Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội

Mục tiêu học tập dự kiến (LLOs)

- LLO1. Hiểu các khái niệm cơ bản liên quan đến khai phá luật kết hợp
- LLO2. Vận dụng được thuật toán Apriori
- LLO3. Đánh giá được luật kết hợp bằng một số độ đo cơ bản

Nội dung

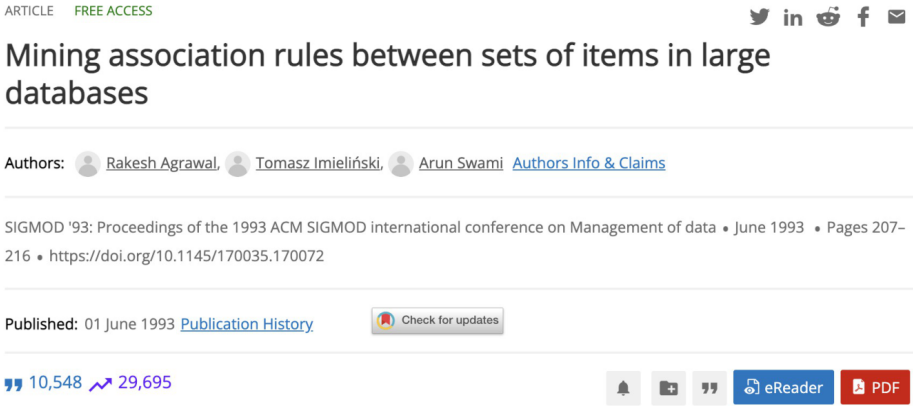
1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Câu chuyện về bia và tã lót





Bài báo gốc về khai phá luật kết hợp của Rakesh Agrawal và cộng sự



ARTICLE FREE ACCESS

Mining association rules between sets of items in large databases

Authors: Rakesh Agrawal, Tomasz Imieliński, Arun Swami Authors Info & Claims

SIGMOD '93: Proceedings of the 1993 ACM SIGMOD international conference on Management of data • June 1993 • Pages 207–216 • https://doi.org/10.1145/170035.170072

Published: 01 June 1993 Publication History

Check for updates

10,548 29,695

eReader PDF

Rakesh Agrawal



Rakesh Agrawal

Data Insights Laboratories
Verified email at datainsightslabs.com
Data Mining Privacy Web Search Education

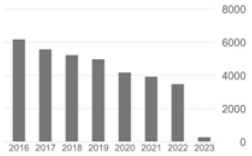
FOLLOW

GET MY OWN PROFILE

TITLE	CITED BY	YEAR
Fast algorithms for mining association rules R Agrawal, R Srikant Proc. 20th int. conf. very large data bases, VLDB 1215, 487-499	28713	1994
Mining association rules between sets of items in large databases R Agrawal, T Imieliński, A Swami Proceedings of the 1993 ACM SIGMOD international conference on Management of …	25530	1993
Association rules between sets of items in large databases R Agrawal, T Imielinski, AN Swami Proc. of ACM SIGMOD Int. Conf. on Management of Data, Washington, 207-216	~~25530~~	1993
Mining sequential patterns R Agrawal, R Srikant Proceedings of the eleventh international conference on data engineering, 3-14	8280	1995
Privacy-preserving data mining R Agrawal, R Srikant Proceedings of the 2000 ACM SIGMOD international conference on Management of …	4678	2000

Cited by VIEW ALL

	All	Since 2018
Citations	135875	22040
h-index	107	44
i10-index	263	131



Public access VIEW ALL

0 articles 1 article

Ví dụ về các luật kết hợp



- {bánh mỳ, bơ, mứt dâu tây} $\rightarrow$ {sữa tươi} (độ hỗ trợ = 1.3%, độ tin cậy = 83.5%)
- {the lean startup, good to great} $\rightarrow$ {zero to one} (độ hỗ trợ = 0.2%, độ tin cậy = 89%)

Nội dung

1. **Các khái niệm khai phá mẫu kết hợp**
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Các khái niệm khai phá mẫu kết hợp

1. Các mục (Items) và tập mục (Itemsets)
2. Giao dịch (Transactions) và cơ sở dữ liệu giao dịch
3. Tập mục phổ biến (Frequent itemsets) hoặc mẫu phổ biến (Frequent patterns)
4. Luật kết hợp (Association rules)
5. Ứng dụng của mẫu phổ biến và luật kết hợp

Các mục (Items) và tập mục (Itemsets)

- Một mục (item) có thể là một cuốn sách, một bộ phim, một sản phẩm, v.v. trong một cơ sở dữ liệu.
- Giả sử $I = \{x_1, x_2, ..., x_n\}$ là tập hợp tất cả n mục trong cơ sở dữ liệu.
  - Tất cả sản phẩm trong siêu thị: $I = \{$sữa, trứng, bánh mỳ, bơ, mật ong, thịt bò, táo, ...$\}$
  - Tất cả phim trong cơ sở dữ liệu: $I = \{$cuốn theo chiều gió, tiếng chim hót trong bụi mận gai, trân châu cảng, avatar: dòng chảy của nước, năm mươi sắc thái, quá nhanh quá nguy hiểm 7, ...$\}$
- Mọi tập con $X \subseteq I$ được gọi là một tập mục (itemset).
- Nếu X có k mục (tức là $|X| = k$), X là một tập mục k-mục (k-itemset). Ví dụ:
  - $X = \{$sữa, bánh mỳ, thịt bò$\}$ là một 3-itemset.
  - $Y = \{$cuốn theo chiều gió, tiếng chim hót trong bụi mận gai$\}$ là một 2-itemset.

Giao dịch và cơ sở dữ liệu giao dịch

- Một giao dịch T là một tập các mục: $T \subseteq I$
  - Thông thường, kích thước của T nhỏ hơn rất nhiều so với kích thước của I, tức là $|T| \ll |I|$
  - Một giao dịch thực chất là một tập mục. Tuy nhiên, chúng là hai khái niệm khác nhau.
- Giả sử $D = \{T_1, T_2, ..., T_m\}$ là một cơ sở dữ liệu giao dịch chứa m giao dịch.
- Trong các cơ sở dữ liệu thực tế, n có thể lớn và m có thể rất lớn.

Một ví dụ về cơ sở dữ liệu giao dịch

- Tập hợp tất cả các mục I: $I = \{A, B, C, D, E\}$
- Cơ sở dữ liệu giao dịch D: $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$ như sau:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
  - $T_6 = \{B, C, D\}$

Tập mục phổ biến hoặc mẫu phổ biến

- Cho X là một tập mục và D là một cơ sở dữ liệu giao dịch, độ hỗ trợ của X trong D, ký hiệu $sup(X, D)$, là số lượng các giao dịch trong D chứa X:

$$sup(X, D) = |\{T \mid T \in D \text{ và } X \subseteq T\}|$$

- Độ hỗ trợ tương đối của X trong D, ký hiệu $rsup(X, D)$, là phần trăm các giao dịch trong D chứa X:

$$rsup(X, D) = \frac{sup(X, D)}{|D|} = \frac{sup(X, D)}{m}$$

- X được gọi là một tập mục phổ biến hoặc mẫu phổ biến trong D nếu $sup(X, D) > minsup$, trong đó $minsup$ là ngưỡng độ hỗ trợ tối thiểu do người dùng định nghĩa.
- Gọi F là tập hợp tất cả các tập mục phổ biến.
- Gọi $F^{(k)}$ là tập hợp tất cả các tập mục phổ biến có độ dài k, tức là k-itemset phổ biến.

Các tập mục phổ biến (với minsup = 3) từ cơ sở dữ liệu mẫu D

- $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
  - $T_6 = \{B, C, D\}$
- Tập hợp tất cả các tập mục phổ biến có thể có F và $F^{(k)}$:
  - $F =$
    $\{A, B, C, D, E, AB, AD, AE, BC, BD, BE, CE, DE, ABD, ABE, ADE, BCE, BDE, ABDE\}$
  - $F^{(1)} = \{A, B, C, D, E\}$
  - $F^{(2)} = \{AB, AD, AE, BC, BD, BE, CE, DE\}$
  - $F^{(3)} = \{ABD, ABE, ADE, BCE, BDE\}$
  - $F^{(4)} = \{ABDE\}$

Luật kết hợp

- Một luật kết hợp được định nghĩa là:

$$X \to Y$$

trong đó X và Y là hai tập mục, tức là $X, Y \subseteq I$ và $X \cap Y = \emptyset$. X được gọi là tiền đề (vế trái); Y được gọi là hệ quả (vế phải).

- Độ hỗ trợ của luật $X \to Y$ trong D, ký hiệu $sup(X \to Y, D)$, là số lượng giao dịch trong D chứa cả X và Y:

$$sup(X \to Y, D) = sup(X \cup Y, D)$$

- Độ hỗ trợ tương đối của luật $X \to Y$ trong D, ký hiệu $rsup(X \to Y, D)$, là tỷ lệ phần trăm:

$$rsup(X \to Y, D) = \frac{sup(X \to Y, D)}{|D|} = \frac{sup(X \cup Y, D)}{m}$$

- Luật $X \to Y$ là phổ biến nếu: $sup(X \to Y, D) \geq minsup$

Luật kết hợp (tiếp theo)

- Độ tin cậy của luật $X \rightarrow Y$ trong D, ký hiệu $conf(X \rightarrow Y, D)$, là tỷ lệ giữa số lượng giao dịch chứa cả X và Y so với số lượng giao dịch chỉ chứa X:

$$conf(X \rightarrow Y, D) = \frac{sup(X \cup Y, D)}{sup(X, D)}$$

- Về phương diện xác suất, $conf(X \rightarrow Y, D)$ có thể xem như xác suất có điều kiện của một giao dịch trong D chứa Y khi đã chứa X, tức là $P(Y|X)$.
- Tuy nhiên, chúng khác nhau. Độ tin cậy của một luật không phải là xác suất.
- $X \rightarrow Y$ là một luật mạnh (đáng tin cậy) nếu độ tin cậy của nó lớn hơn hoặc bằng ngưỡng độ tin cậy tối thiểu do người dùng định nghĩa *minconf*:

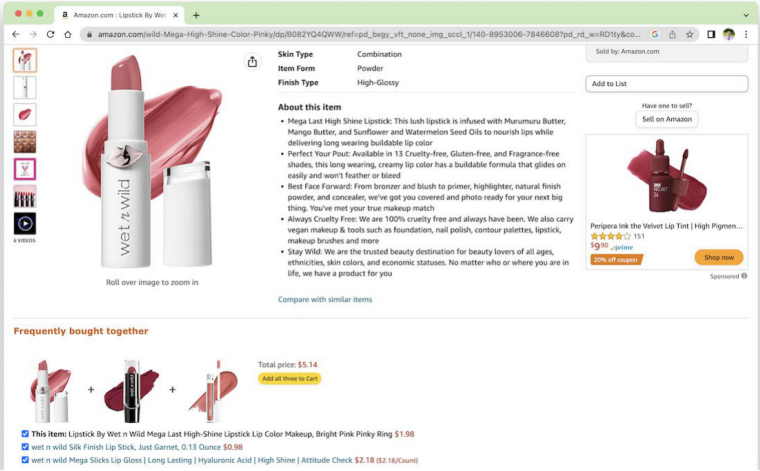
$$conf(X \rightarrow Y, D) \geq minconf$$

- Bên cạnh độ hỗ trợ và độ tin cậy, có một số tiêu chí khác để đo lường tính thú vị và tính hữu ích của luật kết hợp.

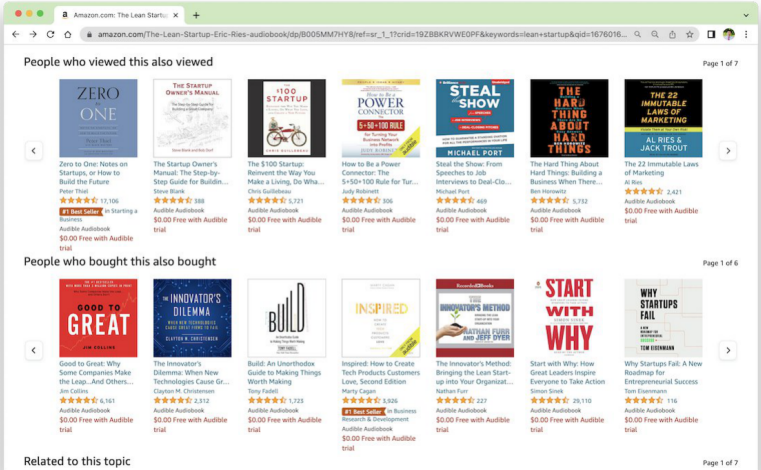
Ví dụ về các luật kết hợp

- $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$:
  - $T_1 = \{A, B, D, E\}$, $T_2 = \{B, C, E\}$, $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$, $T_5 = \{A, B, C, D, E\}$, $T_6 = \{B, C, D\}$
- Xét luật $\{B, C\} \rightarrow \{E\}$ (hay $BC \rightarrow E$):
  - $sup(BC \rightarrow E, D) = sup(BCE, D) = 3$
  - $conf(BC \rightarrow E, D) = \frac{sup(BCE, D)}{sup(BC, D)} = \frac{3}{4} = 0.75$ (75%)
- Xét luật $AD \rightarrow BE$:
  - $sup(AD \rightarrow BE, D) = sup(ABDE, D) = 3$
  - $conf(AD \rightarrow BE, D) = \frac{sup(ABDE, D)}{sup(AD, D)} = \frac{3}{3} = 1.0$ (100%)

Ứng dụng của luật kết hợp: Gợi ý trên Amazon



Ứng dụng của luật kết hợp: Gợi ý trên Amazon (tiếp theo)



Các ứng dụng khác của mẫu phổ biến và luật kết hợp

- Gợi ý trong nhiều lĩnh vực kinh doanh khác nhau: phim ảnh, sản phẩm, tài chính, du lịch...
- Phân tích giỏ hàng (Market basket analysis):
  - Tiếp thị, khuyến mãi bán hàng
  - Tối ưu hóa bố cục cửa hàng
- Phân tích và tìm hiểu hành vi khách hàng, ví dụ: phân tích dữ liệu nhật ký web
- Phân tích mạng xã hội
- Khai phá văn bản và web
- Khai phá mẫu tuần tự
- An toàn thông tin, ví dụ: phát hiện gian lận
- Y học, ví dụ: các mối liên hệ có thể có giữa các triệu chứng, yếu tố rủi ro, bệnh tật, v.v.

Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. **Khai phá luật kết hợp**
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Quy trình khai phá luật kết hợp

- **Giai đoạn 1: Khai phá các tập mục phổ biến:**
  - Cho một cơ sở dữ liệu giao dịch D và ngưỡng độ hỗ trợ tối thiểu *minsup*.
  - Khai phá tất cả các tập mục phổ biến có thể có từ D với *minsup*.
- **Giai đoạn 2: Sinh các luật mạnh:**
  - Cho ngưỡng độ tin cậy tối thiểu *minconf*.
  - Sinh tất cả các luật mạnh (đáng tin cậy) có thể có từ các tập mục phổ biến thu được ở bước 1 với *minconf*.

Khai phá luật kết hợp tốn thời gian như thế nào?

- Giai đoạn đầu tiên thường tốn kém thời gian hơn nhiều
- Xét một cơ sở dữ liệu nhỏ với $I = \{x_1, x_2, ..., x_{100}\}$, sẽ có $2^{100} - 1 \approx 1.27 \times 10^{30}$ tập con (loại trừ $\emptyset$).
- Các cơ sở dữ liệu thực tế cực kỳ lớn. Tổng số lượng mục có thể lên đến hàng trăm nghìn hoặc hàng triệu.
- Giai đoạn thứ hai tốn ít thời gian hơn

Các phương pháp tiếp cận khai phá tập mục phổ biến

- Thuật toán vét cạn (Brute-force)
- Thuật toán Apriori
- Thuật toán Eclat
- Thuật toán FP-Growth
- V.v.

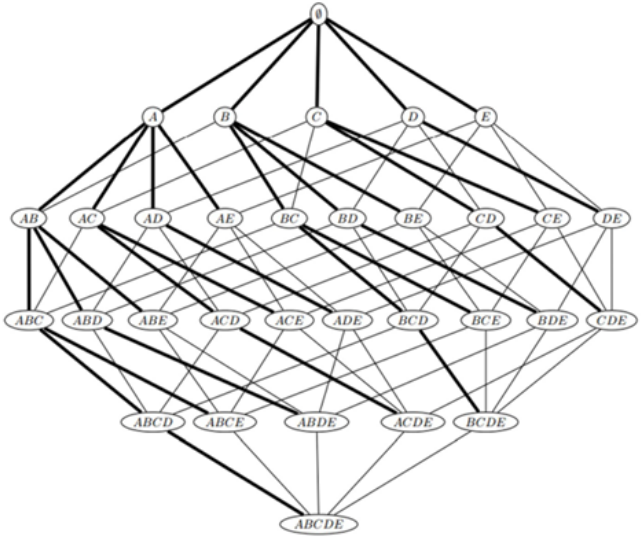
Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. **Thuật toán vét cạn (Brute-force)**
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Dàn tập mục (Itemset lattice)

- Cho $I = \{x_1, x_2, ..., x_n\}$ là tập hợp tất cả các mục, có 2^n tập mục (bao gồm cả I và $\emptyset$).
- Các tập mục được liên kết với nhau theo cách sau để tạo thành một dàn:
  - Tập mục X và Y được kết nối trên dàn khi và chỉ khi X là tập con trực tiếp của Y, tức là $X \subseteq Y$ và $|Y| = |X| + 1$.
- Các tập mục trên dàn có thể được duyệt qua bằng Tìm kiếm theo chiều sâu (DFS) hoặc Tìm kiếm theo chiều rộng (BFS).
- Với $I = \{A, B, C, D, E\}$, dàn có $2^5 = 32$ tập mục với $\emptyset$ nằm trên cùng và I ở dưới cùng (xem slide tiếp theo).

Dàn với I = {A, B, C, D, E}



[Nguồn: Data Mining and Analysis: Fundamental Concepts and Algorithms by Zaki and Jr]

Thuật toán vét cạn (Brute-force)

```
1: procedure BruteForce(D={T_1, T_2, ..., T_m}, I={x_1, x_2, ..., x_n},
minsup)
2:   F <- rỗng;
3:   for (mỗi X thuộc I) do
4:     sup(X, D) <- ComputeSupport(X, D);
5:     if (sup(X, D) >= minsup) then
6:       F <- F hợp {X};
7:     end if
8:   end for
9:   return F;
```

Thuật toán vét cạn (tiếp theo)

```
1: procedure ComputeSupport(X, D={T_1, T_2, ..., T_m})
2:   sup(X, D) <- 0;
3:   for (mỗi T thuộc D) do
4:     if (X là tập con của T) then
5:       sup(X, D) <- sup(X, D) + 1;
6:     end if
7:   end for
8:   return sup(X, D);
```

Các tập mục phổ biến tìm được từ D với minsup = 3

- $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
- Các tập mục phổ biến với các mức độ hỗ trợ khác nhau tìm được từ D:
  - $sup = 6$: {B}
  - $sup = 5$: {E, BE}
  - $sup = 4$: {A, C, D, AB, AE, BC, BD, ABE}
  - $sup = 3$: {AD, CE, DE, ABD, ADE, BCE, BDE, ABDE}

Hiệu suất của thuật toán vét cạn

- Độ phức tạp tính toán của thuật toán `ComputeSupport` là $O(|T| \cdot |D|) = O(n \cdot m)$.
- Vì có $2^{|I|}$ tập con của I, độ phức tạp tính toán của `BruteForce` là $O(|T| \cdot |D| \cdot 2^{|I|}) = O(n \cdot m \cdot 2^n)$.
- Độ phức tạp I/O: cần quét cơ sở dữ liệu D lên đến $O(2^n)$ lần.
- Cần kiểm tra toàn bộ không gian tập mục, tức là xem xét tất cả các nút trên dàn.
- **Vấn đề:**
  - Độ phức tạp tính toán và chi phí I/O khổng lồ.
  - Phải kiểm tra nhiều tập mục không cần thiết (có khả năng không phổ biến).

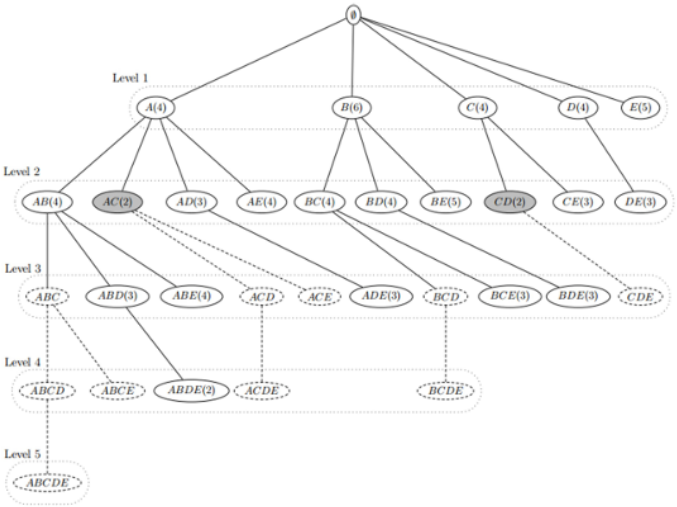
Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. **Thuật toán Apriori**
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Tính chất Apriori

- Cho X và Y là hai tập mục (tức là $X, Y \subseteq I$) và một cơ sở dữ liệu D. Nếu $X \subseteq Y$ thì $sup(X, D) \geq sup(Y, D)$
- Hai tính chất Apriori:
  - Nếu Y phổ biến, thì mọi tập con X của Y cũng phổ biến.
  - Nếu X không phổ biến, thì mọi tập cha Y của X cũng không phổ biến.
- Thuật toán Apriori sử dụng hai tính chất này để cải thiện hiệu suất của thuật toán vét cạn (Brute-force) bằng cách tỉa bớt các nhánh không cần thiết trên dàn.
- Thuật toán Apriori loại bỏ (tỉa) tất cả các tập mục cha có chứa một tập con không phổ biến.

Ví dụ về tỉa trên dàn với minsup = 3



[Nguồn: Data Mining and Analysis: Fundamental Concepts and Algorithms by Zaki and Jr]

Ví dụ về tỉa trên dàn với minsup = 3 (tiếp theo)

- Trong hình ở slide trước: các nút màu tối là các tập mục không phổ biến.
- Bất kỳ tập mục cha nào của các tập mục không phổ biến này đều bị loại bỏ (các nút nét đứt). Bất kỳ nhánh nào bắt đầu từ một trong những tập mục cha này cũng bị loại bỏ.
- **Ví dụ:** tập mục AC có $sup(AC, D) = 2 < minsup$. Do đó, tất cả các tập mục cha chứa AC sẽ bị loại bỏ, ví dụ: ABC, ACD, ACE.

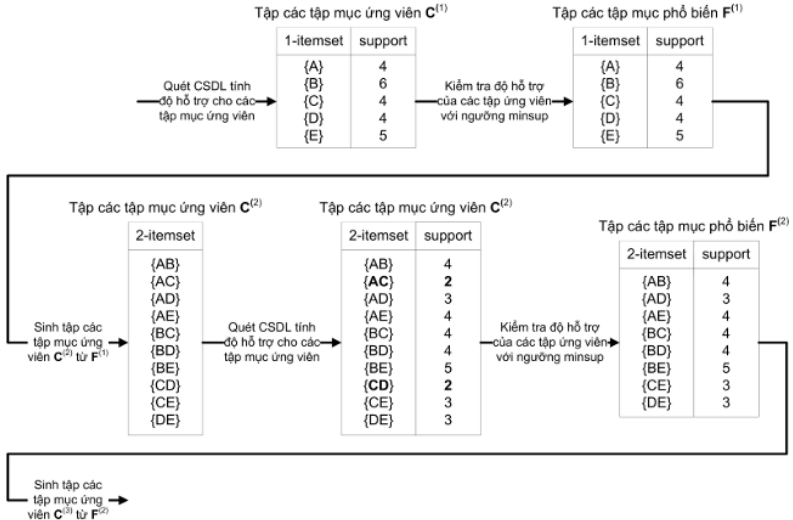
Khai phá các tập mục phổ biến từ cơ sở dữ liệu này với minsup = 3

- Tập hợp tất cả các mục I:

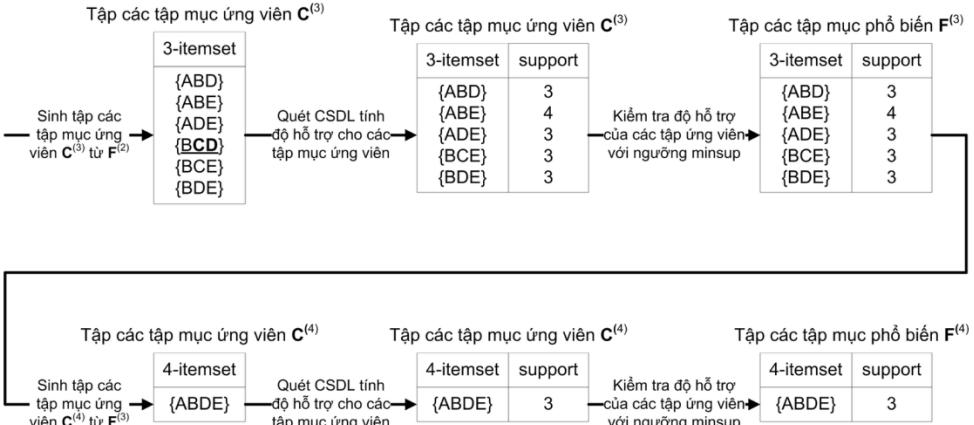
$$I = \{A, B, C, D, E\}$$

- Cơ sở dữ liệu giao dịch $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$ như sau:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
  - $T_6 = \{B, C, D\}$

Minh họa cách thức hoạt động của thuật toán Apriori



Minh họa cách thức hoạt động của thuật toán Apriori (tiếp theo)



Thuật toán Apriori

```
1: procedure APRIORI(D={T_1, T_2, ..., T_m}, I={x_1, x_2, ..., x_n}, minsup)
2:   F <- rỗng;
3:   F^1 <- FindFrequentItemsets(D, I, minsup);
4:   for (k=2; F^k-1 != rỗng; k++) do
5:     C^k <- AprioriGen(F^k-1);
6:     for (mỗi giao dịch T thuộc D) do
7:       C_T <- SubsetsOfT(C^k, T);
8:       for (mỗi C thuộc C_T) do
9:         C.count++;
10:      end for
11:    end for
12:    F^k <- {C thuộc C^k | C.count >= minsup};
13:  end for
14:  F <- F^1 hợp F^2 hợp ... hợp F^k;
15:  return F;
```

Thuật toán Apriori (tiếp theo)

```
1: procedure APRIORIGEN(F^k-1)
2:   C^k <- rỗng;
3:   for (mỗi tập mục F_1 thuộc F^k-1) do
4:     for (mỗi tập mục F_2 thuộc F^k-1) do
5:       if (F_1[1]=F_2[1] và ... F_1[k-2]=F_2[k-2] và F_1[k-1]<F_2[k-1]) then
6:         C <- F_1 hợp F_2;
7:         if (HasInfrequentSubset(C, F^k-1)) then
8:           loại bỏ C;
9:         else
10:          C^k <- C^k hợp {C};
11:        end if
12:      end if
13:    end for
14:  end for
15:  return C^k;
```

Thuật toán Apriori (tiếp theo)

```
1: procedure HASINFREQUENTSUBSET(C, F^k-1)
2:   for (mỗi tập con S kích thước (k-1) của C) do
3:     if (S không thuộc F^k-1) then
4:       return TRUE;
5:     end if
6:   end for
7:   return FALSE;
```

Ưu và nhược điểm của thuật toán Apriori

- **Ưu điểm:**
  - Cắt tỉa nhiều nhánh không cần thiết trên dàn bằng cách sử dụng các tính chất Apriori.
  - Nhanh hơn nhiều so với thuật toán vét cạn (Brute-force).
- **Nhược điểm:**
  - Vẫn cần tạo ra một số lượng lớn các ứng viên tập mục. Nếu có 10^4 tập mục 1-itemset phổ biến, thuật toán cần sinh ra hơn 10^7 ứng viên 2-itemset.
  - Vẫn cần quét cơ sở dữ liệu nhiều lần trong quá trình thực thi.

Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. **Sinh các luật kết hợp**
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Sinh luật kết hợp từ tập các tập mục phổ biến F

- Cho F là tập hợp tất cả các tập mục phổ biến được tìm thấy từ cơ sở dữ liệu D với ngưỡng độ hỗ trợ tối thiểu *minsup*.
- Sinh các luật mạnh (giai đoạn 2) là tạo ra tất cả các luật kết hợp có thể có từ F sao cho độ tin cậy của chúng $\geq$ *minconf*. Việc sinh luật được thực hiện như sau:
  - Xem xét mỗi tập mục phổ biến $F \in \mathbb{F}$.
  - Sinh tất cả các luật mạnh có thể có từ F.

Sinh luật kết hợp từ một tập mục phổ biến F

- Cho một tập mục phổ biến $F \in \mathbb{F}$, chúng ta xem xét tất cả các tập con thực sự $X \subset F$ để tính toán các luật có dạng sau:

$$X \rightarrow Y \text{ trong đó } Y = F \setminus X$$

- Luật này đã phổ biến vì $sup(X \cup Y, D) = sup(F, D) \geq minsup$.
- Phải kiểm tra xem luật có mạnh (có độ tin cậy) hay không:

$$c = conf(X \rightarrow Y, D) = \frac{sup(X \cup Y, D)}{sup(X, D)} = \frac{sup(F, D)}{sup(X, D)}$$

- Nếu $c \geq minconf$, thì luật đó là luật mạnh.
- Mặt khác, nếu $c < minconf$, thì $conf(Z \rightarrow F \setminus Z) \leq c < minconf$ đối với tất cả các tập con $Z \subset X$, vì $sup(Z) \geq sup(X)$.
  - Trong trường hợp này, ta có thể tránh việc kiểm tra tất cả các tập con Z của X.
  - Do đó, loại bỏ tất cả các tập con Z khỏi tập hợp đang xét.

Thuật toán sinh các luật kết hợp mạnh

```
1: procedure GENFREQUENTSTRONGRULES(F, minconf)
2:   R <- rỗng;
3:   for (mỗi F thuộc F và |F| >= 2) do
4:     Z <- {Z | Z con F, Z != rỗng};
5:     while (Z != rỗng) do
6:       X <- phần tử cực đại trong Z;
7:       Z <- Z \ X;
8:       if (conf(X -> F \ X, D) >= minconf) then
9:         R <- R hợp {X -> F \ X};
10:      else
11:        Z <- Z \ {Z | Z con X};
12:      end if
13:    end while
14:  end for
15:  return R;
```

Minh họa việc sinh luật

- Sinh tất cả các luật mạnh từ tập hợp các tập mục phổ biến:
  $F = \{ABDE, ABD, ABE, ADE, BCE, BDE, AB, AD, AE, BC, BD, BE, CE, DE, A, B, C, D, E\}$ với $minconf = 0.8$:
- Thuật toán sinh luật bắt đầu với tập mục phổ biến đầu tiên: $F = ABDE$:
- $Z =$
  $\{ABD(3), ABE(4), ADE(3), BDE(3), AB(4), AD(4), AE(4), BD(4), BE(5), DE(3), A(4), B(6), D(4), E(5)\}$.
- $X = ABD$: $conf(ABD \to E) = \frac{3}{3} = 1.0 > 0.8$ thì $ABD \to E$ là luật mạnh.
- $X = ABE$: $conf(ABE \to D) = \frac{3}{4} = 0.75 < 0.8$, $ABE \to D$ không là luật mạnh.
  Loại bỏ khỏi Z tất cả các tập con của ABE (tức là loại bỏ AB, AE, BE, A, B, E).
- Khi đó, $Z = \{ADE(3), BDE(3), AD(4), BD(4), DE(3), D(4)\}$.

Minh họa việc sinh luật (tiếp theo)

- $X = ADE$: $conf(ADE \rightarrow B) = \frac{3}{3} = 1.0 > 0.8$, thì $ADE \rightarrow B$ là luật mạnh.
- $X = BDE$: $conf(BDE \rightarrow A) = \frac{3}{3} = 1.0 > 0.8$, thì $BDE \rightarrow A$ là luật mạnh.
- $X = AD$: $conf(AD \rightarrow BE) = \frac{3}{4} = 0.75 < 0.8$, $AD \rightarrow BE$ không là luật mạnh.
  - Loại bỏ khỏi Z tất cả các tập con của AD (tức là loại bỏ D).
  - Khi đó, $Z = \{BD(4), DE(3)\}$.
- $X = BD$: $conf(BD \rightarrow AE) = \frac{3}{4} = 0.75 < 0.8$, $BD \rightarrow AE$ không là luật mạnh.
  - Loại bỏ khỏi Z tất cả các tập con của BD.
  - Khi đó, $Z = \{DE(3)\}$.
- $X = DE$: $conf(DE \rightarrow AB) = \frac{3}{3} = 1.0 > 0.8$, $DE \rightarrow AB$ là luật mạnh.

Minh họa việc sinh luật (tiếp theo)

- Các luật mạnh được sinh ra từ tập mục phổ biến $ABDE$:
  - $ABD \rightarrow E$ ($sup = 3$, $conf = 1.0$ tức là 100%)
  - $ADE \rightarrow B$ ($sup = 3$, $conf = 1.0$ tức là 100%)
  - $BDE \rightarrow A$ ($sup = 3$, $conf = 1.0$ tức là 100%)
  - $DE \rightarrow AB$ ($sup = 3$, $conf = 1.0$ tức là 100%)
- Để sinh thêm các luật mạnh, thuật toán sẽ tiếp tục với $F = ABD, ABE, ADE, BCE, BDE, AB, AD, AE, BC, BD, BE, CE, DE, A, B, C, D, E$ trong $\mathbb{F}$.
- Thuật toán sẽ không sinh ra luật nào từ $\{A, B, C, D, E\}$ vì chúng là các 1-itemset.

Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. **Thuật toán FP-Growth**
7. Đánh giá mẫu và luật kết hợp
8. Tài liệu tham khảo và Tổng kết

Khai phá tập mục phổ biến với thuật toán FP-Growth

1. Cấu trúc của cây FP-Tree (Frequent Pattern Tree)
2. Thuật toán sinh cây FP-Tree
3. Sinh các tập mục phổ biến từ cây FP-Tree
4. Ưu và nhược điểm của phương pháp FP-Growth

Cấu trúc của cây FP-Tree (Frequent Pattern Tree)

- Nút trên cùng hoặc nút gốc được dán nhãn là $\emptyset$.
- Mỗi nút trong và nút lá đại diện cho một mục trong cơ sở dữ liệu. Có thể có hai hoặc nhiều nút có cùng nhãn (tức là cùng một mục).
- Mỗi nút lưu trữ độ hỗ trợ của mục đó, đó là số lượng giao dịch trong cơ sở dữ liệu chứa tập mục bao gồm tất cả các mục từ gốc đến nó.
- Có một bảng lưu trữ các mục và các con trỏ (node-links) để liên kết tất cả các nút có cùng nhãn (tức là cùng mục) trong cây.

Thuật toán sinh cây FP-Tree

```
1: procedure BUILDFPTREE(D={T_1, T_2, ..., T_m})
2:   Khởi tạo cây FP-Tree T chỉ chứa nút gốc rỗng và rỗng.support <- 0;
3:   for (mỗi giao dịch T thuộc D) do
4:     T' = {x^1, ..., x^h} <- sắp xếp các mục thuộc T theo thứ tự giảm dần của support.
5:     pNode <- nút gốc;
6:     for (i=1; i<=h; i++) do
7:       if (có cNode thuộc Children(pNode) và cNode.label == x^i) then
8:         cNode.support++;
9:         pNode <- cNode;
10:      else
11:        tạo cNode là nút con mới của pNode;
12:        cNode.label <- x^i;
13:        cNode.support <- 1;
14:        pNode <- cNode;
15:      end if
16:    end for
17:    rỗng.support++;
18:  end for
19:  return T;
```

Khai phá các tập mục phổ biến từ cơ sở dữ liệu này với minsup = 3

- Tập hợp tất cả các mục I:

$$I = \{A, B, C, D, E\}$$

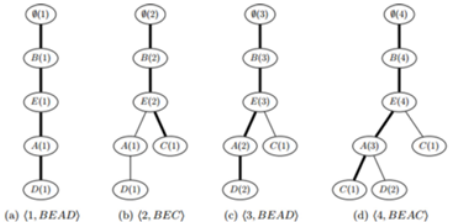
- Cơ sở dữ liệu giao dịch $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$ như sau:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
  - $T_6 = \{B, C, D\}$

- Tập hợp tất cả các mục I:

$$I = \{B(6), E(5), A(4), C(4), D(4)\}$$

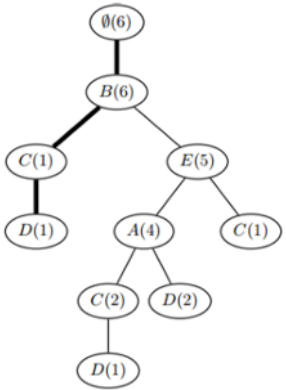
- Cơ sở dữ liệu giao dịch $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$ như sau:
  - $T_1 = \{B, E, A, D\}$
  - $T_2 = \{B, E, C\}$
  - $T_3 = \{B, E, A, D\}$
  - $T_4 = \{B, E, A, C\}$
  - $T_5 = \{B, E, A, C, D\}$
  - $T_6 = \{B, C, D\}$

Xây dựng cây FP-Tree T từ cơ sở dữ liệu D



[Nguồn: Data Mining and Analysis: Fundamental Concepts and Algorithms by Zaki and Jr]

Cây FP-Tree T được tạo từ cơ sở dữ liệu D



[Nguồn: Data Mining and Analysis: Fundamental Concepts and Algorithms by Zaki and Jr]

Một số nhận xét về cây FP-Tree

- Chỉ cần quét cơ sở dữ liệu 2 lần để xây dựng cây T.
- Cây FP-Tree là một dạng biểu diễn nén của cơ sở dữ liệu (cơ sở dữ liệu có thể được xây dựng lại từ cây FP-Tree).
- Các mục phổ biến hơn xuất hiện gần gốc của cây hơn.
- Một cây FP-Tree nhỏ hoặc nhỏ gọn sẽ tốt hơn. Một cây FP-Tree nhỏ gọn có nghĩa là cơ sở dữ liệu dày đặc. Ngược lại, một cây FP-Tree lớn có nghĩa là cơ sở dữ liệu thưa thớt.
- Tất cả các tập mục phổ biến của cơ sở dữ liệu có thể được khai phá trực tiếp từ cây FP-Tree mà không cần quét lại cơ sở dữ liệu thêm lần nào nữa.

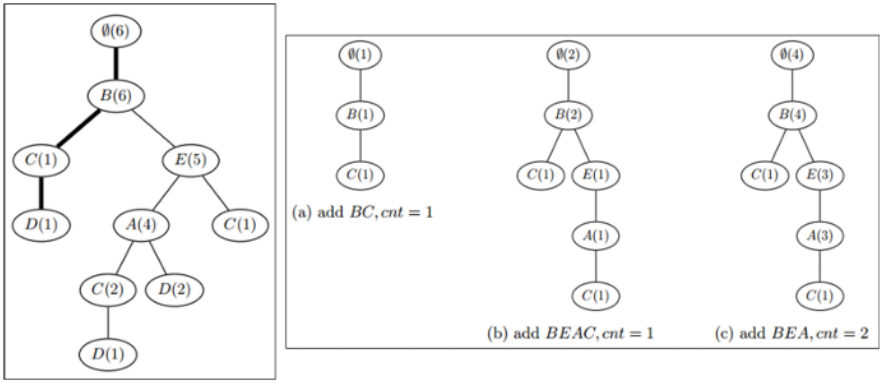
Thuật toán sinh tập mục phổ biến từ cây FP-Tree

```
1: procedure FPGROWTH(T, P, F, minsup)
2:   loại bỏ tất cả các mục không phổ biến trong T;
3:   if (IsPath(T)) then
4:     for (mỗi tập con Y của T) do
5:       X <- P hợp Y;
6:       X.support <- min_{x thuộc Y}{cnt(x)};
7:       F <- F hợp {X};
8:     end for
9:   else
10:    for (mỗi mục y thuộc T theo thứ tự tăng dần của sup(y)) do
11:      X <- P hợp {y};
12:      X.support <- sup(y);
13:      F <- F hợp {X};
14:      khởi tạo FP-Tree T_X <- rỗng;
15:      for mỗi đường dẫn từ gốc đến nút có nhãn y trong T do
16:        cnt(y) <- tần suất của y trong đường dẫn;
17:        chèn đường dẫn (ngoại trừ nút y) vào FP-Tree T_X với cnt(y);
18:      end for
19:      if (T_X != rỗng) then
20:        FPGrowth(T_X, X, F, minsup);  => Gọi hàm đệ quy
21:      end if
22:    end for
23:  end if
```

Một số lưu ý từ thuật toán

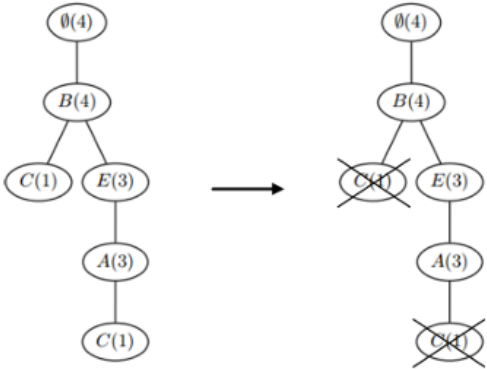
- Lời gọi hàm đầu tiên là `FPGrowth(T, P <- rỗng, F <- rỗng, minsup)`.
- Cách thực hiện phép chiếu của cây T theo một mục cụ thể (xem các slide tiếp theo).
- Một cây FP-Tree T có thể là một đường dẫn tuyến tính (linear path).
- Cách loại bỏ các mục không phổ biến trong FP-Tree.

Cây FP-Tree chiếu theo mục D



[Nguồn: Data Mining and Analysis: Fundamental Concepts and Algorithms by Zaki and Jr]

Loại bỏ các mục không phổ biến trong cây FP-Tree



- **Trái:** Cây FP-Tree T_D được chiếu sử dụng D từ cây FP-Tree T.
- **Phải:** Cây FP-Tree T_D sau khi loại bỏ mục C (không phổ biến vì $cnt(C) = 1 + 1 = 2 < minsup = 3$).

Minh họa thuật toán sinh tập mục phổ biến

- Lời gọi đầu tiên: `FPGrowth(T, P <- rỗng, F <- rỗng, minsup = 3)`.
- Tất cả các mục đều phổ biến, không loại bỏ bất kỳ mục nào.
- T không phải là một đường dẫn tuyến tính.
- Tiền tố: $P = \emptyset$.
- y sẽ lần lượt nhận các giá trị $D(4), C(4), A(4), E(5), B(6)$.
- Đầu tiên y lấy D:
  - $X \leftarrow P \cup \{y\} = \emptyset \cup \{D\} = \{D\}$.
  - $\mathbb{F} \leftarrow \mathbb{F} \cup \{X\} = \emptyset \cup \{\{D(4)\}\} = \{\{D(4)\}\}$.
  - Có ba đường dẫn tuyến tính từ gốc của T đến nút D: $BCD, cnt(D) = 1$; $BEACD, cnt(D) = 1$; và $BEAD, cnt(D) = 2$.
  - Tạo cây FP-Tree $\mathbb{T}_{\{D\}}$ từ ba đường dẫn trên.
  - Gọi đệ quy đến $\texttt{FPGrowth}(\mathbb{T}_{\{D\}}, \{D\}, \{\{D(4)\}\}, minsup = 3)$.
- y lấy C:
- y lấy A:

Minh họa thuật toán sinh tập mục phổ biến (tiếp theo)

- Lời gọi đệ quy: $\texttt{FPGrowth}(\mathbb{T}_{\{D\}}, P = \{D\}, \mathbb{F} = \{\{D(4)\}\}, minsup = 3)$:
  - Loại bỏ tất cả các nút có nhãn C trong $\mathbb{T}_{\{D\}}$ vì $cnt(C) = 1 + 1 = 2 < minsup = 3$.
  - Cây FP-Tree $\mathbb{T}_{\{D\}}$ trở thành một đường dẫn tuyến tính: $B(4) - E(3) - A(3)$:
    - Liệt kê tất cả các tập con của đường dẫn tuyến tính này: B, E, A, BE, BA, EA, BEA.
    - Thêm tiền tố $P = \{D\}$ để tạo thành các tập mục phổ biến $DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)$.
    - Thêm các tập mục phổ biến này vào $\mathbb{F}$ để có $\mathbb{F} = \{D(4), DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)\}$.
    - Lời gọi đệ quy $\texttt{FPGrowth}(\mathbb{T}_{\{D\}}, P = \{D\}, \mathbb{F} = \{\{D(4)\}\}, minsup = 3)$ kết thúc.

Minh họa thuật toán sinh tập mục phổ biến (tiếp theo)

- Khi y lấy các mục khác:
  - y lấy C:
    - $\mathbb{F} = \{D(4), DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)\} \cup \underline{\{C(4), CB(4), CE(3), CBE(3)\}}$.
  - y lấy A:
    - $\mathbb{F} = \{D(4), DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)\} \cup \{C(4), CB(4), CE(3), CBE(3)\} \cup \underline{\{A(4), AE(4), AB(4), AEB(4)\}}$.
  - y lấy E:
    - $\mathbb{F} = \{D(4), DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)\} \cup \{C(4), CB(4), CE(3), CBE(3)\} \cup \{A(4), AE(4), AB(4), AEB(4)\} \cup \underline{\{E(5), EB(5)\}}$.
  - y lấy B:
    - $\mathbb{F} = \{D(4), DB(4), DE(3), DA(3), DBE(3), DBA(3), DEA(3), DBEA(3)\} \cup \{C(4), CB(4), CE(3), CBE(3)\} \cup \{A(4), AE(4), AB(4), AEB(4)\} \cup \{E(5), EB(5)\} \cup \underline{\{B(6)\}}$.

Minh họa thuật toán sinh tập mục phổ biến (tiếp theo)

- Cuối cùng, $\mathbb{F}$ bao gồm các tập mục phổ biến sau đây với các mức độ hỗ trợ khác nhau:
  - **Support = 6:** B
  - **Support = 5:** E, BE
  - **Support = 4:** $D, C, A, DB, CB, AE, AB, ABE$
  - **Support = 3:** $DE, DA, CE, DBE, DBA, DAE, CBE, DBEA$

Ưu và nhược điểm của thuật toán FP-Growth

- **Ưu điểm:**
  - Nén toàn bộ cơ sở dữ liệu thành một cây FP-Tree đơn giản và gọn gọn.
  - Chỉ quét cơ sở dữ liệu hai lần.
  - Hoạt động tốt ngay cả khi *minsup* nhỏ.
- **Nhược điểm:**
  - Cài đặt phức tạp hơn so với Apriori.
  - Khi cơ sở dữ liệu lớn và thưa thớt, cây FP-Tree sẽ lớn và khó để vừa trong bộ nhớ chính.
  - Thuật toán sinh tập mục phổ biến là thuật toán đệ quy.

Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. **Đánh giá mẫu và luật kết hợp**
8. Tài liệu tham khảo và Tổng kết

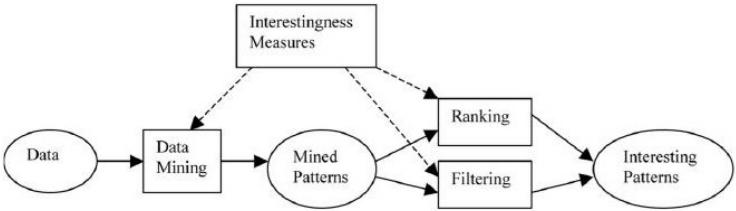
Đánh giá mẫu và luật kết hợp

1. Đánh giá luật kết hợp
2. So sánh các tập mục
3. So sánh các luật

Đánh giá mẫu và luật kết hợp

1. **Đánh giá luật kết hợp**
2. So sánh các tập mục
3. So sánh các luật

Đánh giá luật kết hợp



- Khai phá luật dựa trên các tiêu chí độ hỗ trợ và độ tin cậy có thể không đủ.
- Một số luật phổ biến và mạnh nhưng không thực sự thú vị hoặc hữu ích cho ứng dụng. Có thể sử dụng một số tiêu chí khác.

Một số tiêu chí đánh giá luật kết hợp

- Độ bao phủ (Coverage, tức là Độ hỗ trợ - Support)
- Độ tin cậy (Reliability, tức là Độ tin cậy - Confidence)
- Tính hữu ích (Usefulness)
- Tính súc tích (Conciseness)
- Tính đặc thù (Peculiarity)
- Tính đa dạng (Diversity)
- Tính mới lạ (Novelty)
- Tính bất ngờ (Unexpectedness)
- Tính khả thi hoặc khả năng áp dụng (Actionability / Applicability)

Một luật mạnh có thể không thú vị hoặc không có ý nghĩa

- Xem xét cơ sở dữ liệu AllElectronics chứa hai mục: video và trò chơi (games). Giả sử cơ sở dữ liệu có 10.000 giao dịch, trong đó:
  - 6.000 giao dịch mua trò chơi,
  - 7.500 giao dịch mua video, và
  - 4.000 giao dịch mua cả trò chơi và video.
- Giả sử $minsup = 30\%$ và $minconf = 60\%$.
- Luật $\{\text{games}\} \rightarrow \{\text{videos}\}$ có $sup = 40\%$ và $conf = 66.67\%$. Nó là phổ biến và mạnh (đáng tin cậy).
- Tuy nhiên, luật này không có ý nghĩa hoặc không thú vị vì xác suất một giao dịch mua $\{\text{videos}\}$ trong cơ sở dữ liệu là $7.500/10.000 = 75\% > 66.67\%$.
- Rõ ràng, việc mua trò chơi không phải là "tác nhân" kích thích khách hàng mua video.

Độ đo Lift (Độ nâng)

- Độ đo lift của một luật $X \to Y$ được tính như sau:

$$lift(X \to Y, D) = \frac{conf(X \to Y, D)}{sup(Y, D)} = \frac{sup(X \cup Y, D)}{sup(X, D) sup(Y, D)}$$

- Về phương diện xác suất: tỷ lệ giữa xác suất kết hợp quan sát được của X và Y so với xác suất kết hợp kỳ vọng nếu chúng độc lập thống kê:

$$lift(X \to Y, D) = \frac{P(X \cup Y)}{P(X)P(Y)}$$

- Ba trường hợp:
  - $lift(X \to Y, D) = 1$: không có sự kết hợp nào giữa X và Y (chúng độc lập).
  - $lift(X \to Y, D) > 1$: luật $X \to Y$ có ý nghĩa hoặc thú vị.
  - $lift(X \to Y, D) < 1$: luật $X \to Y$ và luật $Y \to X$ không có ý nghĩa hoặc không thú vị (trong phạm vi cơ sở dữ liệu D).

Độ đo Lift (tiếp theo)

- Lift đo lường mức độ bất ngờ của một luật.
- Lift là một độ đo có tính đối xứng.
- Giá trị Lift luôn lớn hơn hoặc bằng độ tin cậy.
- Lift có thể dễ bị ảnh hưởng bởi nhiễu trong các tập dữ liệu nhỏ, vì các luật với các tập mục hiếm, chỉ xuất hiện một vài lần, có thể có giá trị lift rất cao.

Ví dụ về độ đo Lift: Trường hợp AllElectronics

- Tính giá trị lift của luật $\{\text{games}\} \rightarrow \{\text{videos}\}$:

$$lift(\text{games} \rightarrow \text{videos}, \text{AllElectronics}) = \frac{\frac{4.000}{10.000}}{\frac{6.000}{10.000} \cdot \frac{7.500}{10.000}} = 0.89 < 1$$

- Luật $\{\text{games}\} \rightarrow \{\text{videos}\}$ không thú vị hoặc không có ý nghĩa.

Khai phá các tập mục phổ biến từ cơ sở dữ liệu này với minsup = 3

- Tập hợp tất cả các mục I:

$$I = \{A, B, C, D, E\}$$

- Cơ sở dữ liệu giao dịch $D = \{T_1, T_2, T_3, T_4, T_5, T_6\}$ như sau:
  - $T_1 = \{A, B, D, E\}$
  - $T_2 = \{B, C, E\}$
  - $T_3 = \{A, B, D, E\}$
  - $T_4 = \{A, B, C, E\}$
  - $T_5 = \{A, B, C, D, E\}$
  - $T_6 = \{B, C, D\}$

Giá trị lift của các luật được sinh ra từ tập mục phổ biến ABDE

- $ABD \rightarrow E$ ($sup = 3$, $conf = 1.0$ tức là 100%)

$$lift(ABD \rightarrow E, D) = \frac{\frac{3}{6}}{\frac{3}{6} \cdot \frac{5}{6}} = 1.2$$

- $ADE \rightarrow B$ ($sup = 3$, $conf = 1.0$ tức là 100%)

$$lift(ADE \rightarrow B, D) = \frac{\frac{3}{6}}{\frac{3}{6} \cdot \frac{6}{6}} = 1.0$$

- $BDE \rightarrow A$ ($sup = 3$, $conf = 1.0$ tức là 100%)

$$lift(BDE \rightarrow A, D) = \frac{\frac{3}{6}}{\frac{3}{6} \cdot \frac{4}{6}} = 1.5$$

- $DE \rightarrow AB$ ($sup = 3$, $conf = 1.0$ tức là 100%)

$$lift(DE \rightarrow AB, D) = \frac{\frac{3}{6}}{\frac{3}{6} \cdot \frac{4}{6}} = 1.5$$

Độ đo Lift (tiếp theo)

Luật	$rsup(X)$	$rsup(Y)$	$rsup(X \cup Y)$	$conf$	$lift$
$ACD \rightarrow E$	0.167	0.833	0.167	1.000	1.200
$AC \rightarrow E$	0.333	0.833	0.333	1.000	1.200
$AB \rightarrow D$	0.667	0.667	0.500	0.750	1.125
$A \rightarrow E$	0.667	0.833	0.667	1.000	1.200
$A \rightarrow DE$	0.667	0.500	0.500	0.750	1.500
$DE \rightarrow A$	0.500	0.667	0.500	1.000	1.500
$E \rightarrow C$	0.833	0.667	0.500	0.600	0.900
$C \rightarrow E$	0.667	0.833	0.500	0.750	0.900

Độ đo Leverage (Đòn bẩy)

- Leverage đo lường sự khác biệt giữa xác suất kết hợp quan sát được và kỳ vọng của XY giả định rằng X và Y là độc lập.

$$leverage(X \to Y, D) = P(XY) - P(X)P(Y)$$

$$= rsup(X \cup Y, D) - rsup(X, D)rsup(Y, D)$$

- Leverage cung cấp một thước đo "tuyệt đối" về mức độ bất ngờ của một luật và nó nên được sử dụng cùng với giá trị lift.
- Giống như lift, leverage có tính đối xứng.

Độ đo Leverage (tiếp theo)

Luật	$rsup(X)$	$rsup(Y)$	$rsup(X \cup Y)$	$conf$	$lift$	$leverage$
$ACD \rightarrow E$	0.167	0.833	0.167	1.000	1.200	0.028
$AC \rightarrow E$	0.333	0.833	0.333	1.000	1.200	0.056
$AB \rightarrow D$	0.667	0.667	0.500	0.750	1.125	0.056
$A \rightarrow E$	0.667	0.833	0.667	1.000	1.200	0.111
$A \rightarrow DE$	0.667	0.500	0.500	0.750	1.500	0.167
$DE \rightarrow A$	0.500	0.667	0.500	1.000	1.500	0.167
$E \rightarrow C$	0.833	0.667	0.500	0.600	0.900	-0.056
$C \rightarrow E$	0.667	0.833	0.500	0.750	0.900	-0.056

Độ đo Leverage (tiếp theo)

- Hai luật đầu tiên có cùng lift, tuy nhiên, leverage của luật thứ nhất bằng một nửa luật thứ hai, chủ yếu do độ hỗ trợ cao hơn của ACE.
- Do đó, nếu chỉ xem xét lift một cách độc lập có thể gây hiểu nhầm vì các luật có độ hỗ trợ khác nhau có thể có cùng lift.
- Luật thứ hai và thứ ba có lift khác nhau nhưng có cùng leverage.
- Cần xem xét leverage cùng với các số liệu khác bằng cách so sánh các luật thứ nhất, thứ hai và thứ tư, mặc dù có cùng lift, nhưng có giá trị leverage khác nhau.
- Luật $A \rightarrow E$ có thể được ưu tiên hơn vì nó đơn giản hơn và có leverage cao hơn.
- Giá trị leverage có thể âm (xem luật $E \rightarrow C$ và $C \rightarrow E$).

Độ đo Jaccard

- Hệ số Jaccard đo lường sự tương đồng giữa hai tập hợp. Khi được áp dụng như một độ đo đánh giá luật, nó tính toán sự tương đồng giữa các tập giao dịch của X và Y:

$$jaccard(X \rightarrow Y, D) = \frac{|T(X) \cap T(Y)|}{|T(X) \cup T(Y)|}$$

$$= \frac{P(XY)}{P(X) + P(Y) - P(XY)}$$

$$= \frac{sup(X \cup Y, D)}{sup(X, D) + sup(Y, D) - sup(X \cup Y, D)}$$

- trong đó $T(X)$ là tập hợp tất cả các giao dịch trong D chứa X, tương tự cho $T(Y)$.

Độ đo Jaccard (tiếp theo)

Luật	$rsup(X)$	$rsup(Y)$	$rsup(X \cup Y)$	*conf*	*lift*	*leverage*	*jaccard*
$ACD \rightarrow E$	0.167	0.833	0.167	1.000	1.200	0.028	0.200
$AC \rightarrow E$	0.333	0.833	0.333	1.000	1.200	0.056	0.400
$AB \rightarrow D$	0.667	0.667	0.500	0.750	1.125	0.056	0.600
$A \rightarrow E$	0.667	0.833	0.667	1.000	1.200	0.111	0.800
$A \rightarrow DE$	0.667	0.500	0.500	0.750	1.500	0.167	0.750
$DE \rightarrow A$	0.500	0.667	0.500	1.000	1.500	0.167	0.750
$E \rightarrow C$	0.833	0.667	0.500	0.600	0.900	-0.056	0.500
$C \rightarrow E$	0.667	0.833	0.500	0.750	0.900	-0.056	0.500

Độ đo Conviction (Sức thuyết phục)

- Conviction của một luật $X \rightarrow Y$ được tính như sau:

$$conviction(X \rightarrow Y, D) = \frac{P(X)P(\overline{Y})}{P(X\overline{Y})} = \frac{sup(X, D)sup(\overline{Y}, D)}{sup(X \cup \overline{Y}, D)}$$

$$= \frac{1}{lift(X \rightarrow \overline{Y}, D)}$$

- Giá trị conviction nằm trong khoảng $[0, +\infty)$.
  - *conviction* $= 1$: X và Y độc lập.
  - *conviction* < 1: luật không có ý nghĩa đáng kể.
  - *conviction* lớn: luật có ý nghĩa.

Độ đo Conviction (tiếp theo)

Luật	*conf*	*lift*	*leverage*	*jaccard*	*conviction*
$ACD \rightarrow E$	1.000	1.200	0.028	0.200	∞
$AC \rightarrow E$	1.000	1.200	0.056	0.400	∞
$AB \rightarrow D$	0.750	1.125	0.056	0.600	1.333
$A \rightarrow E$	1.000	1.200	0.111	0.800	∞
$A \rightarrow DE$	0.750	1.500	0.167	0.750	2.000
$DE \rightarrow A$	1.000	1.500	0.167	0.750	∞
$E \rightarrow C$	0.600	0.900	-0.056	0.500	0.833
$C \rightarrow E$	0.750	0.900	-0.056	0.500	0.667

Đánh giá mẫu và luật kết hợp

1. Đánh giá luật kết hợp
2. **So sánh các tập mục**
3. So sánh các luật

Các tập mục cực đại (Maximal itemsets)

- Một tập mục phổ biến X là **cực đại** nếu tất cả các tập cha của nó đều không phổ biến, tức là X là cực đại khi và chỉ khi:

$$sup(X) > minsup \text{ và đối với mọi } Y \supset X, sup(Y) < minsup$$

- Cho một tập hợp các tập mục phổ biến, chúng ta có thể chọn chỉ giữ lại các tập mục cực đại để tránh dư thừa.
- Tuy nhiên, để tạo ra tất cả các luật mạnh có thể có, chúng ta vẫn cần giữ lại tất cả các tập mục phổ biến.

Đánh giá mẫu và luật kết hợp

1. Đánh giá luật kết hợp
2. So sánh các tập mục
3. **So sánh các luật**

So sánh các luật

- Cho hai luật R và R' có cùng hệ quả (vế phải).

$$R : X \to Y$$

$$R' : W \to Y$$

- Chúng ta nói R cụ thể hơn R', hoặc tương đương, R' tổng quát hơn R nếu:

$$W \subset X$$

Các luật không dư thừa (Non-redundant rules)

- Một luật $R : X \rightarrow Y$ là dư thừa nếu tồn tại một luật tổng quát hơn $R' : W \rightarrow Y$ có cùng độ hỗ trợ, tức là $W \subset X$ và $sup(R) = sup(R')$.
- Mặt khác, nếu $sup(R) < sup(R')$ đối với tất cả các dạng tổng quát hóa R' của nó, thì R là không dư thừa. Các luật dư thừa phát sinh khi một hoặc nhiều mục trong tiền đề (vế trái) của luật độc lập với hệ quả.

Nội dung

1. Các khái niệm khai phá mẫu kết hợp
2. Khai phá luật kết hợp
3. Thuật toán vét cạn (Brute-force)
4. Thuật toán Apriori
5. Sinh các luật kết hợp
6. Thuật toán FP-Growth
7. Đánh giá mẫu và luật kết hợp
8. **Tài liệu tham khảo và Tổng kết**

Tài liệu tham khảo

1. J. Han, M. Kamber, and J. Pei. Data Mining: Concepts and Techniques. Morgan Kaufmann, Elsevier, 2012.
2. C. Aggarwal. Data Mining: The Textbook. Springer, 2015.
3. J. Leskovec, A. Rajaraman, and J. D. Ullman. Mining of Massive Datasets. Cambridge University Press, 2014.
4. M. J. Zaki and W. M. Jr. Data Mining and Analysis: Fundamental Concepts and Algorithms. Cambridge University Press, 2013.
5. D. Easley and J. Kleinberg. Networks, Crowds, and Markets: Reasoning About a Highly Connected World. Cambridge University Press, 2010.
6. J. VanderPlas. Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly, 2017.
7. J. Grus. Data Science from Scratch: First Principles with Python. O'Reilly, 2015.

Tổng kết

- Ý nghĩa và các ứng dụng tiềm năng của mẫu phổ biến và luật kết hợp.
- Các khái niệm cơ bản như mục, tập mục, giao dịch, cơ sở dữ liệu giao dịch, tập mục phổ biến, luật mạnh (đáng tin cậy), độ hỗ trợ và độ tin cậy.
- Dàn tập mục và thuật toán vét cạn để khai phá các mẫu phổ biến.
- Thuật toán Apriori, các tính chất Apriori và cách Apriori thực hiện để khám phá các mẫu phổ biến từ dữ liệu.
- Thuật toán sinh luật (cũng dựa trên các tính chất Apriori).
- Thuật toán FP-Growth với cây FP-Tree và việc sinh các tập mục phổ biến từ FP-Tree.
- Các tiêu chí để đánh giá luật kết hợp và một số độ đo khác như lift hoặc conviction bên cạnh độ hỗ trợ và độ tin cậy. Cách so sánh giữa các tập mục và giữa các luật.