Recommender systems

Trần Hồng Việt
VNU University of Engineering and Technology

Thế nào là một hệ thống gợi ý ?

Định nghĩa của Nvidia

*Hệ thống gợi ý (recommendation system) là một dạng thuật toán trí tuệ nhân tạo, thường gắn liền với các phương pháp học máy, khai thác dữ liệu quy mô lớn (big data) nhằm đề xuất hoặc khuyến nghị các **sản phẩm bổ sung** cho người dùng. Các đề xuất này có thể được xây dựng dựa trên nhiều tiêu chí khác nhau, bao gồm **lịch sử mua hàng, lịch sử tìm kiếm, thông tin nhân khẩu học**, cùng với các yếu tố liên quan khác. Hệ thống gợi ý đóng vai trò quan trọng trong thực tiễn, khi hỗ trợ người dùng khám phá các sản phẩm và dịch vụ mà họ có thể khó tự tìm thấy thông qua các phương thức truyền thống.*

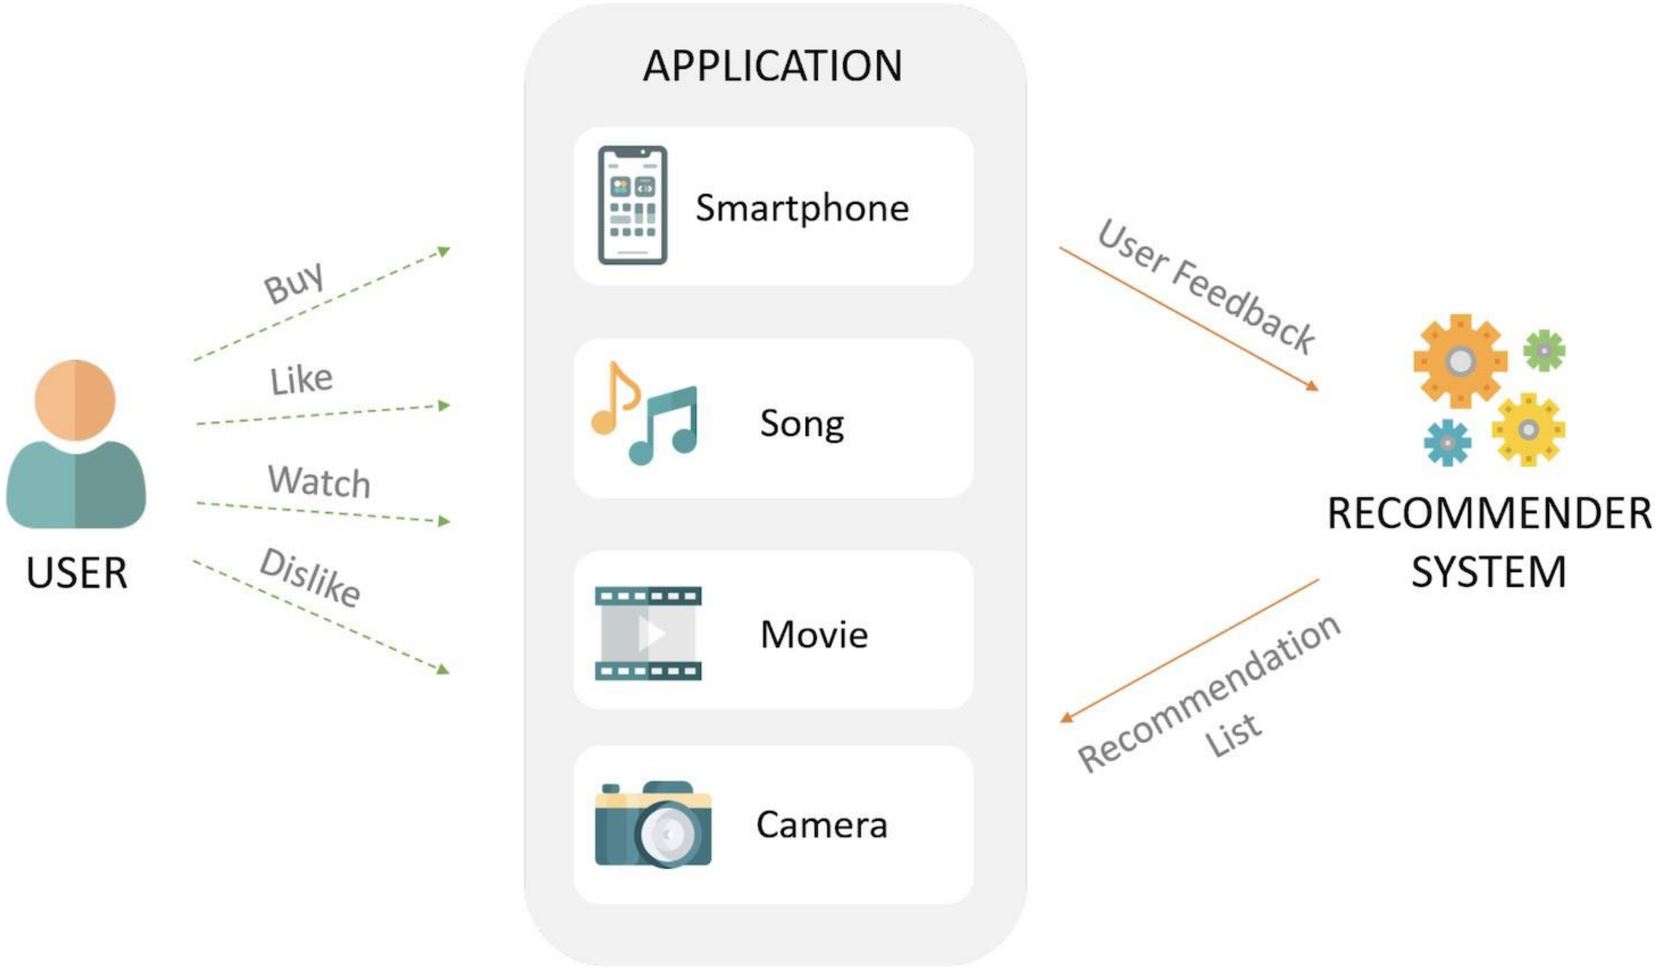
Định nghĩa từ Wikipedia

*Hệ thống gợi ý (recommender system) là một phân lớp của **các hệ thống lọc thông tin** (information filtering systems), có chức năng cung cấp các đề xuất về những mục (items) **phù hợp nhất** đối với một người dùng cụ thể.*

Định nghĩa từ ChatGPT

Hệ thống gợi ý (recommender system) là một dạng của hệ thống lọc thông tin, có nhiệm vụ dự đoán và đề xuất các mục (items) cho người dùng dựa trên hành vi trong quá khứ, sở thích và mối quan tâm của họ. Hệ thống này được ứng dụng rộng rãi trong thương mại điện tử, mạng xã hội, các nền tảng nội dung trực tuyến, cũng như nhiều lĩnh vực khác, nơi các đề xuất mang tính cá nhân hóa có thể nâng cao đáng kể trải nghiệm người dùng.

Thế nào là một hệ thống gợi ý? (cont'd)



[source: Internet]

Hai cách tiếp cận để xây dựng hệ thống gợi ý

- Gợi ý là 1 bài toán dự đoán
- Gợi ý là một bài toán xếp hạng

Gợi ý là 1 bài toán dự đoán

- Dự đoán giá trị đánh giá cho một cặp người dùng–vật phẩm.
- Giả định rằng có sẵn dữ liệu huấn luyện thể hiện sở thích của người dùng đối với các vật phẩm. Với m người dùng và n vật phẩm, các đánh giá của người dùng được biểu diễn dưới dạng một ma trận $m \times n$ chưa đầy đủ.
- Các giá trị đã được quan sát (tồn tại) được sử dụng để huấn luyện (ví dụ: một mô hình gợi ý). Các giá trị chưa được quan sát (bị thiếu) sẽ được dự đoán bằng mô hình.
- Bài toán này còn được gọi là bài toán hoàn thiện ma trận .

Gợi ý là một bài toán xếp hạng

- Không nhất thiết phải dự đoán các giá trị đánh giá bị thiếu để đưa ra khuyến nghị. Thay vào đó có thể:
- Đề xuất top–k vật phẩm cho một người dùng cụ thể
- Xác định top–k người dùng phù hợp cho một vật phẩm cụ thể.
- Việc xác định top–k vật phẩm phổ biến hơn so với việc xác định top–k người dùng. Bài toán này còn được gọi là bài toán khuyến nghị top–k (top–k recommendation problem). Trong cách tiếp cận này, giá trị tuyệt đối của các điểm đánh giá dự đoán không còn quan trọng.
- Thứ hạng có thể được xây dựng dựa trên các giá trị dự đoán trong cách tiếp cận thứ nhất. Tuy nhiên, việc giải trực tiếp bài toán xếp hạng thường đơn giản và tự nhiên hơn.

Goals of recommender systems

- Mục tiêu hướng đến doanh nghiệp (business–centric goals): các mục tiêu chính của hệ thống gợi ý là gia tăng hoạt động của người dùng (xem, xem video, thích, chia sẻ, thêm vào giỏ hàng, v.v.), mức độ chú ý, trải nghiệm người dùng và mức độ tương tác; đồng thời, cuối cùng là tăng sản lượng bán hàng, doanh thu và lợi nhuận của dịch vụ kinh doanh.

- Các mục tiêu vận hành và kỹ thuật:

1. Độ liên quan (Relevance)
2. Tính mới (Novelty)
3. Tính bất ngờ thú vị (Serendipity)
4. Đa dạng (Diversity)
5. Khai thác phân phối đuôi dài (Long-tail)
6. Công bằng (Fairness)
7. Các mục tiêu khác phụ thuộc vào bối cảnh kinh doanh và miền ứng dụng cụ thể.

Goals of recommender systems (cont'd)

- 1. Độ liên quan (Relevance): đề xuất các vật phẩm phù hợp với người dùng:
  - Người dùng có xu hướng tiêu thụ những vật phẩm mà họ thấy thú vị; hoặc
  - Những vật phẩm phù hợp với nhu cầu và ý định của họ (ví dụ: ý định mua hàng).
- 2. Tính mới (Novelty): đề xuất các vật phẩm mà người dùng chưa từng thấy trước đây.
  - Ví dụ, các bộ phim phổ biến thuộc thể loại ưa thích hiếm khi mang tính mới đối với người dùng.
  - Việc lặp lại các đề xuất phổ biến cũng có thể làm giảm sự đa dạng trong doanh số.
- 3. Tính bất ngờ thú vị (Serendipity): các vật phẩm được đề xuất thực sự gây bất ngờ cho người dùng.
  - Không chỉ đơn thuần là những thứ họ chưa biết trước đó.
  - Điều này tương ứng với dạng "unknown unknown", trong khi novelty là "unknown known".
  - Serendipity có tác dụng tích cực là tăng sự đa dạng doanh số hoặc khởi tạo một xu hướng quan tâm mới ở người dùng.
  - Các gợi ý mang tính serendipity thường có xu hướng ít liên quan ở giai đoạn đầu

Goals of recommender systems (cont'd)

- Đa dạng (Diversity): khi tất cả các vật phẩm được đề xuất quá giống nhau, nguy cơ người dùng không thích bất kỳ vật phẩm nào sẽ tăng lên. Tính đa dạng giúp đảm bảo rằng người dùng không cảm thấy nhàm chán do các đề xuất lặp lại và tương tự nhau.
- Long–tail: các hệ thống gợi ý thường bỏ qua những vật phẩm không phổ biến hoặc mới được đưa vào, vốn chỉ có rất ít đánh giá. Việc khai thác các vật phẩm ở phần đuôi dài của phân phối là rất quan trọng.
- Công bằng (Fairness): khái niệm này liên quan đến các nhóm người dùng dựa trên chủng tộc, giới tính, độ tuổi, v.v. Ví dụ, một hệ thống gợi ý việc làm cần đảm bảo tính công bằng khi đề xuất công việc cho các nhó chủng tộc và giới tính khác nhau.
- Các mục tiêu khác theo bối cảnh kinh doanh và miền ứng dụng: điều này phụ thuộc vào từng ứng dụng cụ thể. Một số lĩnh vực yêu cầu cung cấp giải thích cho các vật phẩm được đề xuất; một số cần đề xuất trực tiếp, trong khi một số khác sử dụng các hình thức gợi ý gián tiếp.

Some typical recommender systems

- Hệ thống gợi ý GroupLens:
  - Một hệ thống gợi ý nguyên mẫu tiên phong (ban đầu dùng để gợi ý tin Usenet), sau đó được mở rộng sang gợi ý sách và phim như BookLens và MovieLens.
  - GroupLens hiện là một phòng thí nghiệm nghiên cứu tại Đại học Minnesota, với nhiều đóng góp tiên phong trong lĩnh vực lọc cộng tác (collaborative filtering).
  - Nhóm này cũng đã công bố các bộ dữ liệu quan trọng trong lĩnh vực, chẳng hạn như MovieLens với nhiều kích thước khác nhau.
- Hệ thống gợi ý của Amazon.com:
  - Là một trong những hệ thống tiên phong trong lĩnh vực gợi ý, đặc biệt trong thương mại điện tử. Ban đầu tập trung vào gợi ý sách, sau đó mở rộng sang hầu như tất cả các loại sản phẩm.
  - Các gợi ý của Amazon dựa trên cả đánh giá ngầm (implicit ratings) như hành vi duyệt và mua hàng, cũng như đánh giá tường minh (explicit ratings) (thang điểm 5, từ 1 sao đến 5 sao).
  - Hệ thống gợi ý được xây dựng dựa trên cả lọc cộng tác theo vật phẩm (item-based collaborative filtering) và các mẫu phổ biến (frequent patterns) (ví dụ: thường được mua cùng nhau, mua cái này th cũng mua cái kia).

Some typical recommender systems (cont'd)

- Hệ thống gợi ý phim của Netflix:
  - Việc gợi ý được xây dựng dựa trên thang đánh giá 5 mức.
  - Hệ thống cung cấp các giải thích có ý nghĩa cho những vật phẩm được đề xuất tới người dùng.
- Cuộc thi Netflix Prize: nhằm dự đoán các giá trị đánh giá cho các cặp người dùng–vật phẩm cụ thể.
  - Tập dữ liệu huấn luyện: 100,480,507 đánh giá (480,189 người dùng và 17,770 bộ phim), bao gồm:
    - Probe set: 1,408,395 đánh giá.
  - Tập dữ liệu đánh giá (Qualifying): 2,817,131 đánh giá (được ẩn), bao gồm:
    - Quiz set: 1,408,342 đánh giá; dùng để tính điểm bảng xếp hạng.
    - Test set: 1,408,789 đánh giá; dùng để xác định đội chiến thắng.
  - Dữ liệu không chứa thông tin nào về người dùng và phim ngoài ID và các đánh giá.
  - Các dự đoán được nộp sẽ được chấm điểm so với giá trị thực bằng chỉ số RMSE.
  - Việc xếp hạng dựa trên mức cải thiện so với thuật toán riêng của Netflix là Cinematch.
  - Giải thưởng lớn trị giá 1 triệu USD đã được trao cho nhóm BellKor's Pragmatic Chaos vào năm 2009.

Some typical recommender systems (cont'd)

- Hệ thống cá nhân hóa tin tức của Google:
  - Đề xuất các tin tức cho người dùng dựa trên lịch sử nhấp chuột của họ.
  - Các bài báo được xem như các vật phẩm. Việc người dùng nhấp vào một bài báo được coi là một đánh giá dương (positive rating). Các gợi ý được xây dựng dựa trên lọc cộng tác (collaborative filtering) với các đánh giá ngầm này.
- Gợi ý kết bạn trên Facebook:
  - Đề xuất các bạn bè tiềm năng cho người dùng nhằm tăng cường các kết nối xã hội. Mục tiêu này có phần khác so với gợi ý sản phẩm.
  - Bài toán này còn được gọi là dự đoán liên kết (link prediction) trong lĩnh vực phân tích mạng xã hội. Các gợi ý được xây dựng dựa trên các mối quan hệ cấu trúc thay vì dữ liệu đánh giá.

Some typical recommender systems (cont'd)

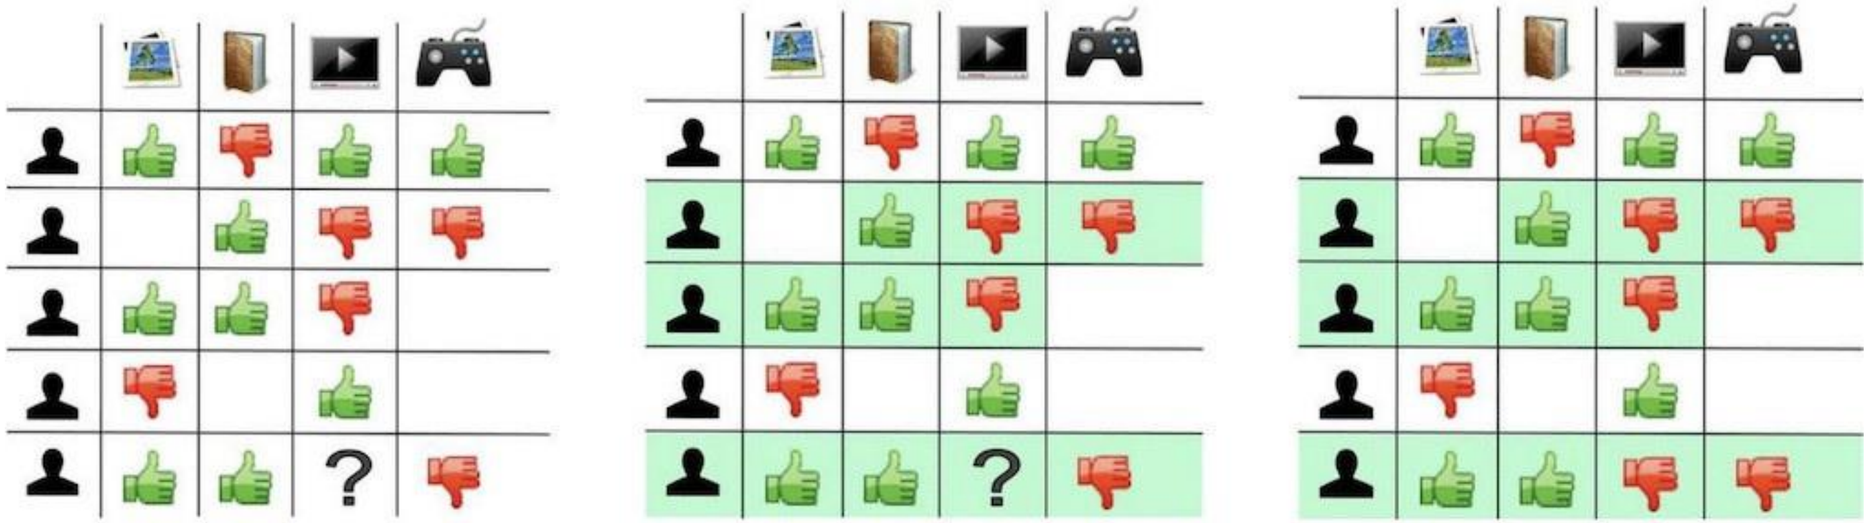
Hệ thống	Lĩnh vực
MovieLens	Phim
Amazon.com	Thương mại điện tử
Netflix	DVD và video
Google News	Tin tức online
Google Search	Quảng cáo
Facebook	Bạn bè và quảng cáo
Pinterest	Ảnh
Tiktok	Video ngắn
Youtube	Video
Pandora	Âm nhạc
Spotify	Âm nhạc
Tripadvisor	Sản phẩm du lịch

Major approaches to building recommender systems

- Hệ thống gợi ý dựa trên lọc cộng tác (Collaborative filtering recommender systems)
- Hệ thống gợi ý dựa trên nội dung (Content–based recommender systems)
- Hệ thống gợi ý dựa trên tri thức (Knowledge–based recommender systems)
- Hệ thống gợi ý lai và dựa trên tổ hợp mô hình (Hybrid and ensemble–based recommender systems)

Collaborative filtering recommender systems

- Lọc cộng tác (Collaborative Filtering – CF) là một phương pháp dự đoán sở thích của người dùng bằng cách thu thập thông tin về sở thích hoặc thị hiếu từ nhiều người dùng khác.
  - Giả định cốt lõi của CF là: nếu một người dùng có cùng quan điểm với người dùng về một vấn đề, thì có nhiều khả năng sẽ có cùng quan điểm với về một vấn đề khác, hơn là so với một người được chọn ngẫu nhiên.
- Các mô hình lọc cộng tác khai thác sức mạnh tổng hợp từ các đánh giá do nhiều người dùng cung cấp để đưa ra các khuyến nghị.

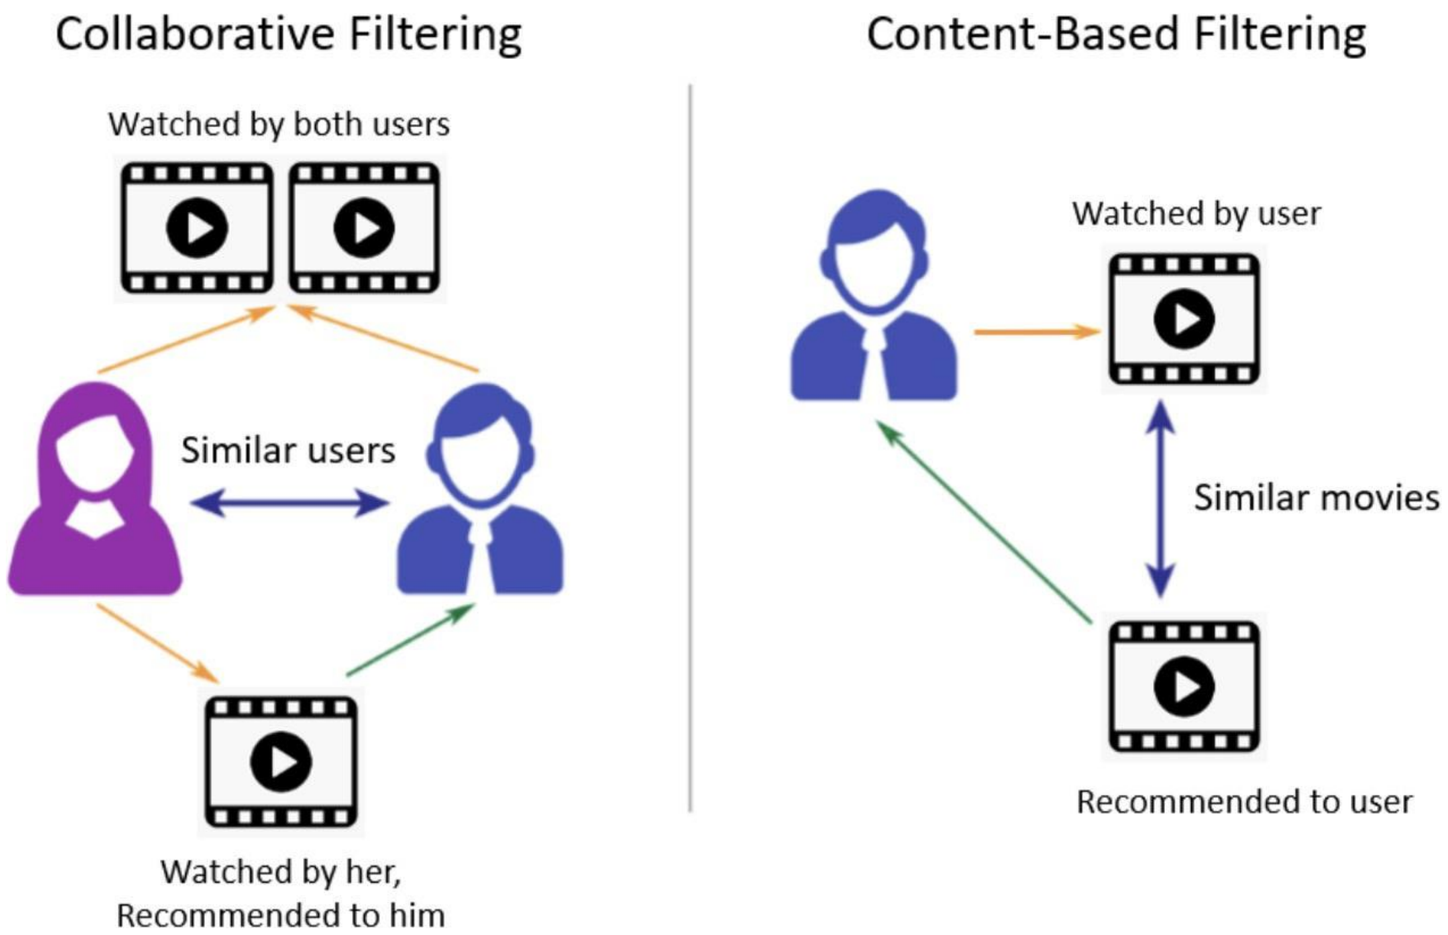


[source: Internet]

Content–based recommender systems

- Ý tưởng chính của hệ thống gợi ý dựa trên nội dung (content–based recommendation) là đề xuất các vật phẩm tương tự với những vật phẩm mà người dùng đã tương tác trong quá khứ. “Tương tác” ở đây bao gồm:
  - Các hành vi của người dùng: duyệt, đọc, xem, thêm vào giỏ hàng, mua, chia sẻ, v.v.; hoặc
  - Các đánh giá tường minh của người dùng đối với vật phẩm.
- Các gợi ý cho một người dùng cụ thể được xây dựng dựa trên các thông tin sau:
  - Các thuộc tính mô tả và nội dung của vật phẩm;
  - Thông tin cơ bản của người dùng, ví dụ: thông tin nhân khẩu học (giới tính, độ tuổi, v.v.) nếu có;
  - Hành vi của người dùng trong quá khứ, tức là lịch sử tương tác của họ.
- Không có sự cộng tác giữa các người dùng, tức là các gợi ý cho mỗi người dùng là độc lập với nhau.
- Hệ thống gợi ý dựa trên nội dung có những ưu điểm và hạn chế riêng khi so sánh với lọc cộng tác (CF).

Content–based versus collaborative filtering



[source: Internet]

Knowledge–based recommender systems

- Hệ thống gợi ý dựa trên tri thức (knowledge–based recommender systems) đặc biệt hữu ích đối với các vật phẩm không được mua thường xuyên, tức là số lượng đánh giá có thể không đủ để phục vụ việc gợi ý.
  - Ví dụ: bất động sản, ô tô, dịch vụ tài chính hoặc các hàng hóa xa xỉ có giá trị cao. Với các loại vật phẩm này, sở thích của người dùng cũng có thể thay đổi theo thời gian.
- Các gợi ý được xây dựng dựa trên sự tương đồng giữa yêu cầu của khách hàng và mô tả của vật phẩm, hoặc dựa trên các ràng buộc do người dùng đưa ra.
  - Hệ thống dựa trên tri thức cho phép người dùng xác định rõ ràng những gì họ mong muốn. Việc chỉ định tường minh này giúp người dùng có mức độ kiểm soát cao hơn đối với quá trình gợi ý.

Approach	**Conceptual Goal**	**Input**
Collaborative	Give me recommendations based on a collaborative approach that leverages the ratings and actions of my peers/myself.	User ratings + community ratings
Content-based	Give me recommendations based on the content (attributes) I have favored in my past ratings and actions.	User ratings + item attributes
Knowledge-based	Give me recommendations based on my explicit specification of the kind of content (attributes) I want.	User specification + item attributes + domain knowledge

Hybrid and ensemble–based recommender systems

- Trong nhiều trường hợp, có sẵn nhiều loại dữ liệu đầu vào khác nhau:
  - Thông tin nhân khẩu học của người dùng: giới tính, độ tuổi, vị trí, sở thích trước đây, v.v
  - Thông tin về vật phẩm: thể loại, mô tả nội dung, thẻ (tags), v.v.
  - Đánh giá của người dùng: đánh giá ngầm (implicit) hoặc tường minh (explicit), v.v.
- Trong những trường hợp như vậy, cách tiếp cận lai (hybrid) là phù hợp để tận dụng tất cả các loại dữ liệu.
  - Kết hợp các phương pháp như lọc cộng tác (CF), dựa trên nội dung (content–based), dựa trên tri thức (knowledge–based), v.v., nhằm khai thác ưu điểm của từng phương pháp.
- Một số kịch bản xây dựng hệ thống gợi ý lai:
  - Bổ sung thông tin nội dung vào hệ thống CF.
  - Bổ sung thông tin CF vào hệ thống dựa trên nội dung.
  - Bổ sung tri thức vào hệ thống CF hoặc hệ thống dựa trên nội dung.

Context and social factors in recommender systems

- Thông tin trạng thái hoặc điều kiện:
  - Nhận biết ngữ cảnh (context–aware): các khuyến nghị cũng dựa trên thông tin bổ sung (nếu có). Ví dụ: người dùng đang độc thân, vừa kết hôn, đang mang thai
- Thông tin thời gian (Temporal information):
  - Tích hợp yếu tố thời gian: thời điểm trong ngày, mùa, ngày lễ, vòng đời sản phẩm, v.v.
- Thông tin vị trí (Location information):
  - Các khuyến nghị cũng dựa trên vị trí hiện tại của người dùng hoặc vật phẩm (nếu có).
  - Ví dụ: gợi ý các khách sạn, nhà hàng gần nhất.
- Thông tin xã hội (Social information):
  - Các khuyến nghị cũng dựa trên các thẻ xã hội, tín hiệu xã hội, thông tin lan truyền, xu hướng trên mạng xã hội, v.v.

Challenges and advanced topics in recommender systems

- Bài toán dữ liệu thưa (The sparse data problem)
- Bài toán khởi đầu lạnh trong hệ thống gợi ý (The cold–start problem in recommender systems)
- Khả năng mở rộng trong hệ thống gợi ý (Scalability in recommender systems)
- Hệ thống gợi ý chống chịu tấn công (Attack–resistant recommender systems)
- Hệ thống gợi ý cho nhóm (Group recommender systems)
- Hệ thống gợi ý đa tiêu chí (Multi–criteria recommender systems)
- Quyền riêng tư trong hệ thống gợi ý (Privacy in recommender systems)

The sparse data problem

- Tương tác và đánh giá của người dùng bị hạn chế, dẫn đến ma trận đánh giá rất thưa (sparse).
- Điều này gây khó khăn trong việc tính toán độ tương đồng giữa người dùng và giữa các vật phẩm.
  - Hai vật phẩm rất giống nhau có thể không được cùng một nhóm người dùng đánh giá.
  - Hai người dùng có sở thích tương tự nhau cũng có thể không đánh giá cùng một vật phẩm.
- Dữ liệu thưa dẫn đến độ bao phủ (coverage) thấp (ví dụ: các vật phẩm thuộc phần long–tail).
- Giải pháp:
  - Sử dụng phân rã ma trận (matrix factorization), phân tích chủ đề (topic analysis), giảm chiều (dimensionality reduction), embedding, v.v.
  - Các phương pháp dựa trên đồ thị (graph–based methods).
  - Kết hợp lọc cộng tác (CF) và phương pháp dựa trên nội dung (content–boosted).

The cold–start problem in recommender systems

- Bài toán người dùng mới (The new user problem):
  - Chưa đánh giá bất kỳ vật phẩm nào.
  - Không có thông tin lịch sử (tương tác, hành vi, v.v.).
- Bài toán vật phẩm mới (The new item problem):
  - Chưa được bất kỳ người dùng nào đánh giá
  - Thậm chí chưa từng được xem hoặc mua.
- Giải pháp:
  - Ở giai đoạn ban đầu, đề xuất các vật phẩm phổ biến (hot), được ưa chuộng, hoặc gợi ý ngẫu nhiên.
  - Với bài toán vật phẩm mới: tính toán độ tương đồng dựa trên thông tin của vật phẩm.
  - Với bài toán người dùng mới: tính toán độ tương đồng dựa trên thông tin nhân khẩu học
  - Kết hợp lọc cộng tác (CF) và phương pháp dựa trên nội dung theo nhiều cách khác nhau.

The scalability in recommender systems

- Ma trận đánh giá thường có kích thước rất lớn (hàng triệu × hàng triệu).
- Việc tính toán trên các ma trận lớn như vậy rất tốn thời gian:
  - Tính toán độ tương đồng giữa người dùng hoặc giữa các vật phẩm.
  - Tìm k láng giềng gần nhất (k người dùng tương tự nhất).

- Trong khi đó, các hệ thống gợi ý thường yêu cầu phản hồi theo thời gian thực hoặc gần thời gian thực.
- Giải pháp:
  - Giảm chiều dữ liệu bằng các phương pháp như PCA, SVD, v.v.
  - Lọc cộng tác dựa trên vật phẩm (item–based CF) thường nhanh hơn và ổn định hơn so với dựa trên người dùng (user–based CF).
  - Xây dựng các hệ thống dựa trên mô hình (model–based), thường có thời gian huấn luyện lớn nhưng suy luận nhanh hơn.

Attack–resistant recommender systems

- Điều này thường xảy ra trên các nền tảng có nhiều đối thủ cạnh tranh.
- Ví dụ: trên một sàn thương mại điện tử, một số người bán có thể gửi các đánh giá bị thổi phồng cho sản phẩm của chính họ nhằm thao túng thứ hạng gợi ý, đồng thời đưa ra các đánh giá thiên lệch hoặc tiêu cực đối với sản phẩm của đối thủ cạnh tranh.
- Đã có nhiều chiến lược tinh vi được phát triển nhằm tấn công các hệ thống gợi ý.

Group recommender systems

- Khuyến nghị cho một nhóm thay vì cho một người dùng đơn lẻ.
- Ví dụ:
  - Một gia đình cùng xem phim hoặc chương trình truyền hình.
  - Một nhóm bạn cùng đi nhà hàng.
  - Gợi ý du lịch cho một gia đình.
- Việc đưa ra khuyến nghị cho nhóm phức tạp hơn so với cho một cá nhân.
- Việc kết hợp đơn giản sở thích hoặc thị hiếu của các cá nhân thường không thực sự hiệu quả.

Multi–criteria recommender systems

- Các vật phẩm trong nhiều lĩnh vực thường có nhiều khía cạnh khác nhau.
- Ví dụ:
  - Khách sạn: phòng, tầm nhìn, bữa sáng, wifi, lễ tân, vị trí gần trung tâm, v.v.
  - Phim: kịch bản, diễn xuất, đồ họa, âm nhạc, v.v.
  - Điện thoại thông minh: thương hiệu, màn hình, pin, độ ổn định, phần mềm và ứng dụng.
- Hai người dùng có cùng điểm đánh giá không nhất thiết có cùng sở thích hoặc thị hiếu.
- Các hệ thống gợi ý đa tiêu chí (multi–criteria systems) giúp xếp hạng các vật phẩm khi xem xét đồng thời nhiều khía cạnh khác nhau.

Privacy in recommender systems

- Các hệ thống gợi ý phụ thuộc rất nhiều vào phản hồi từ người dùng, có thể là phản hồi ngầm (implicit) hoặc tường minh (explicit).
- Những phản hồi này chứa đựng nhiều thông tin quan trọng về sở thích và mối quan tâm của người dùng. Ví dụ:
  - Sở thích cá nhân
  - Tiêu chuẩn thẩm mỹ
  - Quan điểm chính trị

  v.v.
- Những thông tin này có thể rất nhạy cảm, dẫn đến các vấn đề về quyền riêng tư. Do đó, việc bảo vệ quyền riêng tư trong hệ thống gợi ý là vô cùng quan trọng.

Types of collaborative filtering

- Các phương pháp CF dựa trên bộ nhớ (Memory-based CF): còn được gọi là CF dựa trên lân cận (neighborhood-based CF). Các đánh giá (ratings) của các cặp người dùng–mặt hàng được dự đoán dựa trên các "lân cận" của chúng. Các lân cận này có thể được xác định theo một trong hai cách sau:
  CF dựa trên người dùng (User-based CF): khuyến nghị được xây dựng dựa trên sự tương đồng giữa các người dùng.
  CF dựa trên mặt hàng (Item-based CF): khuyến nghị được xây dựng dựa trên sự tương đồng giữa các mặt hàng.
  - Các phương pháp dựa trên bộ nhớ dễ triển khai.
  - Các khuyến nghị tạo ra thường dễ giải thích.
  - Tuy nhiên, chúng hoạt động không tốt với các ma trận đánh giá thưa
- Các phương pháp CF dựa trên mô hình (Model-based CF): sử dụng các phương pháp học máy và khai phá dữ liệu trong bối cảnh các mô hình dự đoán. Các phương pháp điển hình bao gồm: cây quyết định, phương pháp Bayes, hoặc các mô hình nhân tố tiềm ẩn (latent factor models).
  - Các mô hình này được tham số hóa và tối ưu hóa; phức tạp hơn để triển khai.
  - Xử lý tốt hơn các ma trận đánh giá thưa.

Types of user ratings



source: from book [8]

- Đánh giá đơn: {thích} (ví dụ: nút "like" trên Facebook; không có cách thể hiện "không thích").
- Đánh giá nhị phân: {thích, không thích}.
- Thang đánh giá 5 mức: {1, 2, 3, 4, 5} hoặc {−2, −1, 0, 1, 2}.
  - Một số lựa chọn khác là thang 7 mức hoặc 10 mức.
- Giá trị đánh giá liên tục: ví dụ, bất kỳ giá trị thực nào trong khoảng [−10, 10].

Explicit ratings versus implicit ratings

- Đánh giá tường minh: người dùng trực tiếp đánh giá các mặt hàng bằng các thang đo như unary, nhị phân, thang 5 mức, v.v.
- Đánh giá ngầm (Implicit ratings): người dùng không thực sự đánh giá trực tiếp.
- Các giá trị đánh giá được suy ra từ hành vi của người dùng như duyệt, đọc, xem, thêm vào giỏ hàng, mua, chia sẻ, v.v.
- Các giá trị này phụ thuộc vào loại hành động, ví dụ: việc mua một sản phẩm có trọng số cao hơn so với chỉ xem qua sản phẩm đó.

Rating matrices

- I là tập gồm n mặt hàng trong hệ thống (ví dụ: n sản phẩm, n bộ phim, …)
- U là tập gồm m người dùng của hệ thống
- R = {rui} là ma trận m × n biểu diễn đánh giá người dùng – mặt hàng
- Trong đó rui ∈ R là giá trị đánh giá của mặt hàng i do người dùng u đưa ra
- rui là giá trị đánh giá của mặt hàng i do người dùng u đưa ra
- Thông thường chỉ một phần nhỏ các đánh giá được cung cấp hoặc quan sát
- Phần lớn các đánh giá bị thiếu (chưa được cung cấp hoặc chưa được quan sát)
- Do đó, R thường là một ma trận rất thưa
- Ma trận đánh giá còn được gọi là User–Item Matrix hoặc Utility Matrix
- Có hai loại ma trận đánh giá: Explicit rating matrix và Implicit rating matrix

Examples of user–item rating matrices [8]

	GLADITOR	GODFTHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			5		2
U_2		5			4	
U_3	5	3		1		
U_4			3			4
U_5				3	5	
U_6	5		4			

(a) Ordered ratings

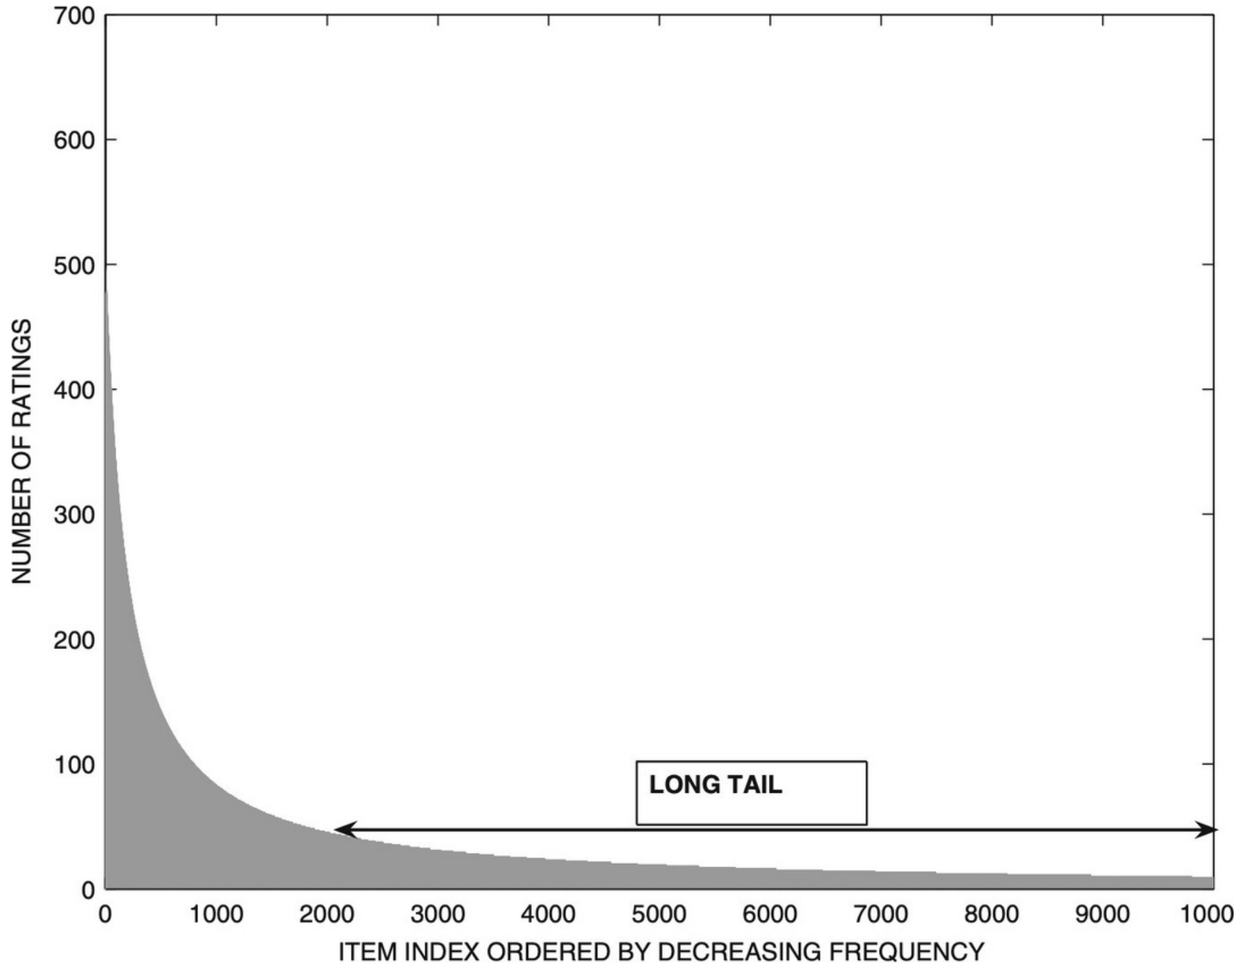
	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			1		1
U_2		1			1	
U_3	1	1		1		
U_4			1			1
U_5				1	1	
U_6	1		1			

(b) Unary ratings

The long–tail of rating frequencies

- Chỉ một phần nhỏ các mặt hàng được đánh giá thường xuyên — đó là các mặt hàng phổ biến
- Phần lớn các mặt hàng ít khi được đánh giá, dẫn đến phân bố đánh giá bị lệch mạnh (skewed)
  - Các mặt hàng có tần suất cao thường mang tính cạnh tranh cao và lợi nhuận thấp
  - Việc khuyến nghị các mặt hàng tần suất thấp mang lại lợi ích cho nhà bán hàng
  - Các mặt hàng có tần suất thấp thường có biên lợi nhuận cao hơn
  - Amazon.com: phần lớn lợi nhuận đến từ việc bán các mặt hàng thuộc “long tail”
- Trên thực tế, nhiều thuật toán gợi ý
  - Có xu hướng đề xuất các mặt hàng phổ biến thay vì các mặt hàng ít phổ biến
  - Ảnh hưởng tiêu cực đến tính đa dạng, khiến người dùng dễ nhàm chán khi liên tục nhận các gợi ý giống nhau
- Vì vậy, cần xem xét bài toán “long-tail” khi thiết kế các hệ thống gợi ý

The long–tail of rating frequencies (cont'd)



source: from the textbook [8]

Neighborhood–based collaborative filtering

- Dự đoán đánh giá bằng các phương pháp dựa trên lân cận (Predicting ratings with neighborhood based methods)
- Phân cụm và các phương pháp dựa trên lân cận (Clustering and neighborhood–based methods)
- Giảm chiều dữ liệu và các phương pháp dựa trên lân cận (Dimensionality reduction and neighborhood methods)
- Mô hình đồ thị cho các phương pháp dựa trên lân cận (Graph models for neighborhood–based methods)

Neighborhood–based CF recommender systems

- **Dự đoán đánh giá bằng các phương pháp dựa trên lân cận (Predicting ratings with neighborhood–based methods)**
- Phân cụm và các phương pháp dựa trên lân cận (Clustering and neighborhood–based methods)
- Giảm chiều và các phương pháp dựa trên lân cận (Dimensionality reduction and neighborhood methods)
- Mô hình đồ thị cho các phương pháp dựa trên lân cận (Graph models for neighborhood–based methods)

Predicting ratings with neighborhood–based methods

- Ý tưởng của các phương pháp dựa trên lân cận (neighborhood-based) là đưa ra gợi ý dựa trên:
  - độ tương đồng giữa người dùng–người dùng
  - độ tương đồng giữa mặt hàng–mặt hàng được tính từ ma trận đánh giá
- "Neighborhood": xác định các người dùng tương tự hoặc các mặt hàng tương tự
- Hai nguyên lý cơ bản trong mô hình này:
  - User-based: những người dùng giống nhau sẽ có đánh giá giống nhau trên cùng một mặt hàng; vì vậy nếu Alice và Bob đã đánh giá phim giống nhau trong quá khứ thì có thể dùng đánh giá của Alice cho phim Terminator để dự đoán đánh giá của Bob cho phim này
  - Item-based: những mặt hàng giống nhau sẽ được cùng một người dùng đánh giá giống nhau; vì vậy có thể dùng đánh giá của Bob cho các phim khoa học viễn tưởng tương tự như Alien và Predator để dự đoán đánh giá của anh ấy cho Terminator

User–based neighborhood methods

- Gọi u, v ∈ U là hai người dùng, tương ứng với hai hàng trong ma trận đánh giá
- Gọi Iu và Iv lần lượt là tập các chỉ số mặt hàng (cột) mà người dùng u và v đã đánh giá

- Khi đó, Iu ∩ Iv là tập các mặt hàng mà cả u và v đều đã đánh giá
- Ví dụ:
  - Iu = {1, 3, 5} nghĩa là u chỉ đánh giá các mặt hàng thứ 1, 3 và 5
  - Iv = {1, 2, 3, 4} nghĩa là v chỉ đánh giá các mặt hàng thứ 1, 2, 3 và 4
  - Iu ∩ Iv = {1, 3} nghĩa là cả u và v cùng đánh giá các mặt hàng 1 và 3
- Trong thực tế, thường xảy ra trường hợp Iu ∩ Iv = ∅ vì ma trận đánh giá thường rất thưa (sparse)
- Vậy làm thế nào để tính độ tương đồng (về sở thích) giữa u và v?

Computing user–user similarity using cosine

- Độ tương đồng cosine giữa người dùng u và v được định nghĩa như sau:

$$\begin{aligned} \mathrm{Sim}(u,v) &= \mathrm{Cosine}(u,v) \\ &= \frac{\sum_{k \in I_u \cap I_v} r_{uk} \cdot r_{vk}}{\sqrt{\sum_{k \in I_u \cap I_v} r_{uk}^2} \cdot \sqrt{\sum_{k \in I_u \cap I_v} r_{vk}^2}} \end{aligned} \tag{1}$$

trong đó ruk và rvk lần lượt là giá trị đánh giá của người dùng u và v trên mặt hàng k

- Tuy nhiên, nếu các người dùng có thang đánh giá khác nhau thì sao? Ví dụ, một người có xu hướng thích hầu hết các mặt hàng, trong khi người khác lại có xu hướng không thích phần lớn các mặt hàng
- Hệ số tương quan Pearson là một cách để xử lý sự khác biệt về thang đánh giá này

Computing user–user similarity using Pearson correlation

Hệ số tương quan Pearson giữa người dùng u và v được định nghĩa như sau:

$$\begin{aligned}\mathrm{Sim}(u,v) &= \mathrm{Pearson}(u,v) \\ &= \frac{\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u) \cdot (r_{vk} - \mu_v)}{\sqrt{\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u)^2} \cdot \sqrt{\sum_{k \in I_u \cap I_v} (r_{vk} - \mu_v)^2}}\end{aligned} \tag{2}$$

Trong đó μu và μv lần lượt là giá trị trung bình các đánh giá của người dùng u và v
ruk và rvk lần lượt là giá trị đánh giá của người dùng u và v trên mặt hàng k

Computing user–user similarity using Pearson correlation (cont'd)

- Có hai cách để tính μ_u và μ_V:

$$\mu_u = \frac{\sum_{k \in I_u \cap I_v} r_{uk}}{|I_u \cap I_v|} \quad \text{and} \quad \mu_v = \frac{\sum_{k \in I_u \cap I_v} r_{vk}}{|I_u \cap I_v|} \tag{3}$$

hoặc:

$$\mu_u = \frac{\sum_{k \in I_u} r_{uk}}{|I_u|} \quad \text{and} \quad \mu_v = \frac{\sum_{k \in I_v} r_{vk}}{|I_v|} \tag{4}$$

- Khó có thể khẳng định cách nào tốt hơn.
- Trong các trường hợp cực đoan, nếu |Iu ∩ Iv| = 1 (chỉ có một mặt hàng chung), cách thứ nhất không thể sử dụng. Ngay cả khi |Iu ∩ Iv| = 2 hoặc 3 và các giá trị đánh giá của một người dùng (u hoặc v) là giống nhau, độ tương đồng cũng sẽ bằng 0
- Cách thứ hai hiệu quả hơn về mặt tính toán (chỉ cần tính một lần cho mỗi người dùng)
  Tuy nhiên, nhiều cách triển khai vẫn tính μu và μv theo từng cặp người dùng

Prediction function: predicting user ratings using weighted average

- Gọi u là người dùng đang xét (active/target user), tức là người mà ta cần dự đoán các đánh giá.
- Gọi $\hat{r}_{u,j}$ là giá trị đánh giá (chưa quan sát) của người dùng u đối với **vật phẩm** j mà ta cần dự đoán.
- Kịch bản dự đoán:
  - Tìm tập k người dùng tương tự nhất $U_u(j)$ của người dùng u, những người đã đánh giá **vật phẩm** j, sử dụng độ tương đồng Pearson hoặc cosine. Tập này còn được gọi là nhóm lân cận (peer group) của u đối với j.
  - Do các người dùng khác nhau có thể sử dụng các thang đánh giá khác nhau (ví dụ: có người luôn chấm điểm cao, người khác lại chấm thấp), nên các đánh giá thô cần được chuẩn hóa bằng cách trừ trung bình theo từng hàng (mean-centering):

$$s_{u,j} = r_{u,j} - \mu_u \quad \forall u \in \{1, \ldots, m\}$$

- Tính giá trị dự đoán có trọng số cho $\hat{r}_{u,j}$ như sau:

$$\hat{r}_{u,j} = \mu_u + \frac{\sum_{v \in U_u(j)} \text{Sim}(u,v) \cdot s_{v,j}}{\sum_{v \in U_u(j)} |\text{Sim}(u,v)|} = \mu_u + \frac{\sum_{v \in U_u(j)} \text{Sim}(u,v) \cdot (r_{v,j} - \mu_v)}{\sum_{v \in U_u(j)} |\text{Sim}(u,v)|}$$

Example of predicting user ratings using weighted average

Item-Id ⇒ / User-Id ⇓	1	2	3	4	5	6	Mean Rating	Cosine$(i, 3)$ (user-user)	Pearson$(i, 3)$ (user-user)
1	7	6	7	4	5	4	5.5	0.956	0.894
2	6	7	?	4	3	4	4.8	0.981	0.939
3	?	3	3	1	1	?	2	1.0	1.0
4	1	2	2	3	3	4	2.5	0.789	-1.0
5	1	?	1	2	3	3	2	0.645	-0.817

source: from the textbook [8]

- Bảng cho thấy các đánh giá của 5 người dùng {1 ... 5} trên 6 mặt hàng {1 ... 6}
- Mỗi giá trị đánh giá nằm trong khoảng {1 ... 7}
- Xét người dùng hiện tại (target user) là u = 3
- Tính độ tương đồng giữa người dùng u và các người dùng khác bằng hai phương pháp: Cosine và Pearson.

Example of predicting user ratings using weighted average (cont'd)

- Ví dụ, tính điểm tương đồng Cosine giữa người dùng 1 và u(=3)

$$\begin{aligned}\text{Cosine}(1,3) &= \frac{6\cdot 3+7\cdot 3+4\cdot 1+5\cdot 1}{\sqrt{6^2+7^2+4^2+5^2}\cdot\sqrt{3^2+3^2+1^2+1^2}}\\ &= 0.956\end{aligned}$$

- Tính điểm tương đồng Pearson

$$\begin{aligned}&\text{Pearson}(1,3)\\ &= \frac{(6-5.5)\cdot(3-2)+(7-5.5)\cdot(3-2)+(4-5.5)\cdot(1-2)+(5-5.5)\cdot(1-2)}{\sqrt{1.5^2+1.5^2+(-1.5)^2+(-0.5)^2}\cdot\sqrt{1^2+1^2+(-1)^2+(-1)^2}}\\ &= 0.894\end{aligned}$$

Example of predicting user ratings using weighted average (cont'd)

- Gọi k = 2. Hai người dùng gần nhất (top–2) với người dùng 3 là người dùng 1 và 2 theo cả hai độ đo
- Sử dụng trung bình có trọng số theo Pearson của các đánh giá gốc từ người dùng 1 và 2 để dự đoán các giá trị còn thiếu $\hat{r}_{31}$ và $\hat{r}_{36}$ như sau:

$$\hat{r}_{31} \quad \frac{7 \cdot 0.894 + 6 \cdot 0.939}{0.894 + 0.939} \approx 6.49$$

$$=\hat{r}_{36}= \quad \frac{4 \cdot 0.894 + 4 \cdot 0.939}{0.894 + 0.939} = 4.0$$

- Các dự đoán tương ứng khi sử dụng đánh giá đã được chuẩn hóa theo trung bình (mean-centered ratings):

$$\hat{r}_{31} = 2 + \frac{1.5 \cdot 0.894 + 1.2 \cdot 0.939}{0.894 + 0.939} \approx 3.35$$

$$\hat{r}_{36} = 2 + \frac{-1.5 \cdot 0.894 - 0.8 \cdot 0.939}{0.894 + 0.939} \approx 0.86$$

Discounted similarity between users

- Độ tin cậy của hàm tương đồng Sim(u, v) thường bị ảnh hưởng bởi số lượng đánh giá chung |Iu ∩ Iv| giữa hai người dùng u và v
- Khi số lượng đánh giá chung giữa hai người dùng quá ít, cần giảm bớt mức độ quan trọng của cặp người dùng đó
- Gọi β là ngưỡng tối thiểu cho số lượng đánh giá chung, độ tương đồng sau khi điều chỉnh (discounted similarity) được định nghĩa như sau:

$$\text{DiscountedSim}(u, v) = \text{Sim}(u, v) \cdot \frac{\min\{|I_u \cap I_v|, \beta\}}{\beta} \tag{7}$$

- Độ tương đồng đã điều chỉnh này được sử dụng cả trong việc xác định nhóm lân cận (top–k người dùng gần nhất) và trong quá trình tính toán dự đoán

Variants of the prediction function

- Sử dụng chuẩn hoá z-score thay vì mean-centering
- Độ lệch chuẩn của user v được thể hiện là:

$$\sigma_v = \sqrt{\frac{\sum_{j \in I_v} (r_{vj} - \mu_v)^2}{|I_v| - 1}} \qquad \forall v \in \{1 \dots m\} \tag{8}$$

- Điểm chuẩn hoá rating được tính như sau:

$$z_{vj} = \frac{r_{vj} - \mu_v}{\sigma_v} \tag{9}$$

- Hàm dự đoán cho rating của user u đối với vật phẩm j:

$$\hat{r}_{uj} = \mu_u + \sigma_u \cdot \frac{\sum_{v \in U_u(j)} Sim(u, v) \cdot z_{vj}}{\sum_{v \in U_u(j)} |Sim(u, v)|} \tag{10}$$

Finding top–*k* closest users (i.e., filtering the peer group)

- Khuếch đại độ tương đồng giữa người dùng:
  Sim(u, v) = Pearson(u, v)^α
  Chọn α > 1 nếu muốn tăng cường mức độ quan trọng của độ tương đồng (11)

- Cần loại bỏ các người dùng có tương quan yếu hoặc tương quan âm với người dùng đang xét u khỏi tập top–k
  - Các người dùng có tương quan yếu có thể làm tăng sai số trong dự đoán
  - Các đánh giá có tương quan âm thường không mang nhiều giá trị dự đoán (mặc dù về mặt kỹ thuật hàm dự đoán vẫn có thể sử dụng các giá trị tương quan yếu hoặc âm)

Impact of the long tail

- Một số **vật phẩm** có thể rất phổ biến và thường xuyên xuất hiện như các vật phẩm được nhiều người dùng cùng đánh giá.
- Những đánh giá này đôi khi làm giảm chất lượng của hệ thống gợi ý vì chúng có xu hướng **kém phân biệt** giữa các người dùng khác nhau.
- Cần **giảm trọng số (de-emphasize)** của các vật phẩm này. Ý tưởng tương tự như **inverse document frequency (IDF)** trong tf-idf. Mỗi vật phẩm j được gán một trọng số w_j:

$$w_j = \log\left(\frac{m}{m_j}\right), \quad \forall j \in \{1, \ldots, n\}$$

- Điều chỉnh độ tương đồng (ví dụ: hệ số tương quan Pearson) như sau:

$$\text{Pearson}(u, v) = \frac{\sum_{k \in I_u \cap I_v} w_k \cdot (r_{u,k} - \mu_u) \cdot (r_{v,k} - \mu_v)}{\sqrt{\sum_{k \in I_u \cap I_v} w_k \cdot (r_{u,k} - \mu_u)^2} \cdot \sqrt{\sum_{k \in I_u \cap I_v} w_k \cdot (r_{v,k} - \mu_v)^2}}$$

Item–based neighborhood methods

- Nhóm lân cận (peer group) được xây dựng theo mặt hàng thay vì theo người dùng
  - Cần tính độ tương đồng giữa các mặt hàng (tức là giữa các cột trong ma trận đánh giá)
  - Trước khi tính độ tương đồng giữa các cột, mỗi hàng (tức là mỗi người dùng) được chuẩn hóa bằng cách trừ đi giá trị trung bình (mean-centered)
- Gọi Ui là tập các chỉ số người dùng đã đánh giá mặt hàng i; ví dụ nếu người dùng 1, 3 và 4 đã đánh giá mặt hàng i thì Ui = {1, 3, 4}. Ui ∩ Uj là tập các người dùng đã cùng đánh giá cả hai mặt hàng i và j
- Để tính độ tương đồng giữa hai mặt hàng i và j, sử dụng cosine điều chỉnh (adjusted cosine) được định nghĩa như sau:

$$\begin{aligned}\text{AdjustedCosine}(i,j) &= \frac{\sum_{v\in U_i\cap U_j} s_{vi}\cdot s_{vj}}{\sqrt{\sum_{v\in U_i\cap U_j} s_{vi}^2}\cdot\sqrt{\sum_{v\in U_i\cap U_j} s_{vj}^2}} \\ &= \frac{\sum_{v\in U_i\cap U_j}(r_{vi}-\mu_v)\cdot(r_{vj}-\mu_v)}{\sqrt{\sum_{v\in U_i\cap U_j}(r_{vi}-\mu_v)^2}\cdot\sqrt{\sum_{v\in U_i\cap U_j}(r_{vj}-\mu_v)^2}}\end{aligned} \tag{14}$$

Item–item based prediction function

- Gọi u là người dùng đang xét (active/target user). Gọi t là **vật phẩm** mà giá trị đánh giá $r_{u,t}$ bị thiếu và cần dự đoán $\hat{r}_{u,t}$.
- Ý tưởng cơ bản là tận dụng chính các đánh giá của người dùng trên những **vật phẩm** tương tự để thực hiện dự đoán.
- Kịch bản dự đoán:
  - Xác định top–k **vật phẩm** tương tự nhất với t dựa trên cosine đã điều chỉnh (adjusted cosine), ký hiệu là I_t.
  - Gọi $I_t(u)$ là tập các vật phẩm trong I_t mà người dùng u đã đánh giá.
  - Giá trị dự đoán $\hat{r}_{u,t}$ của người dùng u đối với vật phẩm t được tính bằng trung bình có trọng số như sau:

$$\hat{r}_{u,t} = \frac{\sum_{j \in I_t(u)} \text{AdjustedCosine}(j,t) \cdot r_{u,j}}{\sum_{j \in I_t(u)} |\text{AdjustedCosine}(j,t)|}$$

Row–normalized rating matrix for item–item similarity computation [8]

Item-Id ⇒ / User-Id ⇓	1	2	3	4	5	6	Mean Rating	Cosine$(i,3)$ (user-user)	Pearson$(i,3)$ (user-user)
1	7	6	7	4	5	4	5.5	0.956	0.894
2	6	7	?	4	3	4	4.8	0.981	0.939
3	?	3	3	1	1	?	2	1.0	1.0
4	1	2	2	3	3	4	2.5	0.789	-1.0
5	1	?	1	2	3	3	2	0.645	-0.817

Item-Id ⇒ / User-Id ⇓	1	2	3	4	5	6
1	1.5	0.5	1.5	-1.5	-0.5	-1.5
2	1.2	2.2	?	-0.8	-1.8	-0.8
3	?	1	1	-1	-1	?
4	-1.5	-0.5	-0.5	0.5	0.5	1.5
5	-1	?	-1	0	1	1
Cosine$(1,j)$ (item-item)	1	0.735	0.912	-0.848	-0.813	-0.990
Cosine$(6,j)$ (item-item)	-0.990	-0.622	-0.912	0.829	0.730	1

Example of item–item based prediction for rating values

- Dự đoán các giá trị đánh giá còn thiếu của người dùng 3 cho các **vật phẩm** 1 và 6, tức là ước lượng $\hat{r}_{3,1}$, $\hat{r}_{3,6}$.
- Độ tương đồng giữa các vật phẩm được tính bằng cosine đã điều chỉnh (Adjusted Cosine), ví dụ:

$$\text{AdjustedCosine}(1,3) = \frac{1.5 \cdot 1.5 + (-1.5) \cdot (-0.5) + (-1) \cdot (-1)}{\sqrt{1.5^2 + (-1.5)^2 + (-1)^2} \cdot \sqrt{1.5^2 + (-0.5)^2 + (-1)^2}} = 0.912$$

- Các vật phẩm 2 và 3 là tương tự nhất với vật phẩm 1:

$$\hat{r}_{3,1} = \frac{3 \cdot 0.735 + 3 \cdot 0.912}{0.735 + 0.912} = 3.0 \quad \text{(so với 3.35 của phương pháp user-based)}$$

- Các vật phẩm 4 và 5 là tương tự nhất với vật phẩm 6:

$$\hat{r}_{3,6} = \frac{1 \cdot 0.829 + 1 \cdot 0.730}{0.829 + 0.730} = 1.0 \quad \text{(so với 0.86 của phương pháp user-based)}$$

Efficient implementation and computational complexity

- Lưu trữ các tính toán trung gian để tăng hiệu quả xếp hạng gợi ý
- Quy trình gợi ý được chia thành hai pha: offline và online
  - Offline: (a) tính trước độ tương đồng giữa người dùng–người dùng (hoặc mặt hàng–mặt hàng) và xây dựng các nhóm lân cận (peer group); (b) lưu trữ trước nhóm lân cận tương ứng cho mỗi người dùng (hoặc mỗi mặt hàng)
  - Online: sử dụng các giá trị tương đồng và nhóm lân cận đã lưu để đưa ra dự đoán
- Gọi n' ($\ll n$) là số lượng đánh giá tối đa của một người dùng (một hàng), và m' ($\ll m$) là số lượng đánh giá tối đa của một mặt hàng (một cột)
  - n' là thời gian chạy tối đa để tính độ tương đồng giữa một cặp người dùng
  - m' là thời gian chạy tối đa để tính độ tương đồng giữa một cặp mặt hàng
  - Việc xác định nhóm lân cận của một người dùng (user–based): $O(m \cdot n')$
  - Việc xác định nhóm lân cận của một mặt hàng (item–based): $O(n \cdot m')$
  - Tính nhóm lân cận cho tất cả người dùng: $O(m^2 \cdot n')$
  - Tính nhóm lân cận cho tất cả mặt hàng: $O(n^2 \cdot m')$

Efficient implementation and computational complexity (cont'd)

- Độ phức tạp không gian để lưu tất cả các cặp độ tương đồng giữa các người dùng: $O(m^2)$
- Độ phức tạp không gian để lưu tất cả các cặp độ tương đồng giữa các mặt hàng: $O(n^2)$
- Thông thường $m > n$ nên các phương pháp dựa trên người dùng (user–based) cần nhiều bộ nhớ hơn so với phương pháp dựa trên mặt hàng (item–based)
- Pha online:
  - Gọi k là kích thước của tập lân cận (neighborhood) dùng để dự đoán
  - Độ phức tạp thời gian để xếp hạng tất cả các mặt hàng cho một người dùng mục tiêu: $O(k \cdot n)$ (áp dụng cho cả user–based và item–based)
  - Độ phức tạp thời gian để xếp hạng tất cả người dùng cho một mặt hàng cụ thể: $O(k \cdot m)$
- Độ phức tạp thời gian của pha offline lớn hơn nhiều so với pha online
- Trong thực tế, cần sử dụng các kỹ thuật tiền xử lý (pre-computing) và lưu đệm (caching) để tăng tốc cả hai pha (đáp ứng yêu cầu gợi ý gần thời gian thực)

Comparing user–based and item–based methods

- Các phương pháp dựa trên vật phẩm (item–based) thường cung cấp các khuyến nghị phù hợp hơn.
  - Lý do là vì các đánh giá của chính người dùng được sử dụng trực tiếp để thực hiện gợi ý, trong khi phương pháp dựa trên người dùng (user–based) phải ngoại suy từ các người dùng khác (có thể có sở thích khác nhau).
- Các phương pháp dựa trên người dùng có thể mang lại các khuyến nghị đa dạng và mới lạ hơn.
  - Tính mới (novelty), đa dạng (diversity) và bất ngờ thú vị (serendipity) thể hiện mức độ gây ngạc nhiên, thú vị và khả năng khám phá.
- Các phương pháp dựa trên vật phẩm có thể đưa ra các lý do cụ thể cho khuyến nghị, ví dụ:
  - "Vì bạn đã xem 'Secrets of the Wings', nên các gợi ý là …"
- Các phương pháp dựa trên vật phẩm ổn định hơn trước các thay đổi của dữ liệu đánh giá, vì:
  - Số người dùng lớn hơn số vật phẩm → ít đồng đánh giá giữa người dùng, nên độ tương đồng user–based dễ biến động khi có thêm dữ liệu.
  - Người dùng mới xuất hiện thường xuyên hơn → độ tương đồng giữa các vật phẩm ổn định ít cần tính toán lại hơn.

Pros and cons of neighborhood–based methods

- Ưu điểm:
  - Đơn giản: dễ triển khai và dễ debug
  - Trực quan: dễ giải thích vì sao một mặt hàng được gợi ý
  - Tương đối ổn định khi thêm người dùng và mặt hàng mới
  - Có tính mở rộng dần (incremental): dễ bổ sung dữ liệu
- Nhược điểm:
  - Chi phí tính toán cao với dữ liệu lớn, đặc biệt ở pha offline
  - Dễ bị độ bao phủ thấp do dữ liệu thưa (sparsity)

Neighborhood–based CF recommender systems

1. Dự đoán đánh giá bằng các phương pháp dựa trên lân cận (Predicting ratings with neighborhood–based methods)
2. **Phân cụm và các phương pháp dựa trên lân cận (Clustering and neighborhood–based methods)**
3. Giảm chiều và các phương pháp dựa trên lân cận (Dimensionality reduction and neighborhood methods)
4. Mô hình đồ thị cho các phương pháp dựa trên lân cận (Graph models for neighborhood–based methods)

Clustering and neighborhood–based methods

- Vấn đề chính của phương pháp dựa trên lân cận là độ phức tạp rất lớn của pha offline
  - $O(m^2 \cdot n')$ là không khả thi nếu số lượng người dùng m lên đến hàng trăm triệu
  - Ví dụ $m = 10^8$ và $n' = 100$ thì $O(m^2 \cdot n') = O(10^{18})$
- Ý tưởng: thay thế việc tính lân cận offline bằng phân cụm (clustering) offline
  - Vấn đề: bước tìm láng giềng gần nhất tạo ra rất nhiều nhóm lân cận (peer groups)
  - Giải pháp: phân cụm tạo ra số lượng nhóm ít hơn
  - Phân cụm hiệu quả hơn nhiều so với $O(m^2 \cdot n')$
  - Sau khi phân cụm: chọn top–k láng giềng gần nhất trong cùng một cụm để dự đoán
- Ưu và nhược điểm khi kết hợp phân cụm với phương pháp lân cận:
  - Kích thước mỗi cụm nhỏ hơn nhiều so với m (hoặc n), nên việc tìm top–k trở nên hiệu quả
  - Tuy nhiên có thể giảm độ chính xác do chỉ tìm trong phạm vi cụm (tính cục bộ)
  - Cụm càng chi tiết (fine-grained) thì hiệu quả càng cao nhưng độ chính xác có thể giảm
  - Trong nhiều trường hợp, việc tăng mạnh hiệu quả chỉ làm giảm nhẹ độ chính xác

Clustering on the rating matrix

- Thách thức: ma trận đánh giá không đầy đủ
  - Các phương pháp phân cụm cần được điều chỉnh để làm việc với dữ liệu bị thiếu nhiều
- Các phương pháp như k–means có thể được điều chỉnh để xử lý dữ liệu không đầy đủ
  - Vấn đề: ma trận đánh giá m × n bị thiếu dữ liệu
  - Việc tính giá trị trung bình và khoảng cách trở nên không xác định
  - Giải pháp: tính giá trị trung bình chỉ dựa trên các giá trị đã quan sát trong mỗi cụm
  - Khoảng cách được tính chỉ trên tập các chiều mà cả điểm dữ liệu và đại diện cụm đều có giá trị
  - Khoảng cách Manhattan phù hợp hơn so với khoảng cách Euclid hoặc các loại khoảng cách khác
- Phân cụm có thể áp dụng cho cả người dùng (theo hàng) và mặt hàng (theo cột)

Neighborhood–based CF recommender systems

1. Dự đoán đánh giá bằng các phương pháp dựa trên lân cận (Predicting ratings with neighborhood–based methods)
2. Phân cụm và các phương pháp dựa trên lân cận (Clustering and neighborhood–based methods)
3. **Giảm chiều và các phương pháp dựa trên lân cận (Dimensionality reduction and neighborhood methods)**
4. Mô hình đồ thị cho các phương pháp dựa trên lân cận (Graph models for neighborhood–based methods)

Dimensionality reduction and neighborhood methods

- Giảm chiều (Dimensionality Reduction – DR) có thể cải thiện cả chất lượng và hiệu quả
  - DR cung cấp biểu diễn dày (dense) với số chiều thấp dựa trên các nhân tố tiềm ẩn (latent)
  - Việc tính độ tương đồng giữa các vector dày, số chiều thấp trở nên dễ dàng và hiệu quả hơn.
  - Từ đó có thể tìm được các lân cận phù hợp hơn trong thời gian ngắn hơn
  - Có hai cách áp dụng DR trong hệ thống gợi ý
- Cách thứ nhất: áp dụng DR cho người dùng (theo hàng) hoặc cho mặt hàng (theo cột)
  - Biểu diễn giảm chiều sẽ nén chiều của mặt hàng hoặc người dùng thành các nhân tố tiềm ẩn
  - Biểu diễn này giúp giảm vấn đề dữ liệu thưa trong các mô hình dựa trên lân cận
- Cách thứ hai: áp dụng DR đồng thời cho cả người dùng và mặt hàng
  - Cách này thuộc nhóm phương pháp CF dựa trên mô hình (model-based), sẽ được trình bày sau

Dimensionality reduction for user–based collaborative filtering

- Ý tưởng: biến đổi ma trận đánh giá R kích thước m × n sang không gian có số chiều thấp hơn bằng các kỹ thuật giảm chiều
  - Ma trận kết quả R′ có kích thước m × d với d ≪ n
  - Mỗi vector đánh giá n chiều của người dùng được chuyển thành vector d chiều
  - Không giống như các vector ban đầu, các vector d chiều là dạng dày (dense)
  - Việc tính độ tương đồng giữa các vector d chiều chính xác và hiệu quả hơn
- Các kỹ thuật giảm chiều phổ biến:
  - Principal Component Analysis (PCA), Singular Value Decomposition (SVD), v.v.

Neighborhood–based CF recommender systems

1. Dự đoán đánh giá bằng các phương pháp dựa trên lân cận (Predicting ratings with neighborhood–based methods)
2. Phân cụm và các phương pháp dựa trên lân cận (Clustering and neighborhood–based methods)
3. Giảm chiều và các phương pháp dựa trên lân cận (Dimensionality reduction and neighborhood methods)
4. **Mô hình đồ thị cho các phương pháp dựa trên lân cận (Graph models for neighborhood–based methods)**

Graph models for neighborhood–based methods

- Độ thưa của dữ liệu đánh giá gây ra vấn đề lớn trong việc tính độ tương đồng
- Phương pháp dựa trên đồ thị (graph–based) là một cách tiếp cận để định nghĩa độ tương đồng trong các phương pháp dựa trên lân cận
- Ý tưởng chung là sử dụng tính bắc cầu cấu trúc (structural transitivity) trên đồ thị để:
  - Suy ra và ước lượng mối quan hệ giữa người dùng và/hoặc mặt hàng
  - Đồng thời xếp hạng các gợi ý
- Đồ thị có thể được xây dựng trên người dùng, trên mặt hàng, hoặc trên cả hai
- Có nhiều thuật toán áp dụng trên đồ thị như random walk, shortest path, v.v.

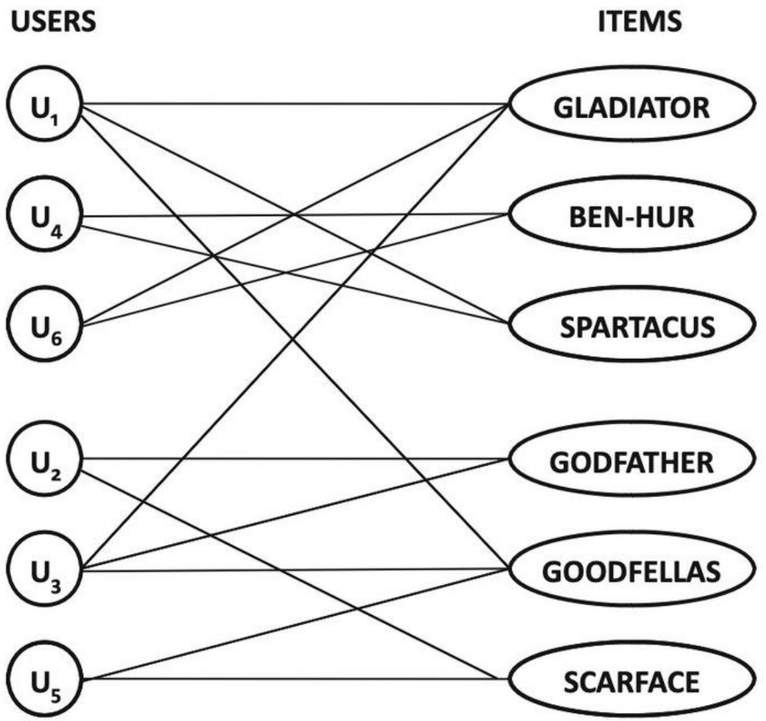
User–item graphs

- Đồ thị user–item là một đồ thị vô hướng và hai phía (bipartite): G = (Nu ∪ Ni, A)
  - Nu là tập các nút biểu diễn người dùng
  - Ni là tập các nút biểu diễn mặt hàng
  - Tất cả các cạnh trong đồ thị chỉ tồn tại giữa người dùng và mặt hàng
  - Một cạnh vô hướng tồn tại giữa người dùng i và mặt hàng j khi và chỉ khi người dùng i đã đánh giá mặt hàng j
  - Do đó, |A| bằng số lượng phần tử đã quan sát trong ma trận đánh giá
- Ưu điểm: hai người dùng không cần phải đánh giá nhiều mặt hàng giống nhau vẫn có thể được coi là lân cận nếu tồn tại nhiều đường đi ngắn giữa họ
  - Lân cận có thể được xác định thông qua các kết nối gián tiếp giữa các nút
  - Tất nhiên, các đường đi trực tiếp hoặc ngắn hơn sẽ có trọng số mạnh hơn khi tính độ tương đồng
  - Có nhiều cách khác nhau để xác định lân cận trên đồ thị nhằm xử lý vấn đề dữ liệu thưa

User–item graphs (cont'd)

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			5		2
U_2		5			4	
U_3	5	3		1		
U_4			3			4
U_5				3	5	
U_6	5		4			

(a) Ratings matrix



(b) User-item graphs of specified ratings

source: from the textbook [8]

Defining neighborhoods with random walks

- Lân cận của một người dùng được định nghĩa là tập các người dùng thường xuyên được "ghé thăm" trong một quá trình random walk bắt đầu từ người dùng đó
- Làm thế nào để đo tần suất kỳ vọng của các random walk này?
  - Sử dụng Personalized PageRank hoặc SimRank
  - Để xác định k người dùng tương tự nhất với một người dùng cho user–based CF
  - Để xác định k mặt hàng tương tự nhất với một mặt hàng bằng cách bắt đầu random walk từ mặt hàng đó
- Tại sao cách tiếp cận này hiệu quả hơn với dữ liệu thưa?
  - Khi tính Pearson correlation: hai người dùng cần có kết nối trực tiếp thông qua các mặt hàng chung
  - Trong đồ thị user–item thưa, kết nối trực tiếp như vậy có thể không tồn tại với nhiều nút
  - Phương pháp random walk còn xét cả các kết nối gián tiếp, từ đó giúp khắc phục vấn đề dữ liệu thưa

Defining neighborhoods with the Katz measure

- Dựa trên số lượng các đường đi (walk) có trọng số giữa một cặp nút
- Trọng số của mỗi đường đi nằm trong khoảng (0, 1) và giảm dần theo độ dài của đường đi. Tổng số đường đi có trọng số giữa hai nút chính là độ đo Katz
- Trực giác: nếu hai người dùng thuộc cùng một "lân cận" theo kết nối dựa trên đường đi, thì khả năng tồn tại liên kết giữa họ là cao
- Độ đo Katz: gọi $n^{(t)}$ là số lượng đường đi có độ dài t giữa hai nút i và j
- Với tham số $\beta < 1$ do người dùng chọn, độ đo Katz giữa i và j được định nghĩa như sau: (được tính bằng tổng có trọng số của tất cả các đường đi theo độ dài t)

$$\mathrm{Katz}(i,j) = \sum_{t=1}^{\infty} \beta^t \cdot n_{ij}^{(t)} \tag{26}$$

Giá trị β đóng vai trò là hệ số suy giảm, làm giảm ảnh hưởng của các đường đi dài hơn
Với giá trị β đủ nhỏ, tổng vô hạn sẽ hội tụ

Defining neighborhoods with the Katz measure (cont'd)

- Gọi K là ma trận m × m chứa hệ số Katz giữa các cặp người dùng
- Nếu A là ma trận kề đối xứng của một đồ thị vô hướng, thì ma trận hệ số Katz K được tính như sau: (được biểu diễn bằng tổng vô hạn các lũy thừa của A có trọng số)

$$K = \sum_{i=1}^{\infty} (\beta A)^i = (I - \beta A)^{-1} - I \tag{27}$$

- Giá trị β phải được chọn nhỏ hơn nghịch đảo của trị riêng lớn nhất của A để đảm bảo tổng vô hạn hội tụ
- A có thể được thay bằng ma trận trọng số của đồ thị, nhằm gán trọng số cho các cạnh trong đồ thị user–item theo giá trị đánh giá tương ứng
- Nên áp dụng ngưỡng cho độ dài đường đi tối đa để giảm chi phí tính toán

Item–item graphs

- Đồ thị item–item được gọi là đồ thị tương quan (correlation graph)
- Đồ thị item–item là một mạng có trọng số và có hướng G = (N, A)
  - Mỗi nút trong N là một mặt hàng
  - Mỗi cạnh (i, j) trong A biểu diễn mối quan hệ giữa hai mặt hàng i và j và có trọng số wij
  - Nếu i và j được ít nhất một người dùng cùng đánh giá thì cả hai cạnh (i, j) và (j, i) đều tồn tại trong G
- Cách tính trọng số wij của cạnh (i, j):
  - Gọi Ui và Uj là tập người dùng đã đánh giá mặt hàng i và j
  - Khởi tạo wij = |Ui ∩ Uj|, khi đó wij = wji (đối xứng)
  - Chuẩn hóa trọng số: tổng trọng số của các cạnh đi ra từ một nút bằng 1

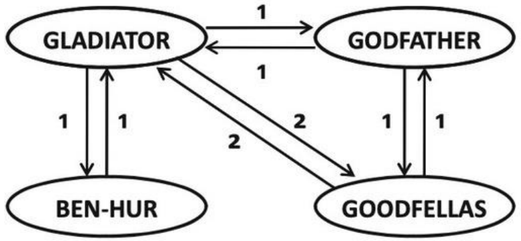
$$w'_{ij} = \frac{w_{ij}}{\sum_{(i,k)\in A} w_{ik}} \quad \text{and} \quad w'_{ji} = \frac{w_{ji}}{\sum_{(j,k)\in A} w_{jk}} \tag{28}$$

  - Trọng số của các cạnh trong đồ thị G tương ứng với xác suất của quá trình random walk

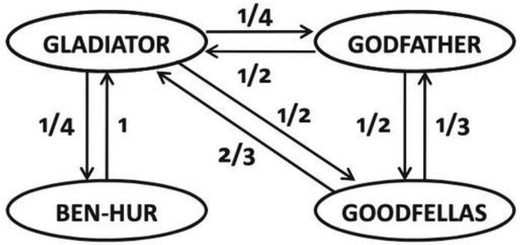
Example of item–item graph [8]

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS
U_1	1			5
U_2		5		
U_3	5	3		1
U_4			3	
U_5				3
U_6	5		4	

(a) Ratings matrix



(b) Unnormalized correlation graph



(c) Normalized correlation graph

Item–item graphs (cont'd)

- Trọng số trên đồ thị tương quan đã chuẩn hóa không đối xứng
- Trọng số có thể được xác định bằng cách sử dụng cosine giữa các vector đánh giá của hai mặt hàng
- Các phương pháp random walk có thể được sử dụng để xác định lân cận của một mặt hàng
- Đồ thị này có thể được sử dụng trong phương pháp collaborative filtering dựa trên mặt hàng

References

1. J. Han, M. Kamber, and J. Pei. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, Elsevier, 2012 [Book1].
2. C. Aggarwal. *Data Mining: The Textbook*. Springer, 2015 [Book2].
3. J. Leskovec, A. Rajaraman, and J. D. Ullman. *Mining of Massive Datasets*. Cambridge University Press, 2014 [Book3].
4. M. J. Zaki and W. M. Jr. *Data Mining and Analysis: Fundamental Concepts and Algorithms*. Cambridge University Press, 2013 [Book4].
5. D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010 [Book5].
6. J. VanderPlas. *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly, 2017 [Book6].
7. J. Grus. *Data Science from Scratch: First Principles with Python*. O'Reilly, 2015 [Book7].
8. C. Aggarwal. *Recommender Systems: The Textbook*. Springer, 2016 [Book8].

Summary

- Recommendation: dự đoán/xếp hạng, mục tiêu, phương pháp, thách thức, ứng dụng
- Rating matrices, thang đánh giá, đánh giá tường minh/ngầm, dữ liệu thưa (sparsity), long–tail, v.v.
- Neighborhood–based CF:
  - Dự đoán rating (user–based, item–based), người dùng mục tiêu (target/active user), nhóm lân cận (peer groups);
  - Pearson correlation, cosine điều chỉnh (adjusted cosine) cho tính toán độ tương đồng user–user và item–item;
  - Bias người dùng, chuẩn hóa rating, mean–centering, v.v.
  - Clustering–based neighborhood CF
  - Dimensionality reduction: SVD, Compact SVD, Truncated SVD, v.v.
  - Graph models: tính bắc cầu cấu trúc (structural transitivity), random walk, đồ thị user–item và item–item